AstroTutor

Grafici del training e del confronto finale

6 modelli · 600 coppie di training · 960 risposte di test · 18 figure

La correttezza stimata dal giudice migliora in cinque modelli su sei. Il miglioramento non si traduce in un adattamento didattico uniforme: le risposte diventano più brevi e, in alcuni casi, meno complete.

Come usare il fascicolo
Figure 01-06: andamento del training. Figure 07-15: risultati e incertezza. Figura 16: risorse. Figure 17-18: transizioni e differenze per argomento. Per il corpo della relazione si consigliano 01, 07, 09, 10, 13 e 15; le altre possono andare in appendice.

Limiti essenziali
I giudizi provengono da GPT-OSS 120B tramite Groq e non sono stati validati da revisori umani. Il test contiene 20 domande ripetute a quattro livelli, su 10 brani: le 960 risposte non sono osservazioni indipendenti. Il training usa un solo seed; non ci sono curve di validation. Non è stato eseguito un braccio SFT in questo confronto. Non si misura l'apprendimento degli studenti.

Fonti e riproducibilità
Grafici ricavati dai log salvati dei sei run e dai giudizi finali. Il pacchetto include PNG, SVG, didascalie, script di generazione e checksum delle fonti. Nessuna risposta o configurazione di training è stata modificata per questa analisi.

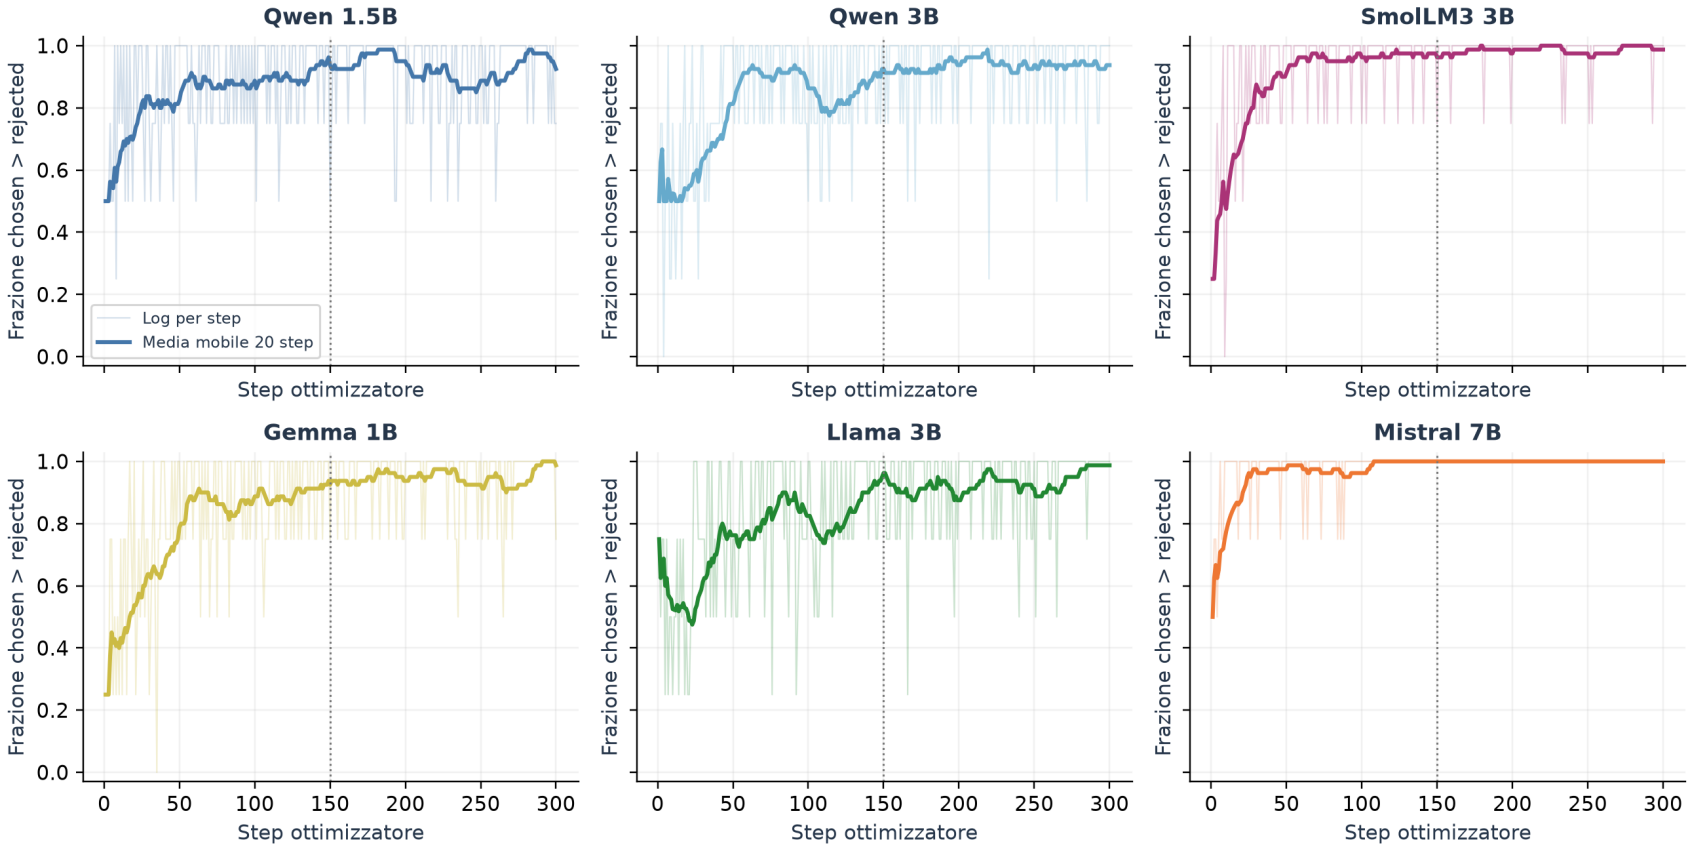
FIGURA 01 | TRAINING



Training: 600 coppie sintetiche, 2 epoche, seed 42. Nessuna validation.

La loss misura l'obiettivo di preferenza sul training. Una loss più bassa non prova correttezza, qualità didattica o generalizzazione; le scale tra modelli non costituiscono una classifica di qualità. Linea tenue: dati grezzi; linea piena: media mobile retrospettiva di 20 step (finestra ridotta all'inizio). Linea verticale: fine prima epoca.

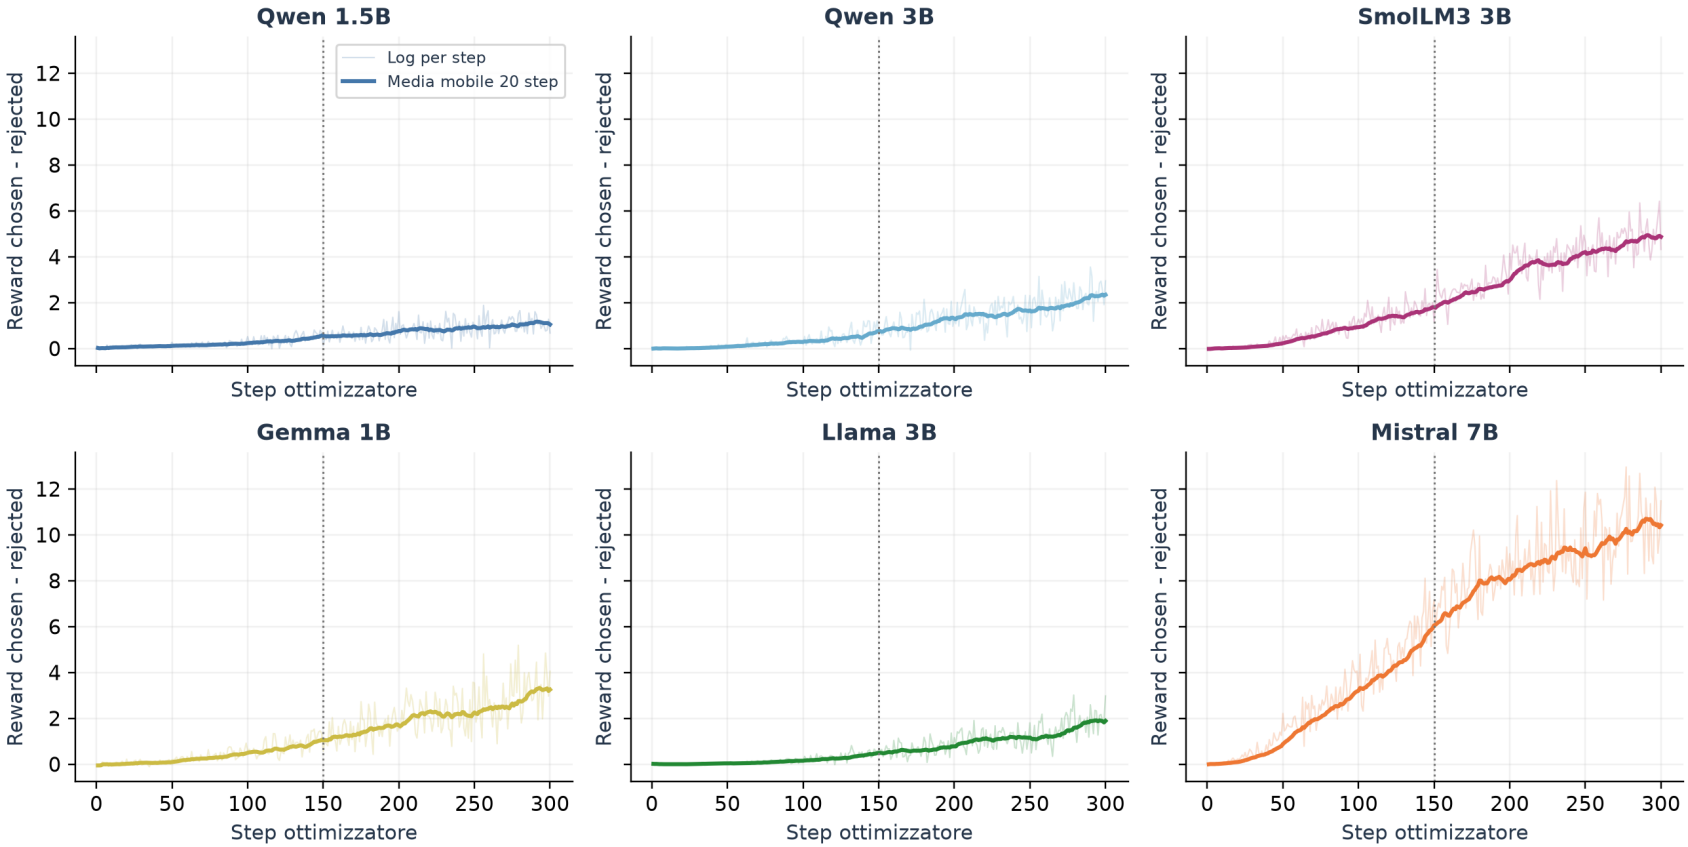
Accuratezza delle preferenze sul training



Training: 600 coppie sintetiche, 2 epoche, seed 42. Nessuna validation.

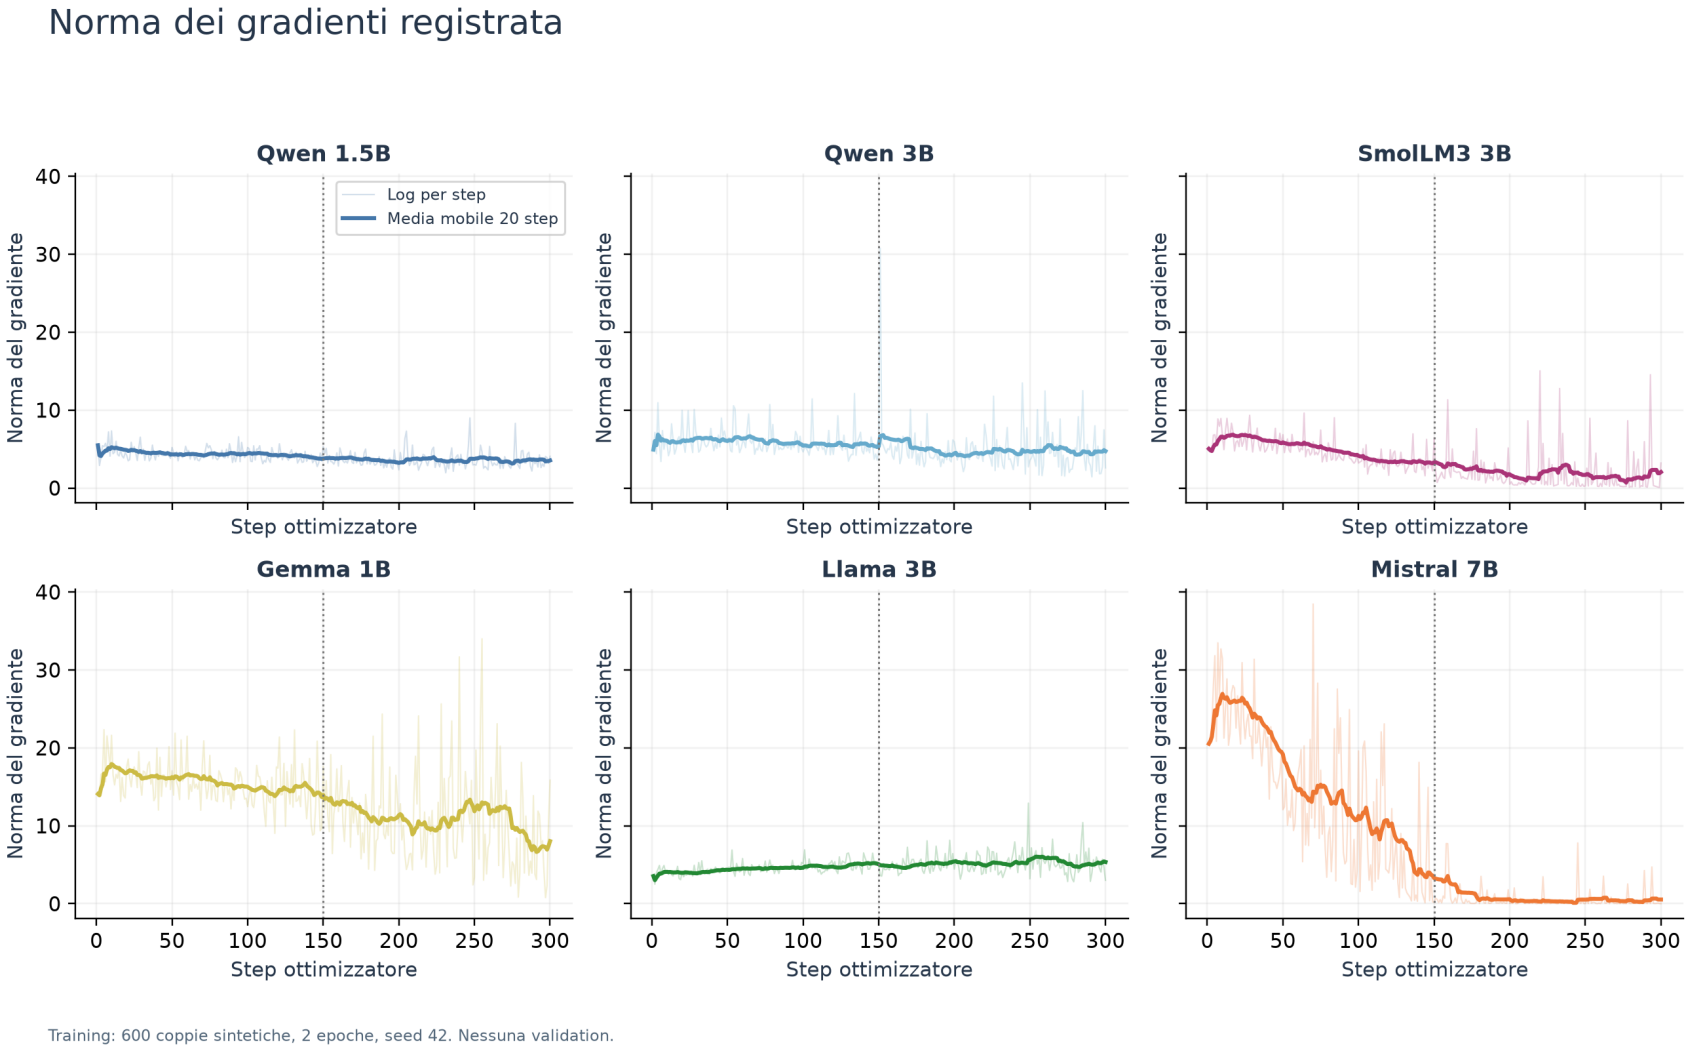
Quota di esempi per cui il reward implicito della risposta preferita supera quello della rifiutata. Non è accuratezza scientifica sul test. Linea tenue: dati grezzi; linea piena: media mobile retrospettiva di 20 step (finestra ridotta all'inizio). Linea verticale: fine prima epoca.

Margine di preferenza durante il training



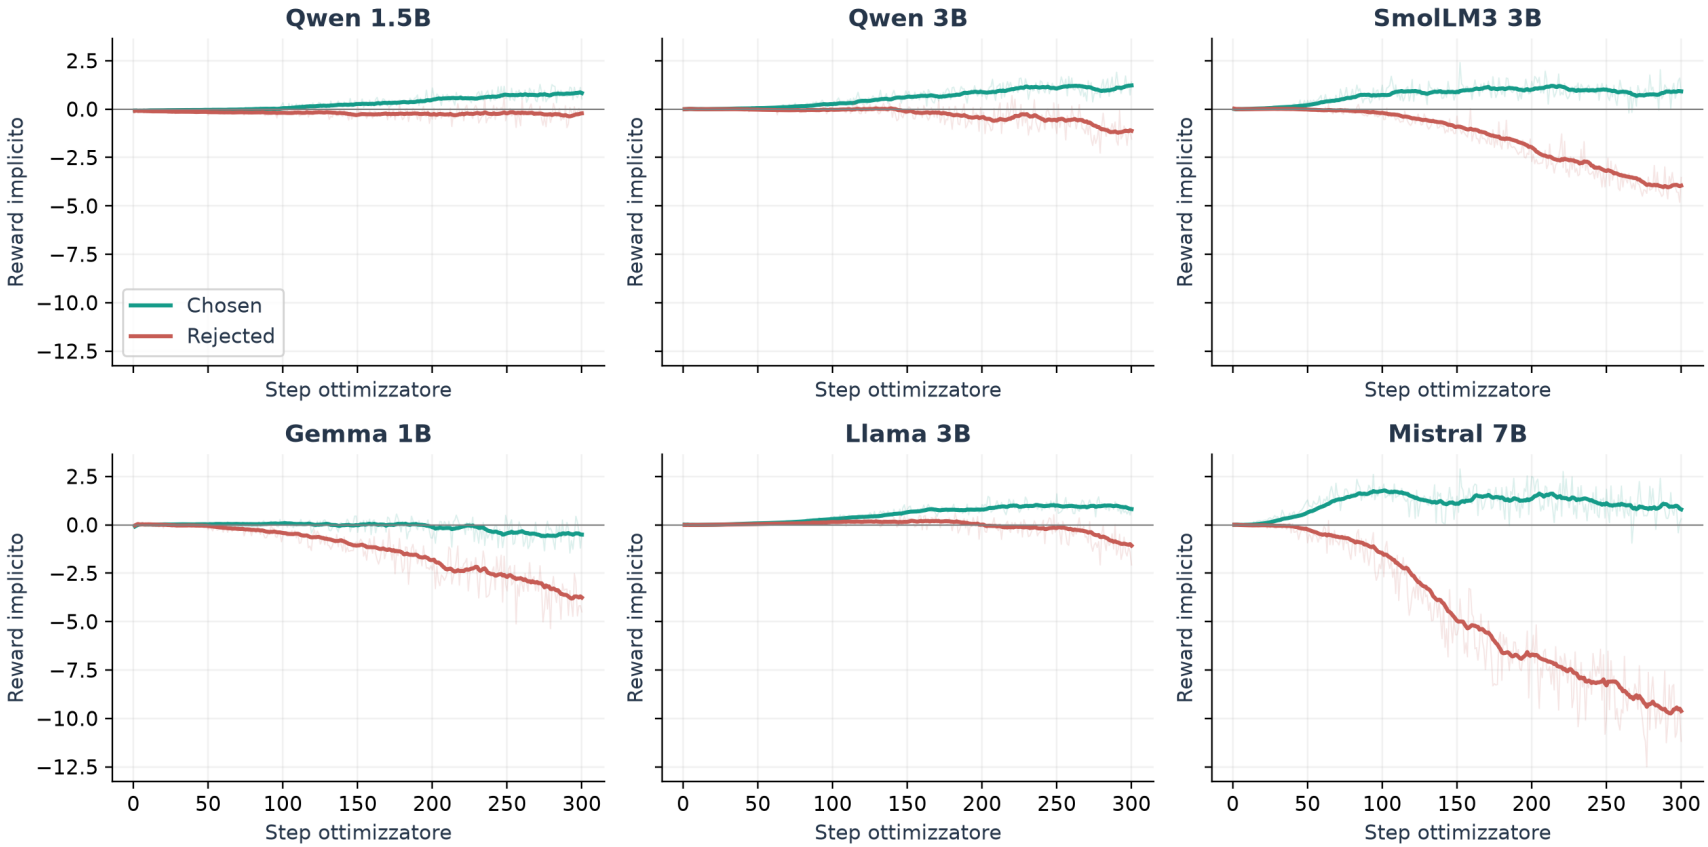
Training: 600 coppie sintetiche, 2 epoche, seed 42. Nessuna validation.

Il margine confronta i reward impliciti rispetto al modello di riferimento. Valori positivi indicano maggiore preferenza per chosen; non sono voti di un docente. Linea tenue: dati grezzi; linea piena: media mobile retrospettiva di 20 step (finestra ridotta all'inizio). Linea verticale: fine prima epoca.



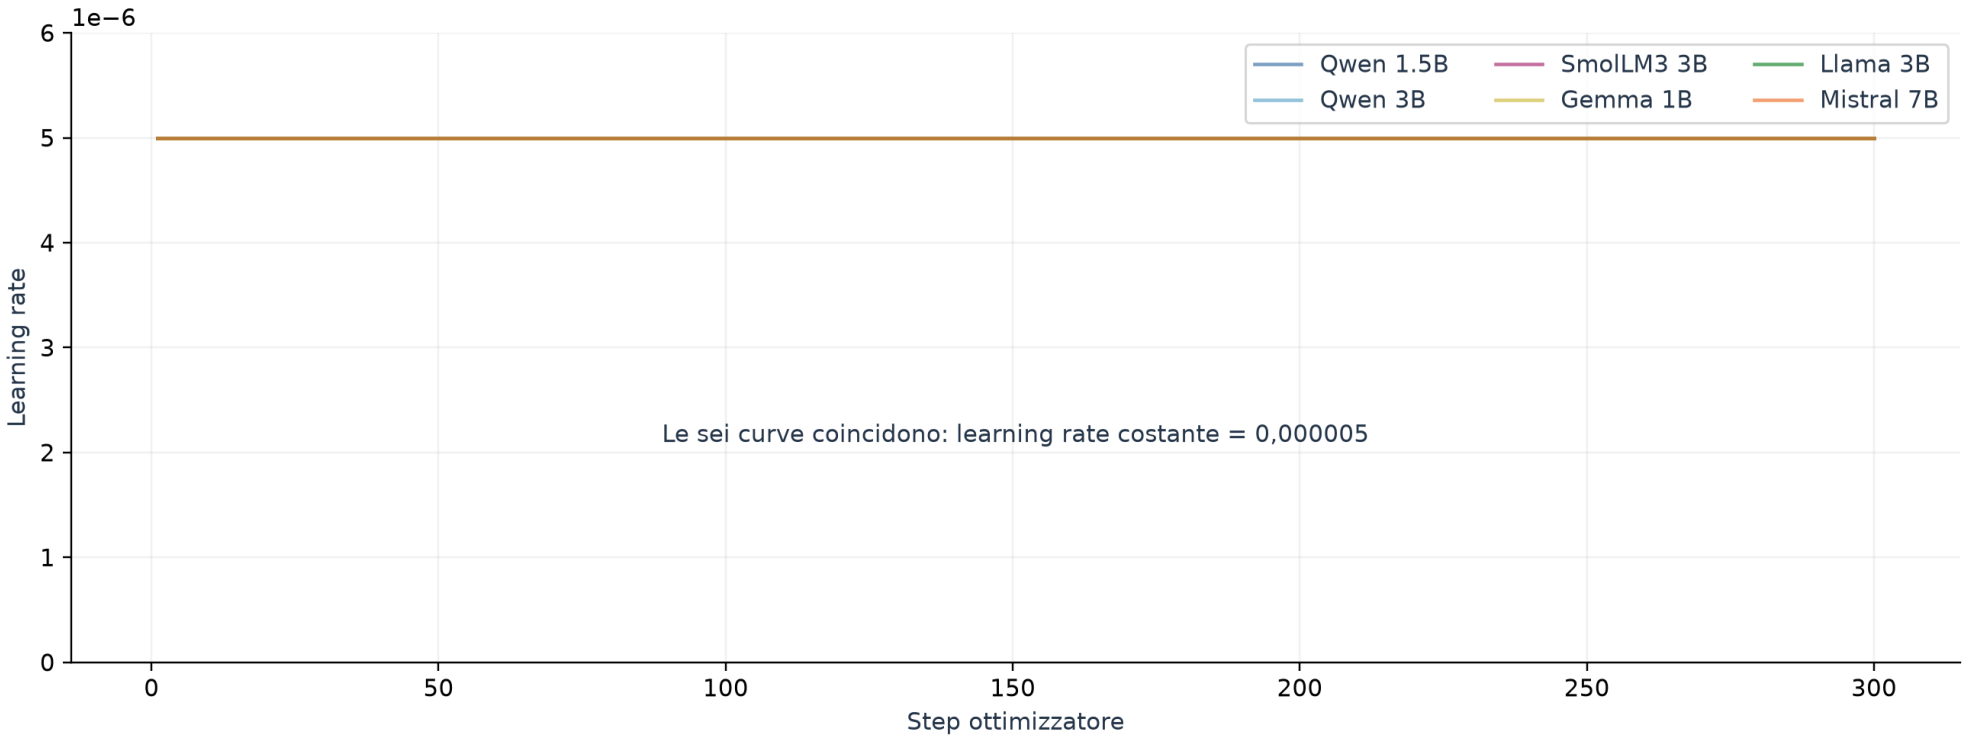
Diagnostica dell'ottimizzazione: non è una misura di qualità delle risposte. Il valore registrato può precedere il clipping e superarne la soglia. Linea tenue: dati grezzi; linea piena: media mobile retrospettiva di 20 step (finestra ridotta all'inizio). Linea verticale: fine prima epoca.

Reward impliciti: chosen e rejected



Training: 600 coppie sintetiche, 2 epoche, seed 42. Nessuna validation.

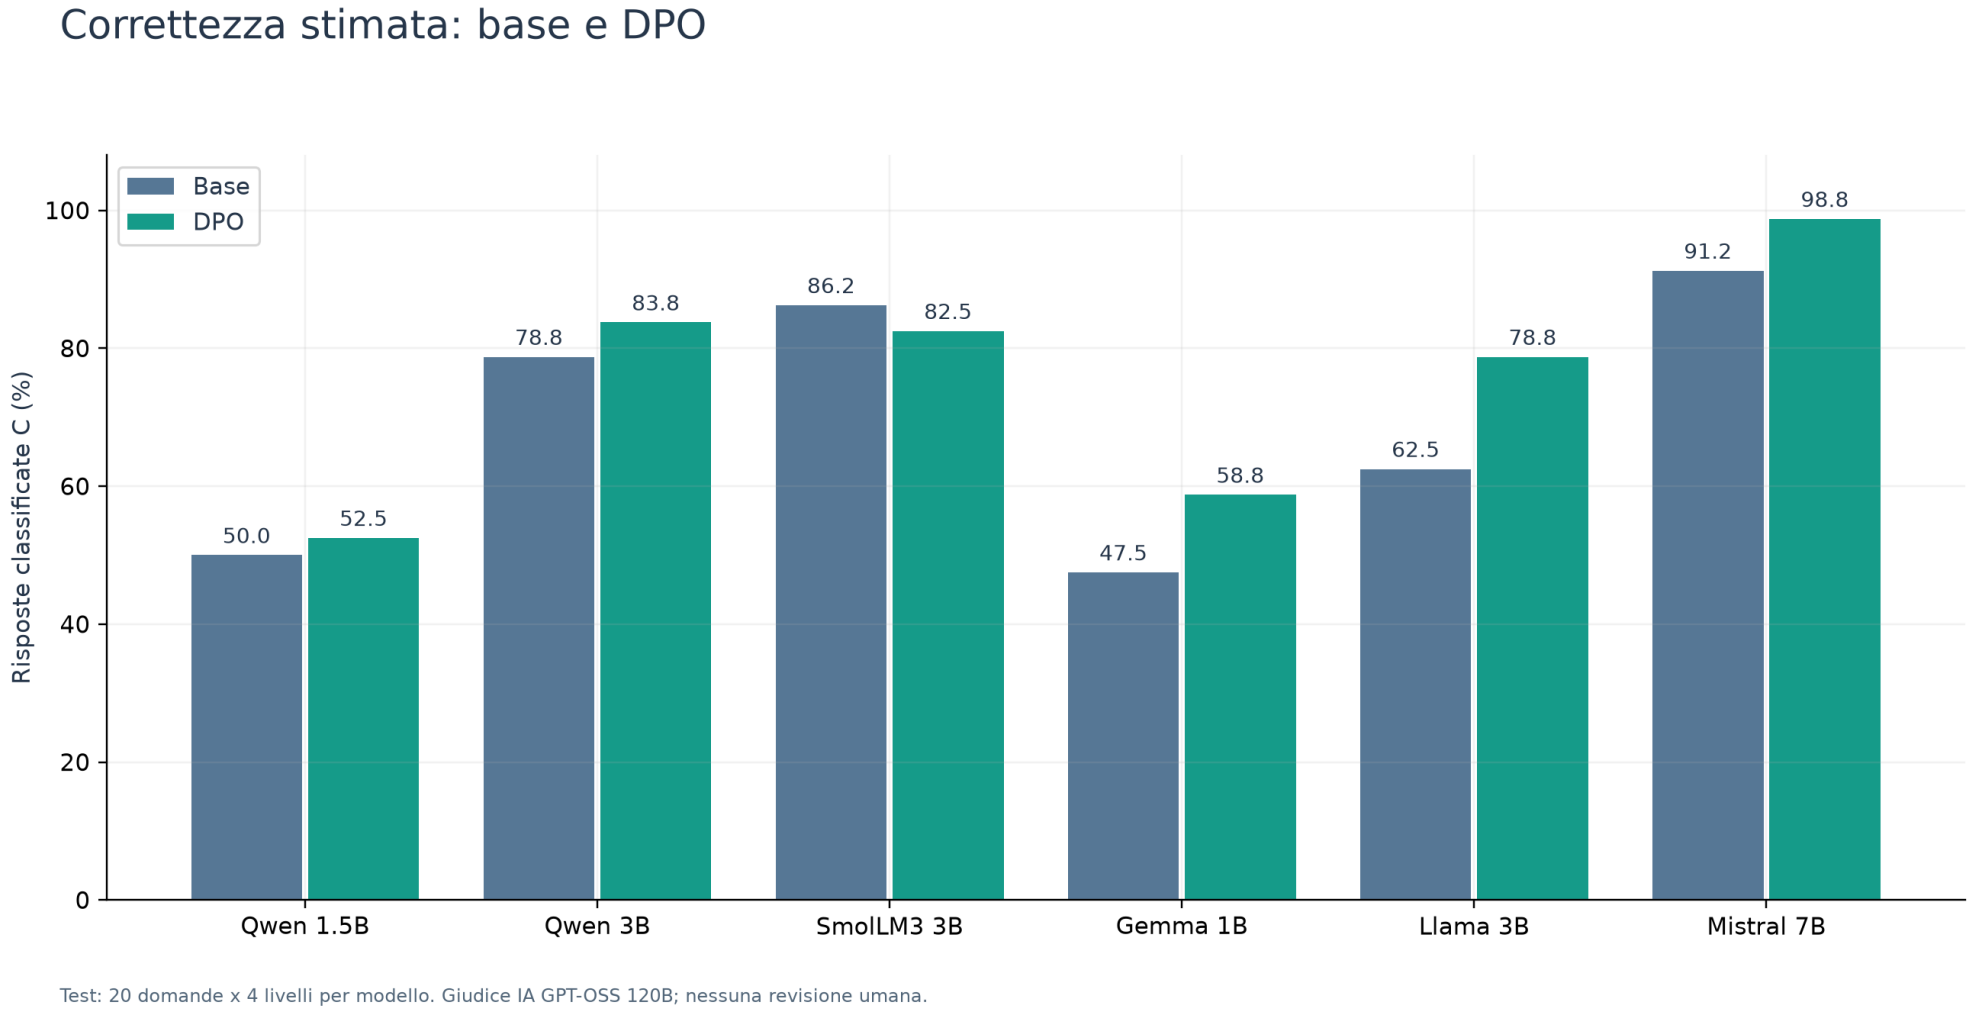
Dati grezzi e media mobile di 20 step. Reward relativi al riferimento, non giudizi esterni di correttezza.



Training: 600 coppie sintetiche, 2 epoche, seed 42. Nessuna validation.

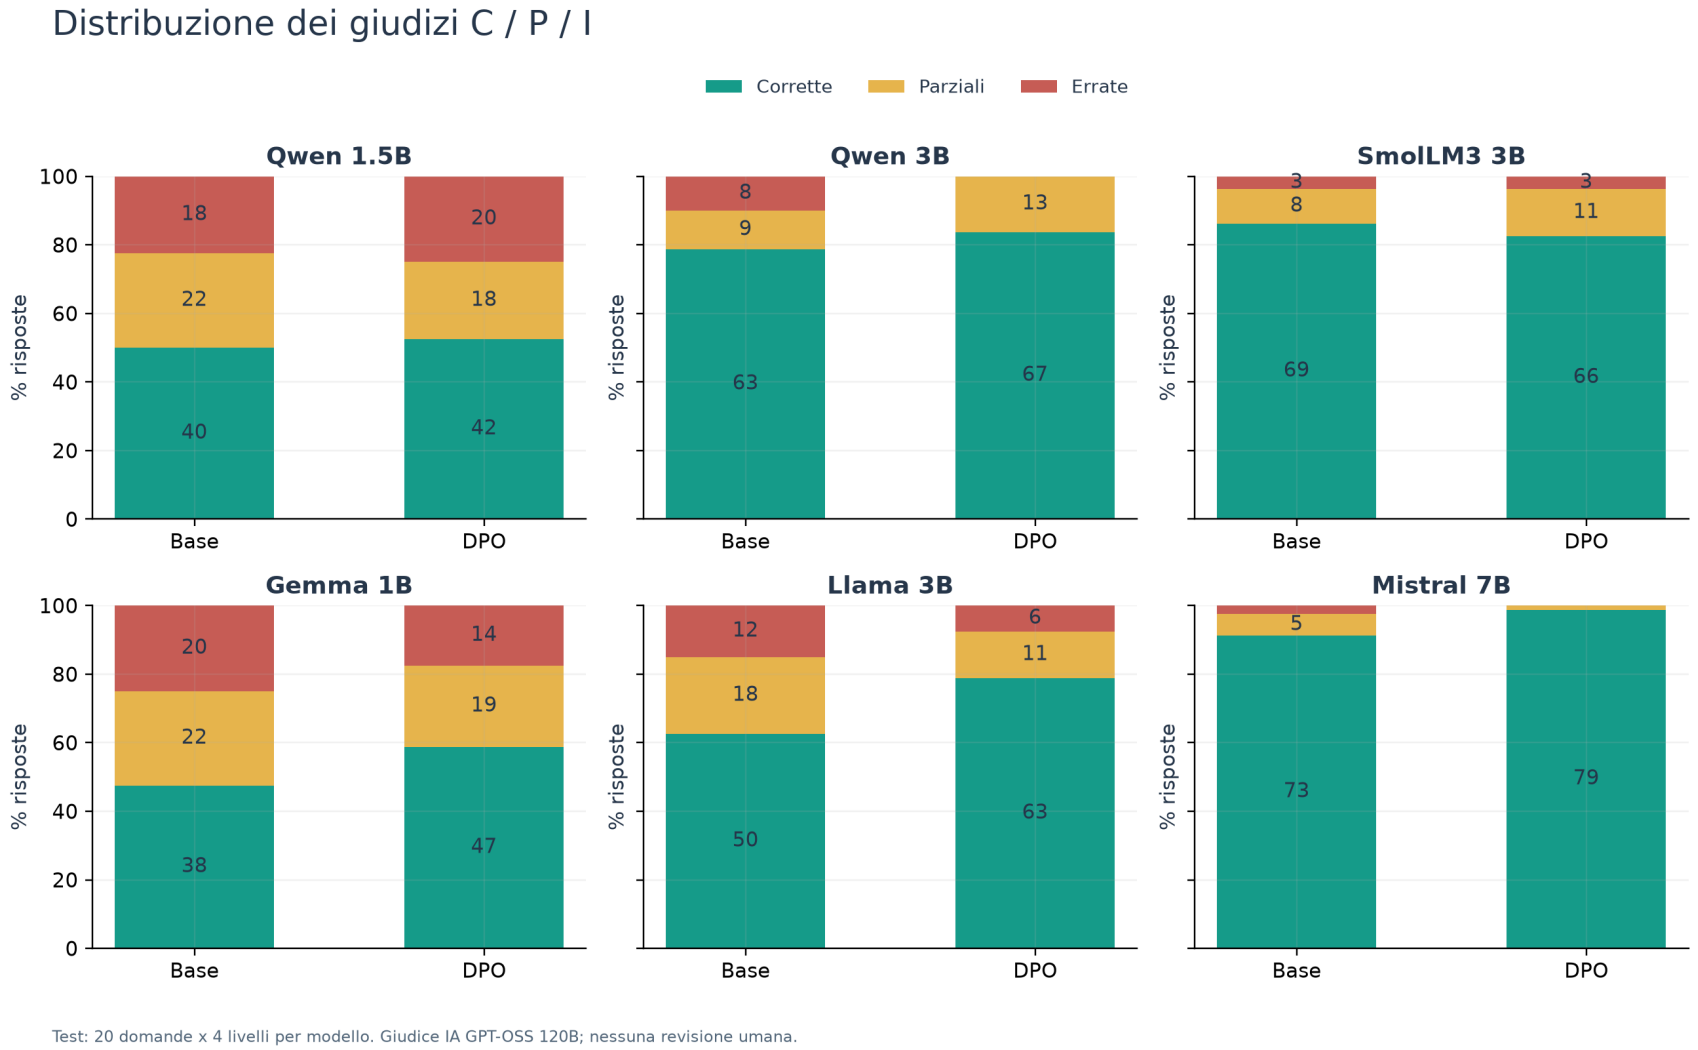
Il learning rate è uguale e costante nei sei run. Non è stata effettuata una ricerca degli iperparametri separata per ciascun modello.

FIGURA 07 | RISULTATI DEL TEST



Test: 20 domande x 4 livelli per modello. Giudice IA GPT-OSS 120B; nessuna revisione umana.

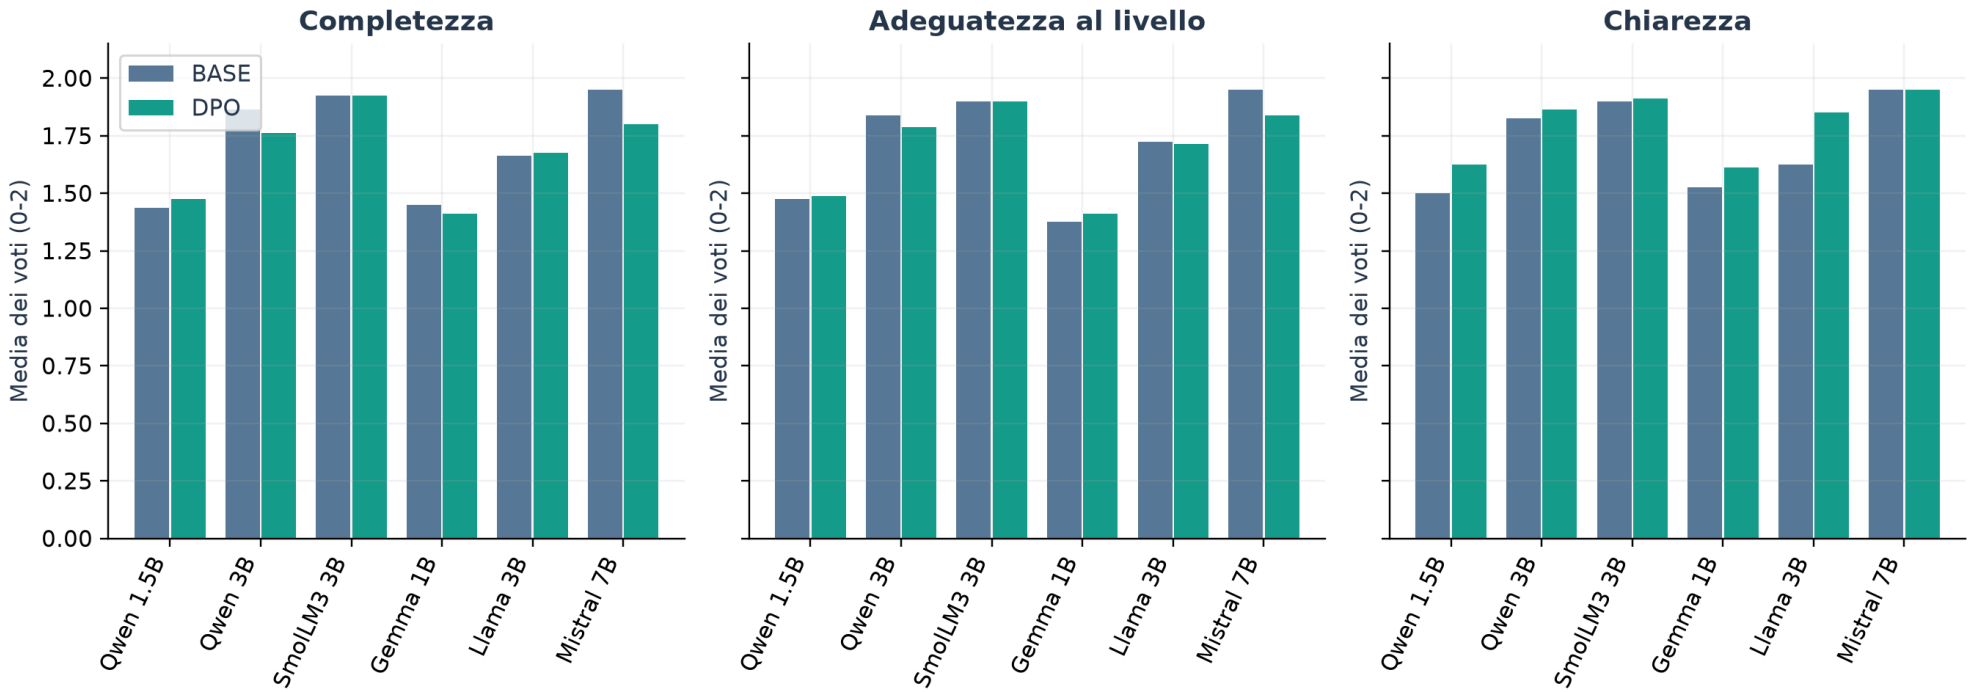
80 risposte per condizione e modello. C indica nucleo corretto e assenza di errori sostanziali secondo il giudice IA. Non sono 80 domande indipendenti.



Test: 20 domande x 4 livelli per modello. Giudice IA GPT-OSS 120B; nessuna revisione umana.

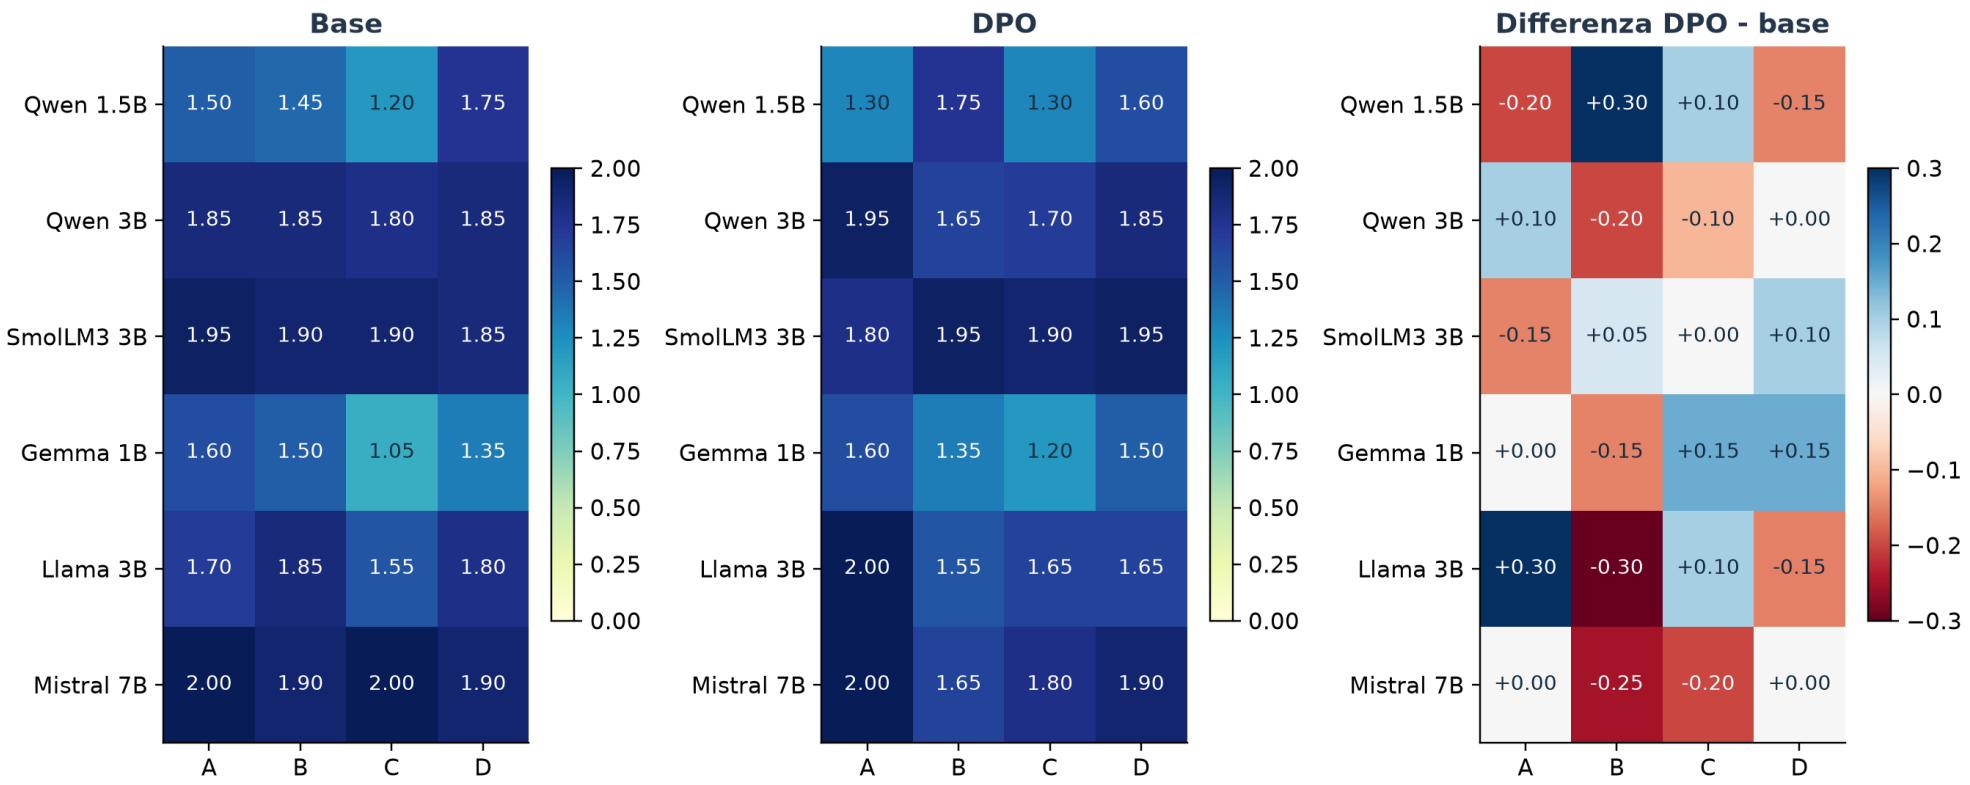
Altezza delle barre in percentuale; numeri interni = conteggi su 80. Le piccole categorie senza etichetta restano incluse.

Qualità delle risposte oltre la correttezza



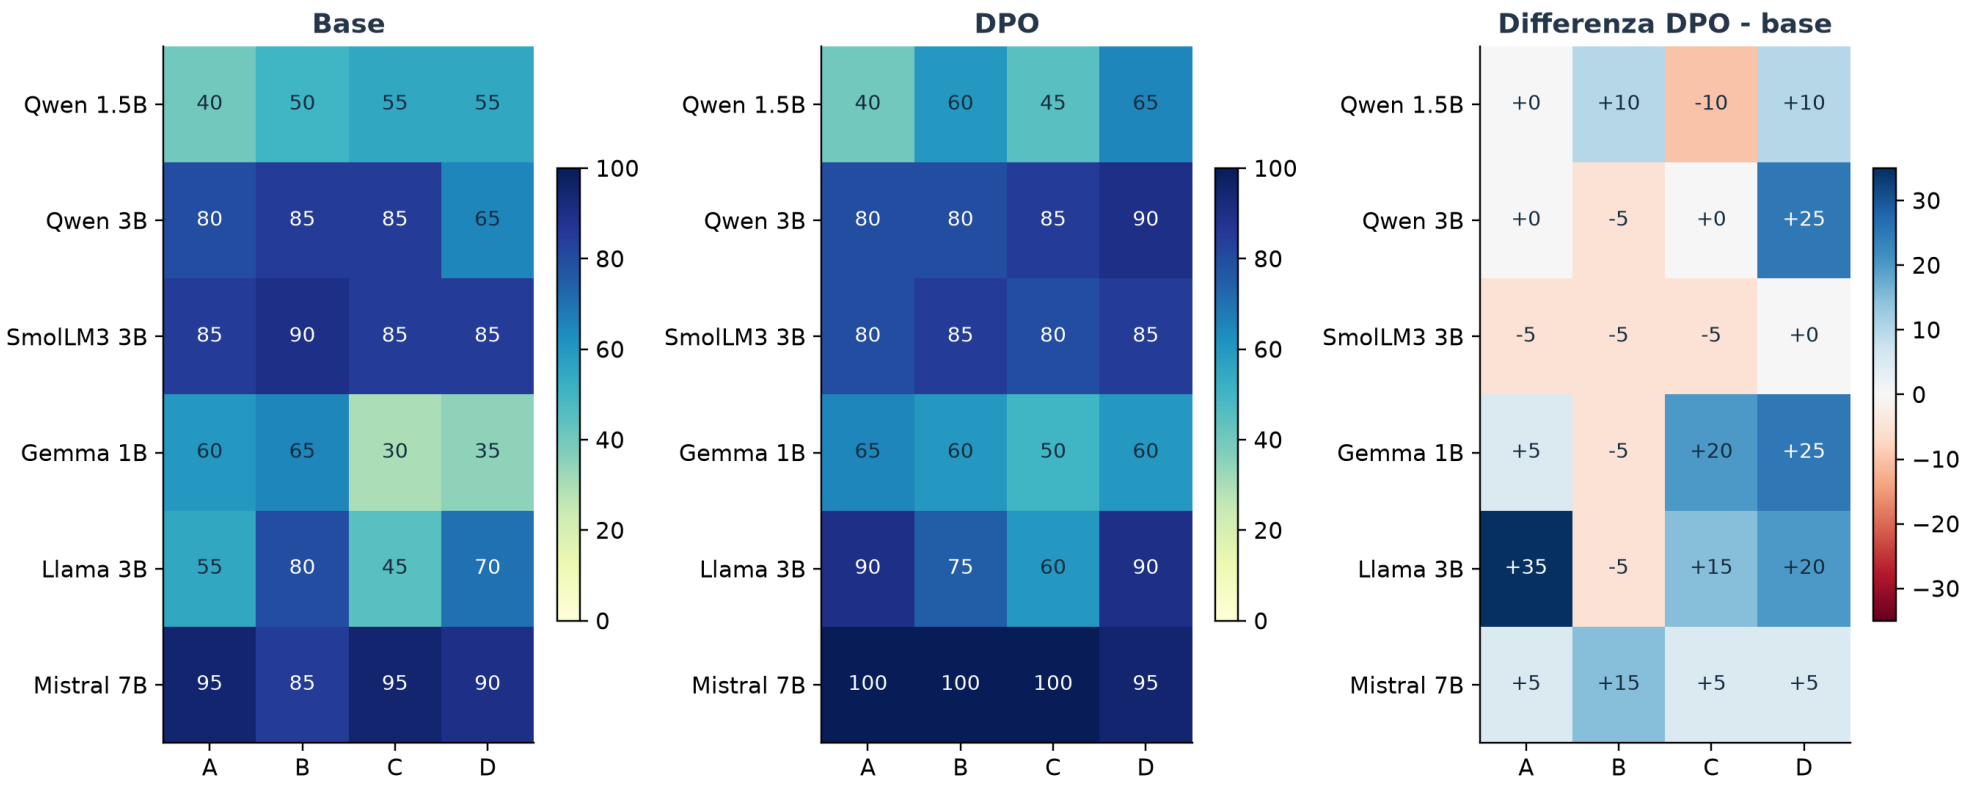
Test: 20 domande x 4 livelli per modello. Giudice IA GPT-OSS 120B; nessuna revisione umana.

Medie descrittive di voti ordinali da 0 a 2. Correttezza e adattamento didattico sono dimensioni diverse: un miglioramento della prima non implica quello della seconda.



Test: 20 domande x 4 livelli per modello. Giudice IA GPT-OSS 120B; nessuna revisione umana.

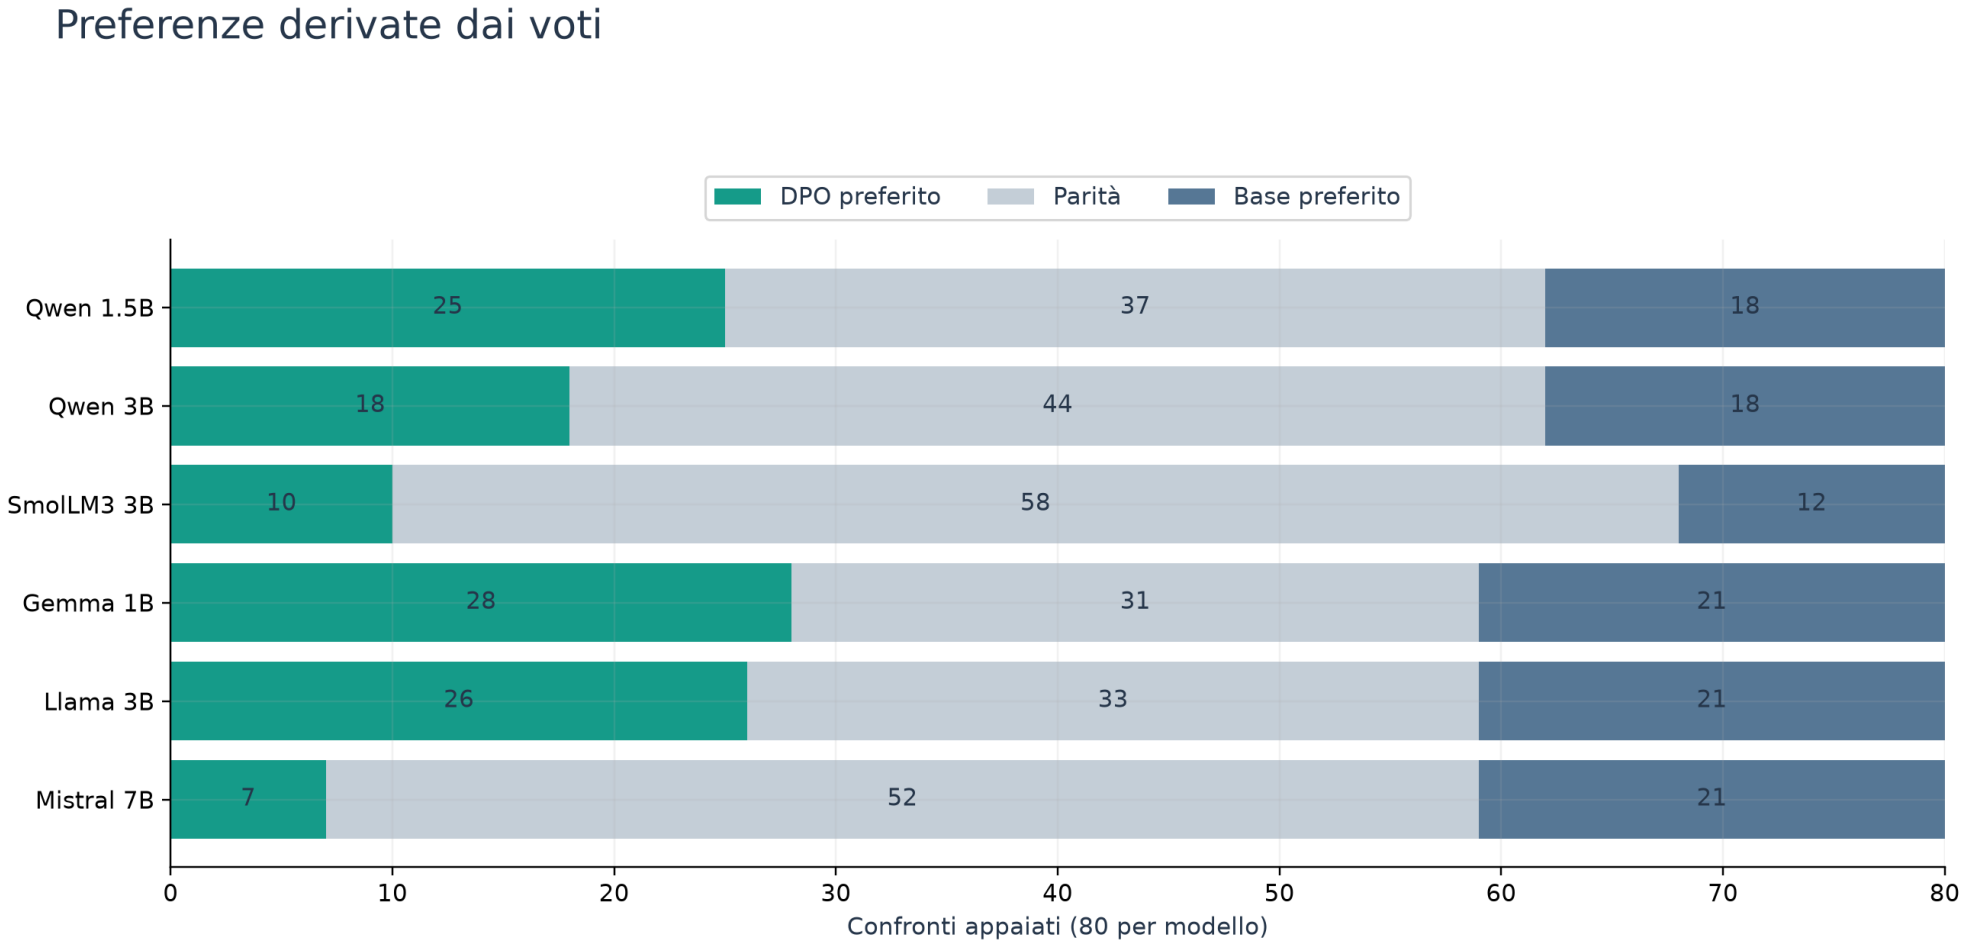
A: primaria; B: medie; C: superiori; D: università. 20 risposte per cella. A destra differenza dei voti medi (scala 0-2); non è una misura di apprendimento.



Test: 20 domande x 4 livelli per modello. Giudice IA GPT-OSS 120B; nessuna revisione umana.

Percentuale di risposte C su 20 per cella. A destra differenza in punti percentuali. Le quattro versioni della stessa domanda sono dipendenti.

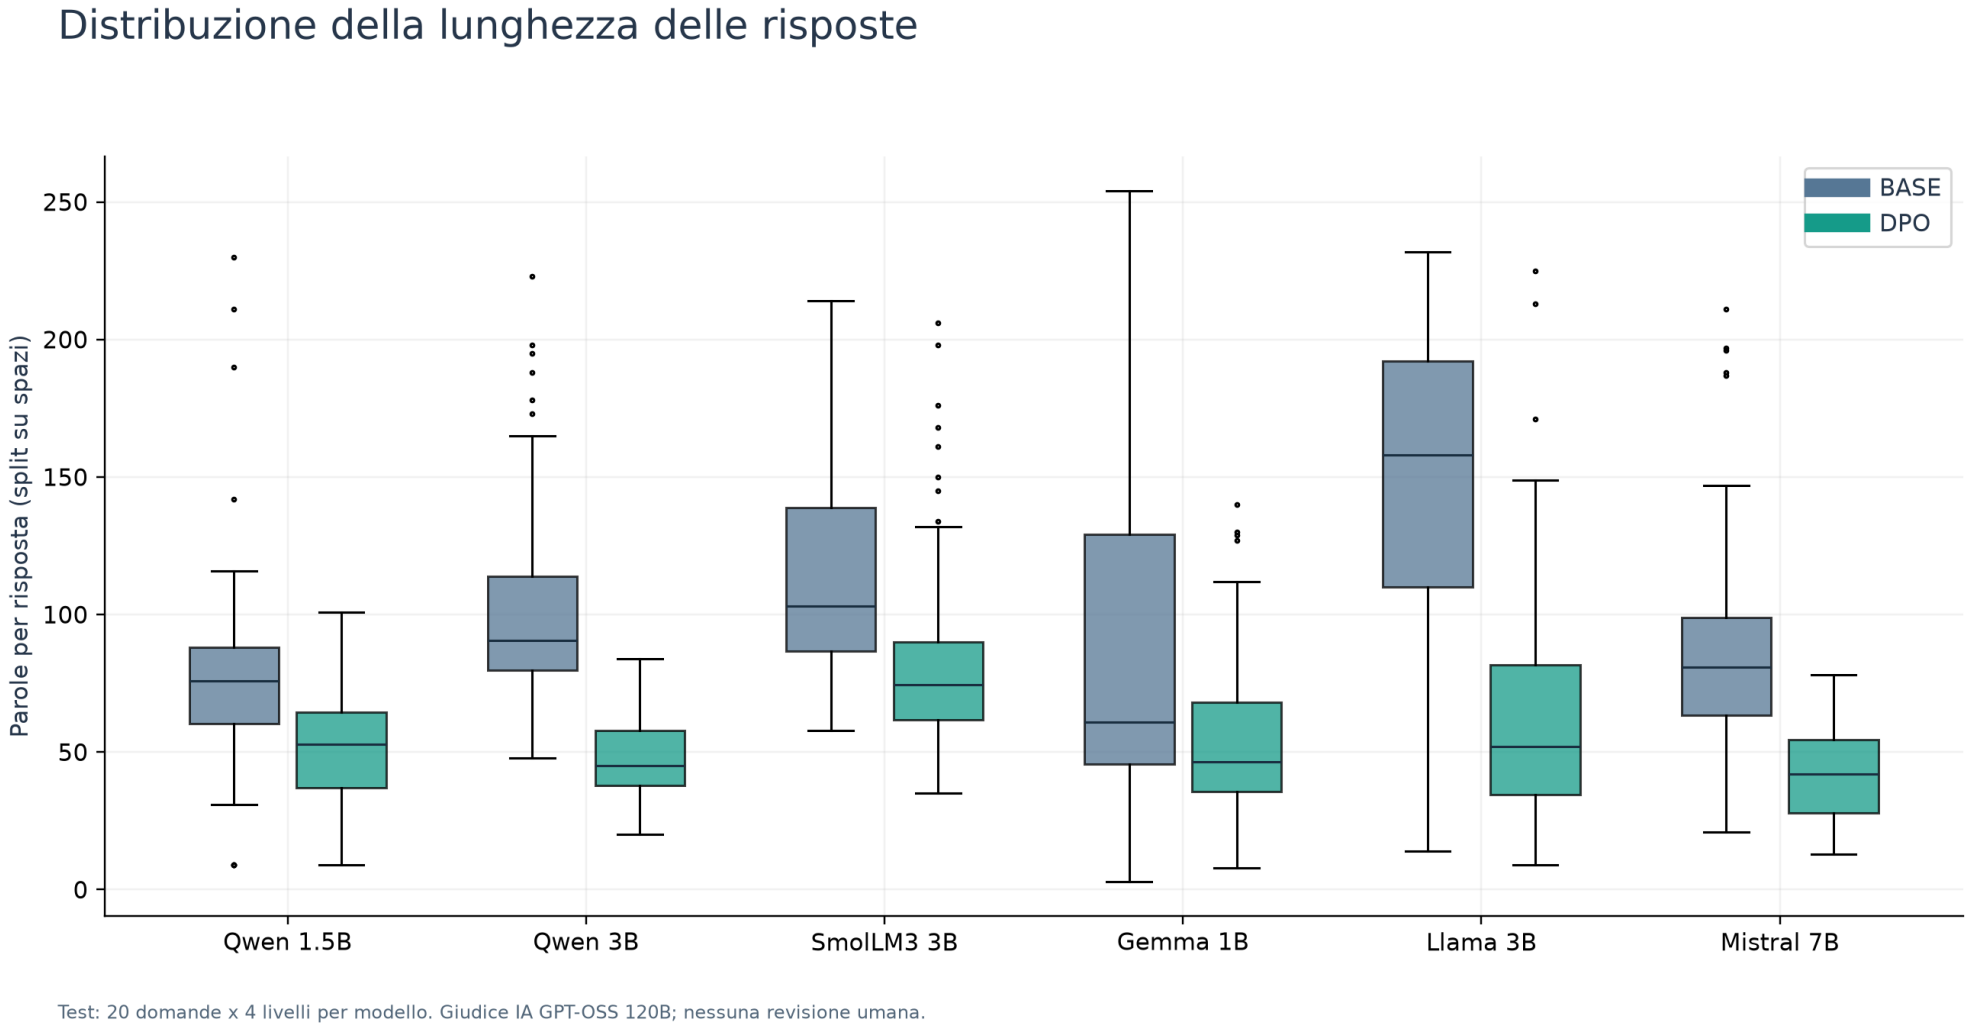
FIGURA 12 | RISULTATI DEL TEST



Test: 20 domande x 4 livelli per modello. Giudice IA GPT-OSS 120B; nessuna revisione umana.

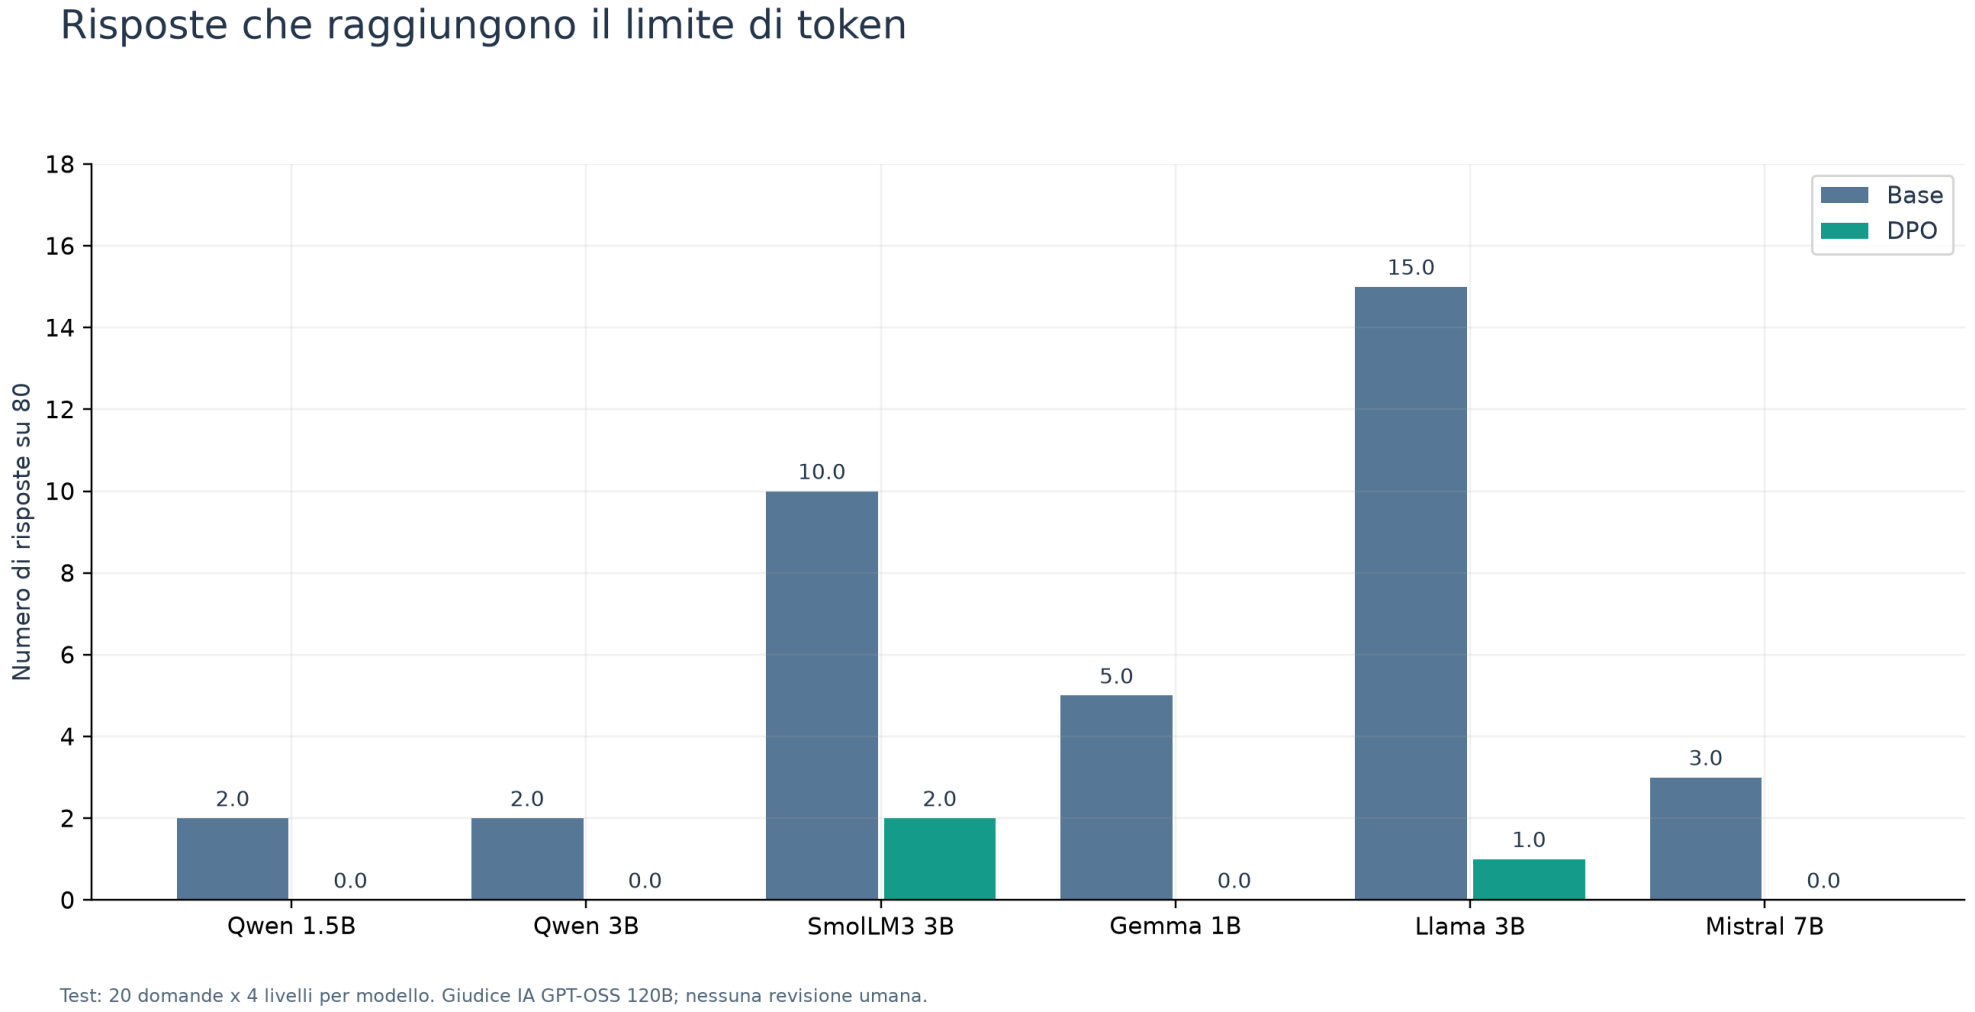
Regola lessicografica: correttezza, completezza, adeguatezza, chiarezza. Non è una seconda valutazione indipendente; sono mantenute le parità.

FIGURA 13 | RISULTATI DEL TEST



Box: quartili 25-75%; linea: mediana; baffi: 1,5 IQR; punti: valori esterni. Sono incluse le risposte al limite di token. La brevità non è di per sé un miglioramento.

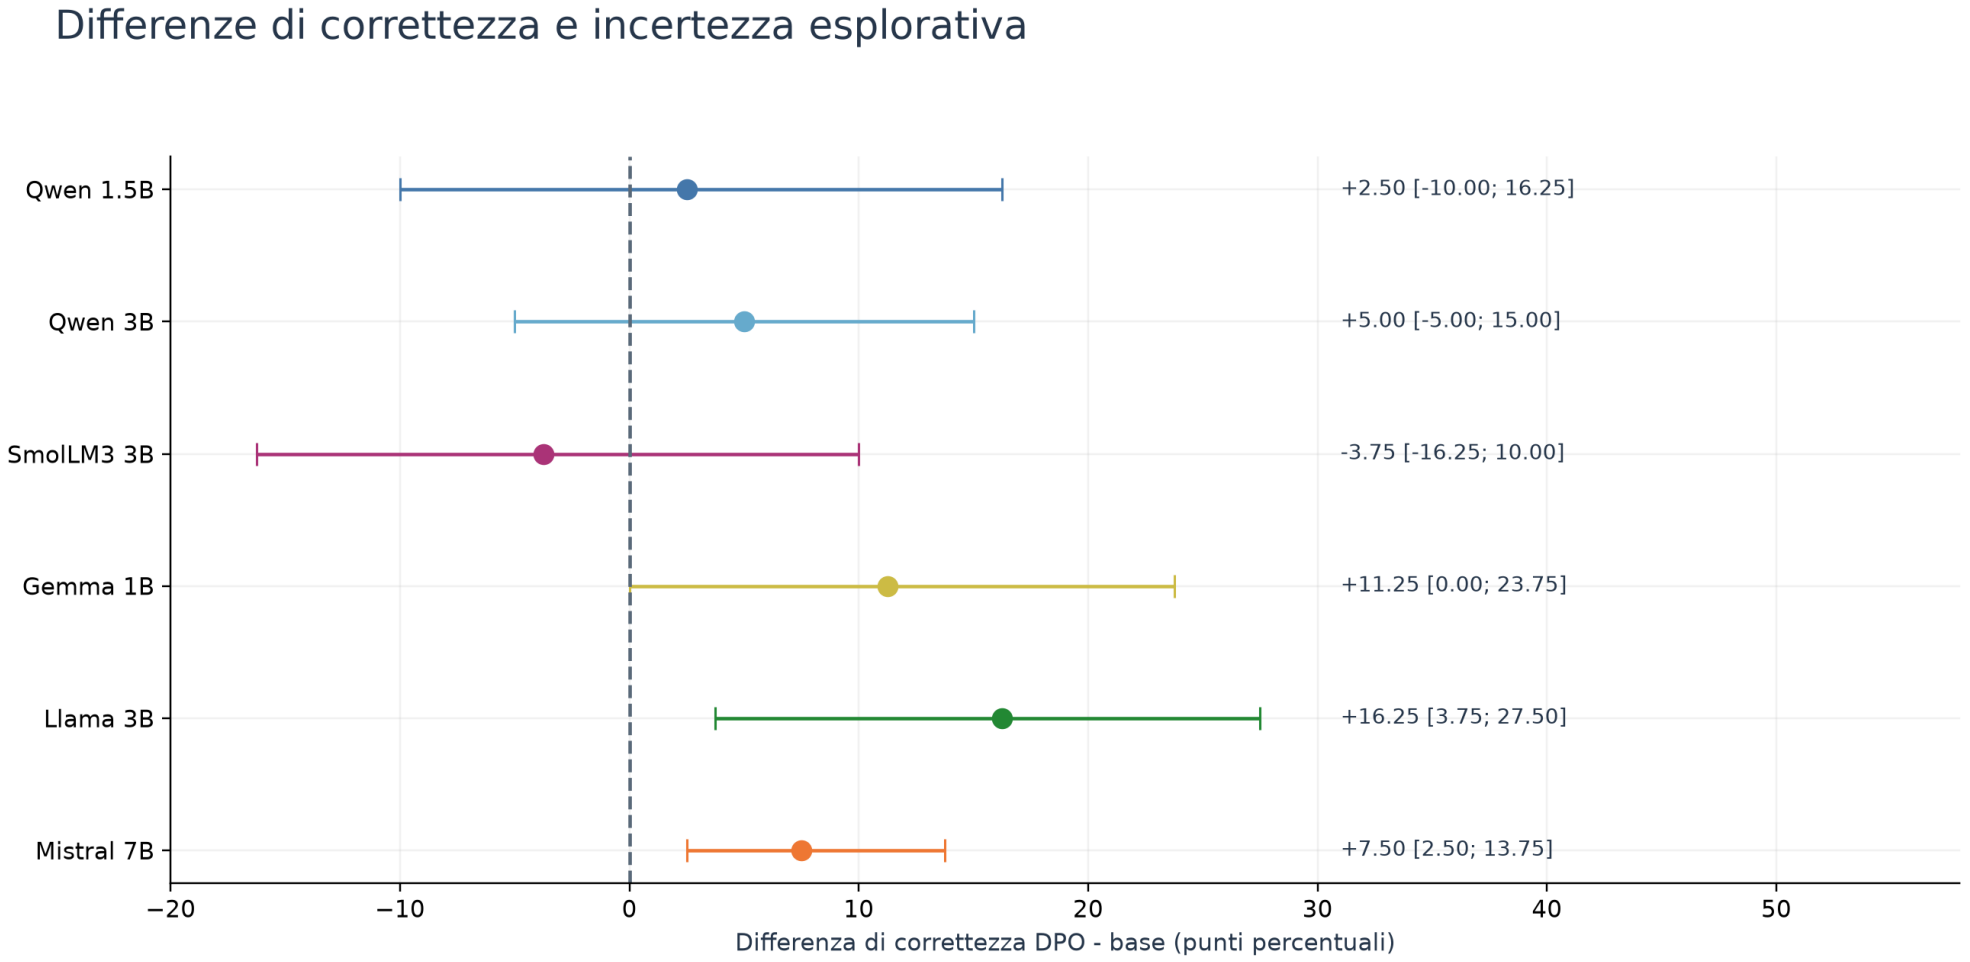
FIGURA 14 | RISULTATI DEL TEST



Test: 20 domande x 4 livelli per modello. Giudice IA GPT-OSS 120B; nessuna revisione umana.

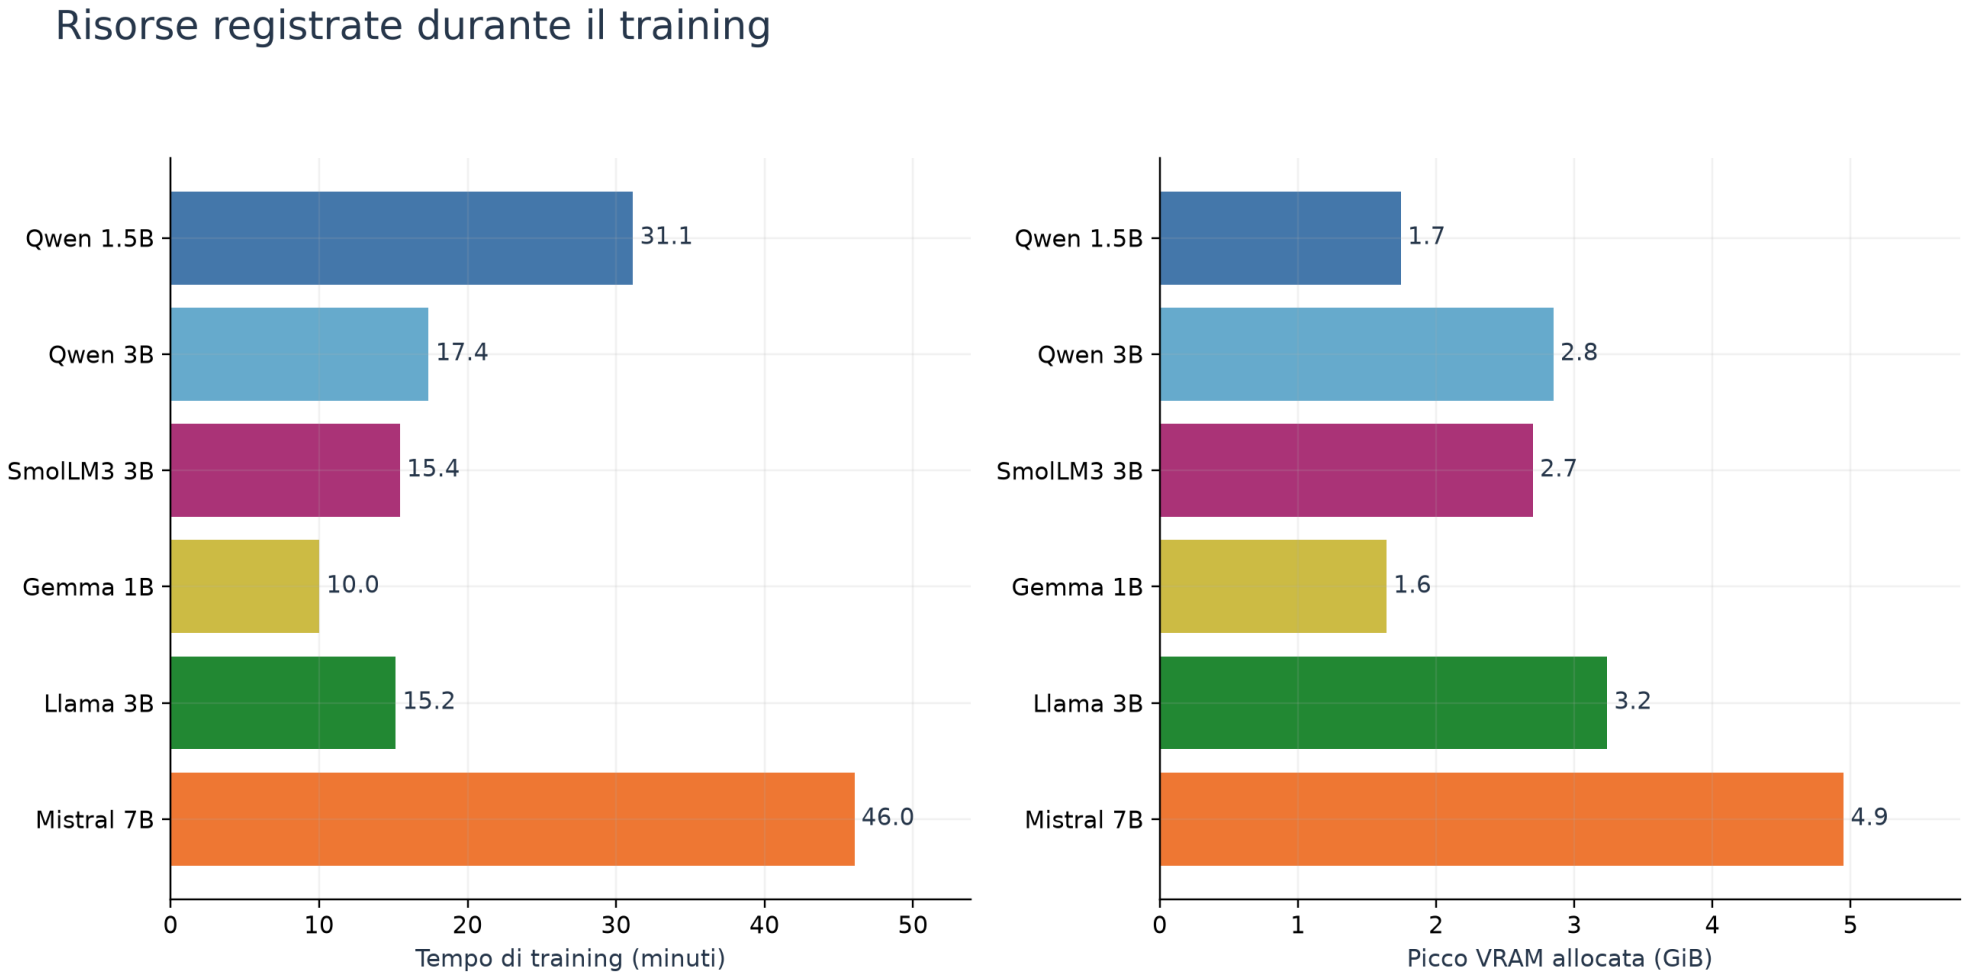
Flag limite_token_senza_EOS: possibile troncamento, non certezza di errore. Limite comune: 384 nuovi token. Tutti questi casi sono inclusi nella valutazione.

FIGURA 15 | RISULTATI DEL TEST



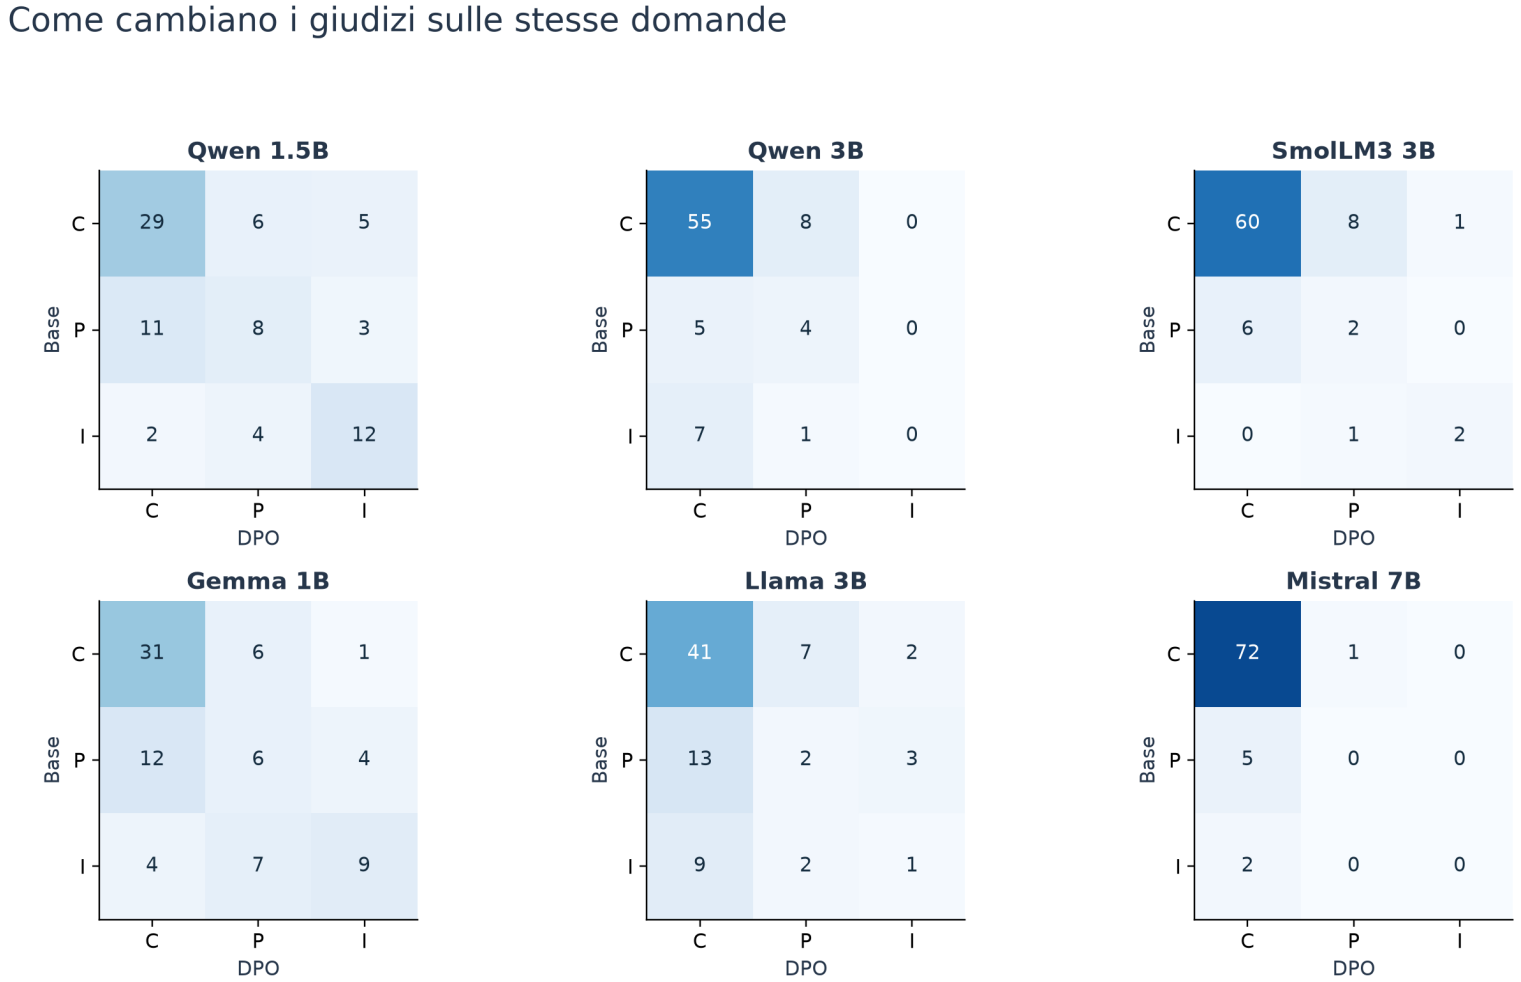
Test: 20 domande x 4 livelli per modello. Giudice IA GPT-OSS 120B; nessuna revisione umana.

Intervalli bootstrap percentili al 95%, 5.000 ricampionamenti di 10 brani. Non includono errore del giudice, variabilità tra seed o dipendenze tra brani dello stesso PDF. Nessuna correzione per confronti multipli: non etichettare come prova definitiva di significatività.



Training: 600 coppie sintetiche, 2 epoche, seed 42. Nessuna validation.

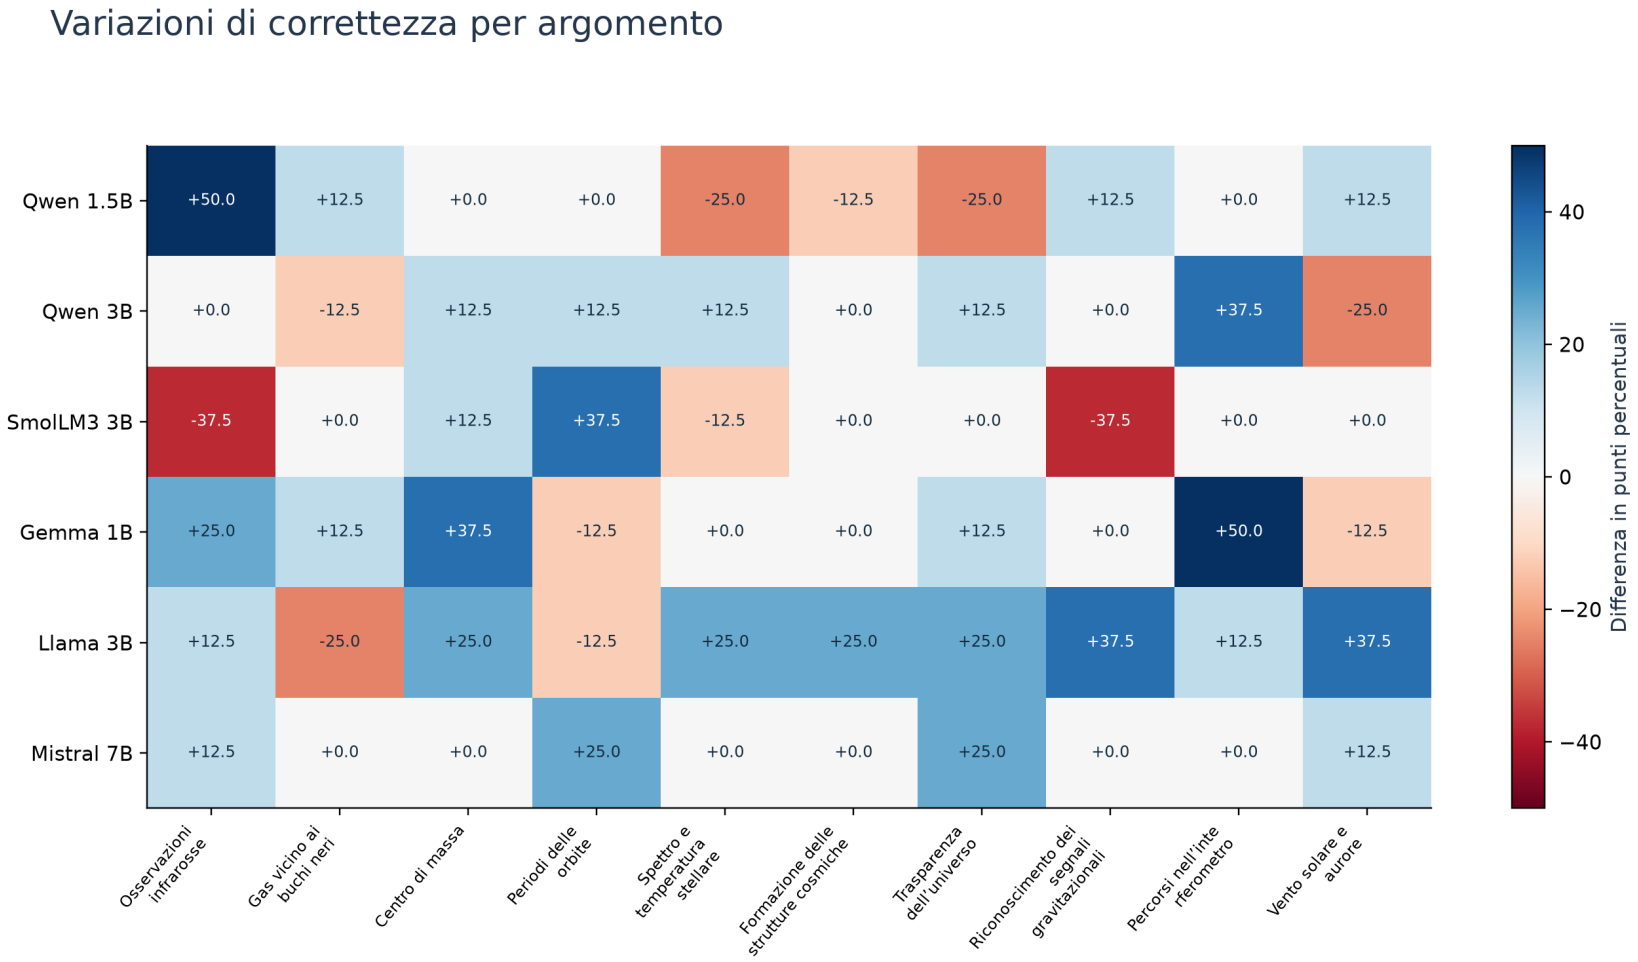
Tempi del trainer: escludono download e possono escludere preparazione/precalcolo. VRAM allocata da PyTorch, non memoria totale della GPU. Stessa RTX 4070 Laptop, ma condizioni operative non controllate: confronto descrittivo, non benchmark di velocità.



Test: 20 domande x 4 livelli per modello. Giudice IA GPT-OSS 120B; nessuna revisione umana.

Conteggi appaiati su 80 prompt per modello. Righe: base; colonne: DPO. La diagonale indica classe invariata; C/P/I indicano corretto/parziale/errato secondo il giudice.

FIGURA 18 | RISULTATI DEL TEST



Test: 20 domande x 4 livelli per modello. Giudice IA GPT-OSS 120B; nessuna revisione umana.

Solo 8 risposte per condizione e argomento: due domande a quattro livelli. Un singolo caso vale 12,5 punti percentuali. Usare per descrivere eterogeneità, non per classificare la competenza su interi argomenti.