AstroTutor: obiettivo e versione originale

Dalla consultazione dei documenti al confronto sperimentale dell’allineamento DPO.

AstroTutor nasce come tutor di astronomia capace di rispondere usando documenti di riferimento e un livello scelto dall’utente: **A primaria, B medie, C superiori, D università**. L’obiettivo è fornire spiegazioni corrette e comprensibili rispetto alle conoscenze dello studente. Nel prototipo il livello è selezionato esplicitamente: non viene stimato mediante un test iniziale.

1. La pipeline già presente nel repository

Il sistema usa il **RAG** (Retrieval-Augmented Generation): prima cerca nei documenti i passaggi pertinenti, poi li inserisce nel prompt del modello. Il flusso è: **PDF e fonti divulgative** → **estrazione** → **chunk** → **indice vettoriale** → **ricerca e riordino** → **risposta adattata**.

Modulo o classe	Funzione e tecnologie
parsing.py; ingest_api_data.py	Docling per i PDF; acquisizione di contenuti divulgativi, anche da Vikidia ed EduINAF.
chuncking.py; indexing.py	Pulizia e suddivisione del testo; embedding BAAI/bge-m3 e indice persistente ChromaDB.
AdvancedRetriever (retrieval.py)	Combina query italiana e tradotta; filtra per livello con fallback ai livelli vicini; riordina con BAAI/bge-reranker-v2-m3.
RAGGenerator (generation.py)	Costruisce il prompt con domanda, contesto e livello; genera tramite Ollama, con Qwen 2.5 3B come modello predefinito.
ResponseGuardrails; TripletFactory (alignment.py)	Controlli di registro e leggibilità con possibile rigenerazione; costruzione di esempi di preferenza tramite un modello “oracolo”.
evaluation.py; retrieval_eval.py	Valutazione storica con Gulpease, faithfulness RAGAS e rifiuti fuori dominio; analisi IR con BM25, Recall@k, MRR e nDCG.

2. Il primo uso del DPO

Il **Direct Preference Optimization** insegna al modello a preferire una risposta *chosen* a una *rejected*, date la stessa domanda e il medesimo contesto. Nel progetto originale erano già presenti training QLoRA/TRL e due versioni allineate di Qwen 3B: 378 e 623 triplette, poi esportate in GGUF e usate con Ollama. L’oracolo per i dati era configurato su Groq; questo non rendeva interamente locale la preparazione del dataset.

Il report del 26 luglio documenta risultati non replicati tra valutazione locale e Colab e problemi nella metrica dei rifiuti. La criticità iniziale era quindi anche **come misurare l’effetto del DPO**, non soltanto quanto addestrare il modello.

Cosa è cambiato e dove si trova il codice

La nuova fase ha mantenuto l’architettura RAG, aggiungendo tracciabilità, prove controllate e un confronto su più modelli. Non è stata riscritta da zero l’applicazione.

3. Modifiche effettive nel branch esperimento-calibrazione

Intervento	Perché è importante
config.py e alignment.py	La chiave dell’oracolo è richiesta quando serve a generare dati, non al semplice import dei moduli locali. Il modello è configurabile tramite ambiente.
RAGGenerator.generate_record()	Salva prompt, contesti, configurazione, risposta originale e finale, tempi e dettagli dei guardrail. È possibile fornire gli stessi documenti a confronti diversi.
Guardrail tracciati e disattivabili	Distingue la risposta del modello dalle eventuali correzioni successive. Il controllo di registro non viene confuso con una verifica scientifica.
retrieval.py	Embedding e re-ranker selezionano CUDA quando disponibile, altrimenti CPU. Non viene introdotto un nuovo algoritmo di retrieval.
scripts/run_dev.py; judge_dev.py	Aggiungono confronti controllati e giudizi riprendibili, con registrazione dei dati e materiale per revisione. Dipendenze e file ignorati sono stati aggiornati.

4. Prove preliminari e nuova campagna sperimentale

Prima della campagna finale sono state svolte prove sulle penalità di generazione, controlli del modello base e piccoli pilot DPO e **SFT**. Lo SFT addestra su esempi di risposta desiderata; il DPO su preferenze tra due risposte. Sono presenti anche pilot di continuazione SFT+DPO e SFT aggiuntivo. Queste prove hanno funzione diagnostica e **non sono i risultati sui sei modelli** riportati nelle pagine successive.

I tentativi di produrre automaticamente nuove coppie tramite modelli e filtri hanno avuto una resa bassa. Il dataset finale da 600 coppie è stato quindi costruito sinteticamente dall’assistente, a partire dai concetti dei documenti, e conservato con provenienza e controlli. Non è il semplice ampliamento del vecchio dataset da 623 triplette.

5. Una distinzione necessaria per la consegna

Il confronto Git verificato è **main 6859ea6** → **esperimento-calibrazione 9e21b5b**: 10 file tracciati differiscono. Diversi script dei pilot sono presenti localmente ma risultano ancora non tracciati. La campagna finale e i grafici sono invece nella cartella esterna **outputs/dpo_pdf_600** dell’area Codex: non vanno descritti come già committati nel branch.

File cruciali della campagna: **dataset_consegna/build.py** costruisce i dati; **train_dpo_600.py** e le varianti di famiglia eseguono il training; **compare_test_*600.py** generano base/DPO; **evaluate_final_local.py**, nonostante il nome, gestisce anche il giudice Groq; **make_relation_charts.py** produce i grafici dai file salvati.

Il nuovo esperimento e l’andamento del training

6. Dati e condizioni del confronto

Il training comprende **75 domande × 4 livelli × 2 risposte rifiutate = 600 coppie**. I 300 prompt hanno una risposta preferita e due tipi di negativo: errori fattuali o contenuti fuori tema. Questo insegna soprattutto correttezza e pertinenza; non isola la capacità di adattare la spiegazione al livello scolastico.

Sono stati addestrati **Qwen 2.5 1.5B e 3B, SmolLM3 3B, Gemma 3 1B, Llama 3.2 3B e Mistral 7B v0.3**. Lo stack usa PyTorch/CUDA, Transformers, Datasets, Accelerate, TRL, PEFT e bitsandbytes. Sulla RTX 4070 Laptop da 8 GB, QLoRA carica i pesi in NF4 e addestra piccoli adapter LoRA, riducendo il fabbisogno di memoria.

Configurazione comune: 2 epoche, 300 step, learning rate 5×10^{-6}, beta 0,1, LoRA rank 8/alpha 16, batch effettivo 4, seed 42. Sono stati rispettati i template dei modelli; per Gemma e Mistral l’istruzione di sistema è unita al primo messaggio utente. Non è una ricerca degli iperparametri ottimali per ciascuna famiglia.

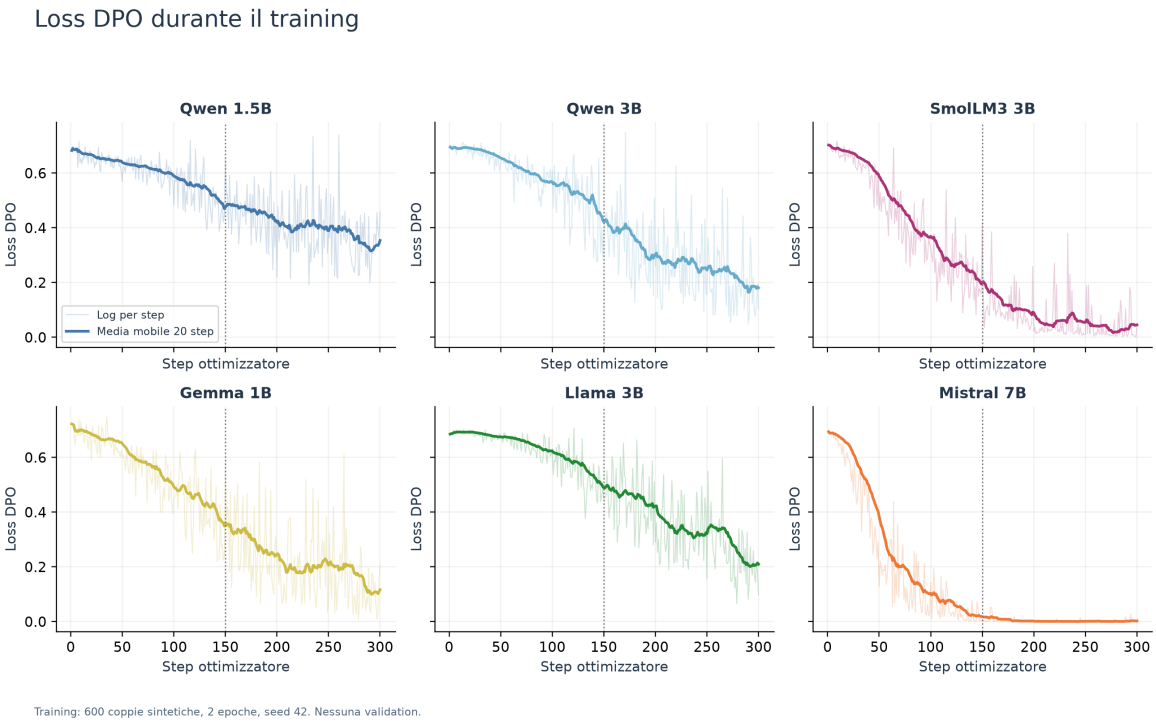


Figura 1. Loss DPO nei sei training. La linea tenue mostra il log per step; quella piena una media mobile di 20 step. La linea verticale indica la fine della prima epoca.

La loss diminuisce nei sei run: il modello sta imparando le preferenze del dataset. Il calo più rapido o il valore finale più basso **non provano che un modello sia un tutor migliore**. Non sono disponibili curve di validation; per valutare l’effetto sulle risposte si usa il test separato.

7. Test congelato e giudice

Il test usa 20 domande nuove, 10 brani e 4 livelli: **80 prompt per modello**, generati sia con il modello base sia con l’adapter DPO. I documenti del test sono separati da quelli del training. Entrambe le condizioni usano gli stessi contesti riformulati in italiano, decoding greedy, NF4 e massimo 384 nuovi token, senza guardrail. Il test isola la generazione con contesto fornito: non rivaluta il retrieval RAG.

Le 960 risposte sono state valutate da **GPT-OSS 120B su Groq**, senza indicare al giudice il modello o la condizione. Otto duplicati identici per lo stesso prompt condividono il giudizio: 952 valutazioni uniche. Il primo giudice locale Qwen 7B è stato scartato dopo controlli qualitativi. I risultati finali restano giudizi IA, non una revisione umana.

Risultati: la correttezza migliora, ma non sempre

La rubrica distingue risposte **C** (corrette), **P** (parziali o con imprecisioni rilevanti) e **I** (errate nel nucleo o con errori gravi). Completezza, adeguatezza al livello e chiarezza sono valutate separatamente da 0 a 2.

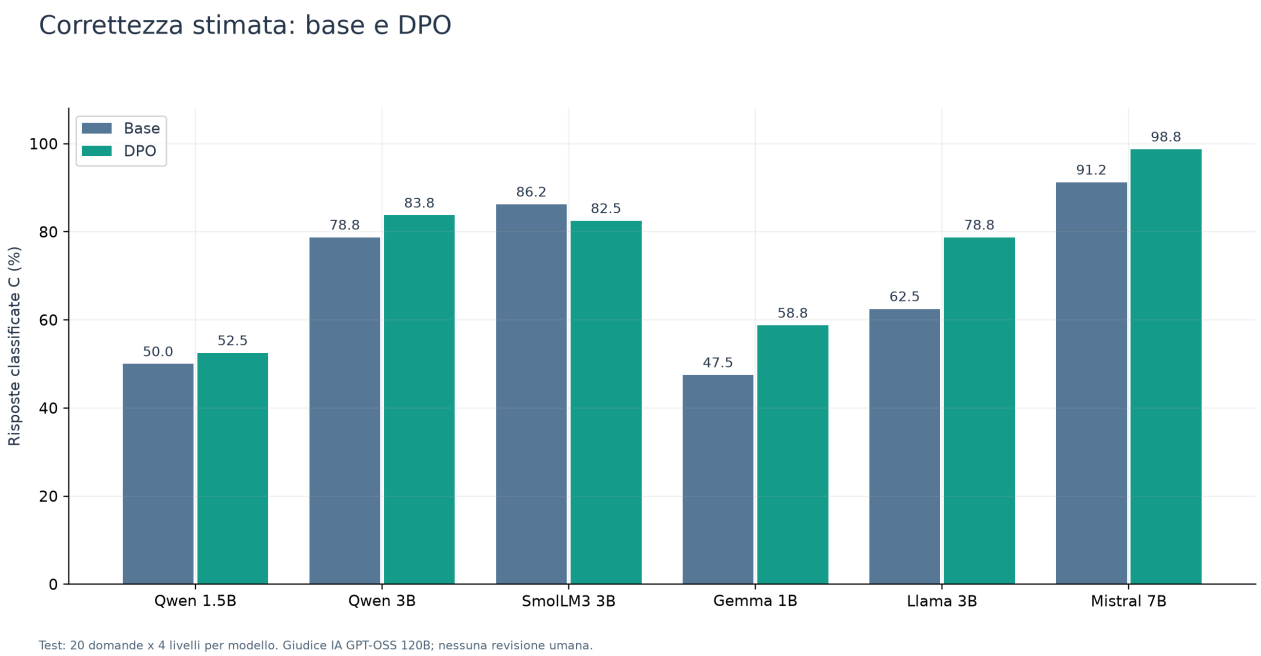


Figura 2. Percentuale di risposte classificate C dal giudice IA, su 80 per condizione. Le quattro versioni di una domanda non sono osservazioni indipendenti.

Modello	C base → DPO	Variazione	Adeguatezza base → DPO
Qwen 2.5 1.5B	40 → 42 /80	+2.50 p.p.	1.48 → 1.49
Qwen 2.5 3B	63 → 67 /80	+5.00 p.p.	1.84 → 1.79
SmolLM3 3B	69 → 66 /80	-3.75 p.p.	1.90 → 1.90
Gemma 3 1B	38 → 47 /80	+11.25 p.p.	1.38 → 1.41
Llama 3.2 3B	50 → 63 /80	+16.25 p.p.	1.73 → 1.71
Mistral 7B v0.3	73 → 79 /80	+7.50 p.p.	1.95 → 1.84

La correttezza stimata cresce in **cinque modelli su sei**; SmolLM3 registra una diminuzione. Llama mostra il maggiore aumento assoluto (+13 risposte C); Mistral passa da 73 a 79 su 80. Sommando descrittivamente le condizioni dei sei modelli, le risposte C passano da 333 a 364 su 480. Questa somma non è un campione di 480 domande indipendenti.

La sola percentuale di C non descrive tutte le regressioni. Per esempio, in Qwen 1.5B aumentano sia le risposte corrette (40→42) sia quelle errate I (18→20), a scapito delle parziali. In Qwen 3B gli errori I scendono da 8 a 0, mentre diminuisce la completezza media. Il risultato dipende quindi dalla dimensione di qualità osservata.

Incertezza: gli intervalli bootstrap del fascicolo completo raggruppano per 10 brani. Non coprono l'errore del giudice o la variabilità tra seed; non è stata applicata una correzione per confronti multipli. Le differenze sono da presentare come risultati esplorativi, non come prova generale dell'efficacia del DPO.

Adattamento didattico e conclusione

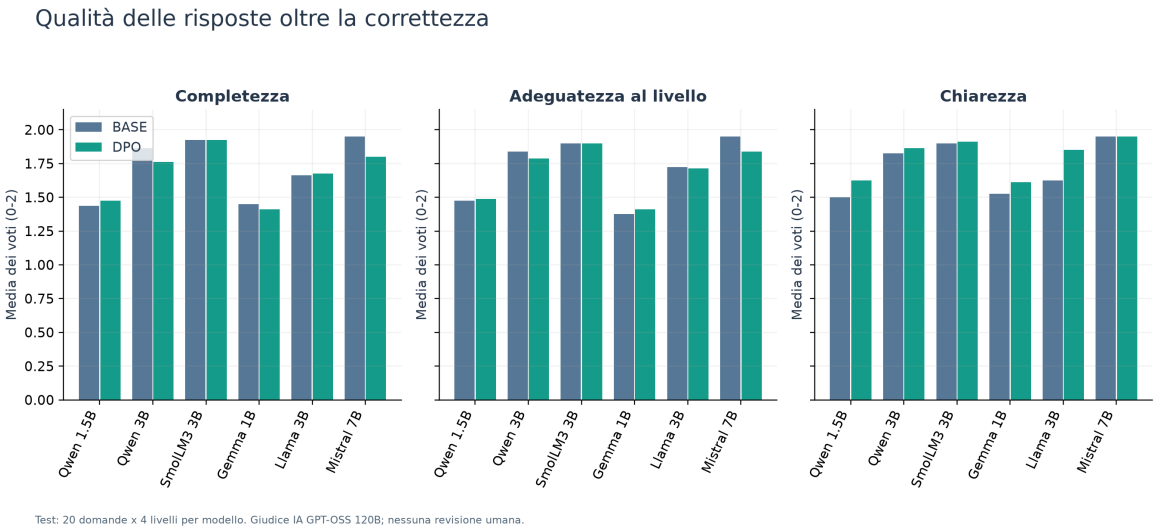


Figura 3. Medie dei voti IA (0-2). Correttezza, completezza e adeguatezza sono dimensioni distinte: il DPO non migliora uniformemente tutte le qualità di un tutor.

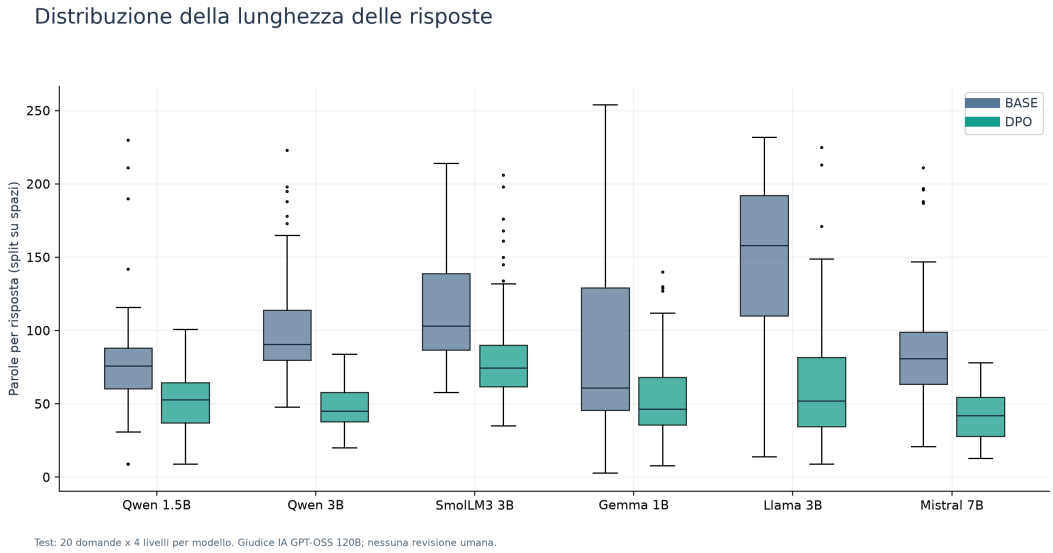


Figura 4. Lunghezza delle risposte: mediana, quartili e distribuzione. La riduzione è comune ai sei modelli; maggiore brevità non equivale automaticamente a maggiore utilità didattica.

Il caso Mistral rende evidente il compromesso: la correttezza cresce, ma la completezza media passa da **1,95 a 1,80**, l'adeguatezza da **1,95 a 1,84** e le parole medie da circa **86 a 44**. Anche negli altri modelli il DPO tende ad accorciare le risposte. I casi al limite di token sono stati conservati, non esclusi dal confronto.

Conclusione. Il progetto passa da un prototipo RAG con primi tentativi di allineamento a un confronto più tracciabile e ripetibile su sei modelli. I risultati non permettono di affermare che "il DPO è inutile": mostrano benefici sulla correttezza, ma non un adattamento didattico uniforme. Per l'obiettivo originale del tutor, resta da verificare se questi benefici siano percepiti anche dagli studenti.

Limiti e passo finale: dati sintetici scritti dall'assistente, un solo giudice IA, un seed, test piccolo e nessuno studio sull'apprendimento. Il campione cieco di 24 coppie è pronto ma non ancora revisionato da una persona. I pilot SFT esistono, ma non costituiscono un confronto SFT sistematico sui sei modelli.

Fonti interne verificate: repository locale e diff main/esperimento-calibrazione; report storico del 26/07/2026; manifest del dataset e del test; log dei sei training; final_groq_v1/summary.json e scored_responses.json. I grafici sono riprodotti dai dati salvati, senza nuove generazioni.