Indice

1 Obiettivo del progetto e impostazione generale **2**

2 Costruzione della pipeline RAG **2**
2.1 Acquisizione, parsing e composizione del corpus . . . 2
2.2 Pulizia, chunking e indicizzazione . . . 3
2.3 Recupero, reranking e gestione dei livelli . . . 4
2.4 Generazione della risposta . . . 5
2.5 Valutazione del retrieval . . . 5

3 Generazione del dataset e controlli di qualità **6**
3.1 Dalla raccolta iniziale al dataset finale . . . 6
3.2 Costruzione delle domande e delle coppie . . . 6
3.3 Controlli strutturali e provenienza . . . 7
3.4 Separazione fra training, sviluppo e test . . . 7

4 Addestramento DPO dei diversi modelli **8**
4.1 Obiettivo di apprendimento . . . 8
4.2 Modelli e configurazione comune . . . 8
4.3 Compatibilità, tempi e memoria . . . 8
4.4 Andamento dell'ottimizzazione . . . 9

5 Test comparativo e risultati **9**
5.1 Disegno del confronto Base/DPO . . . 9
5.2 Rubrica e giudice automatico . . . 10
5.3 Correttezza delle risposte . . . 10
5.4 Adeguatezza, completezza e lunghezza . . . 11
5.5 Analisi di due casi rappresentativi . . . 12
5.6 Incertezza delle stime . . . 13

6 Discussione e conclusioni **13**
6.1 Risultati rispetto agli obiettivi . . . 13
6.2 Integrazione nella demo . . . 14
6.3 Limiti e sviluppi futuri . . . 14

A Diagnostica supplementare **15**
A.1 Metriche di addestramento . . . 15
A.2 Analisi supplementari delle risposte . . . 18

B Riproducibilità e provenienza **23**
B.1 Ambiente e artefatti . . . 23
B.2 Fonti documentali e perimetro delle verifiche . . . 23

Riferimenti bibliografici **24**

AstroTutor — Relazione tecnica completa

Periodo documentale: 01/10/2025–11/11/2026

Sintesi

AstroTutor è un prototipo di assistente didattico che risponde a domande di astronomia utilizzando una raccolta documentale e un livello scolastico indicato dall'utente. Il progetto combina Retrieval-Augmented Generation (RAG), per fornire al modello informazioni pertinenti, e Direct Preference Optimization (DPO), per modificarne il comportamento attraverso coppie di risposte preferite e rifiutate.

Il lavoro comprende la preparazione del corpus, la valutazione del recupero documentale, la costruzione di 600 coppie sintetiche e l'addestramento di sei modelli. Il confronto finale usa 20 domande ripetute a quattro livelli, producendo 960 risposte Base/DPO su contesti predefiniti. Secondo il giudice automatico, il DPO aumenta le risposte corrette in cinque modelli su sei e ne riduce generalmente la lunghezza; completezza e adeguatezza didattica non migliorano in modo uniforme. I risultati descrivono quindi un beneficio dipendente dal modello e dalla dimensione di qualità osservata.

1 Obiettivo del progetto e impostazione generale

Una risposta scientificamente corretta può essere troppo tecnica per un bambino o troppo generica per uno studente universitario. AstroTutor affronta questo problema condizionando la generazione sia sui documenti disponibili sia sul profilo del destinatario. I livelli sono A, scuola primaria; B, scuola media; C, scuola superiore; D, università. Si tratta di profili selezionati dall'utente, non di competenze inferite automaticamente dal dialogo.

Il RAG collega il recupero di informazioni alla generazione: i brani pertinenti vengono inseriti nel prompt insieme alla domanda e alle istruzioni sul livello [1]. Il DPO interviene invece sui parametri addestrabili del modello, apprendendo a preferire una risposta rispetto a un'altra sullo stesso input [2]. Le due componenti rispondono a esigenze complementari: disponibilità dell'informazione e comportamento del generatore.

Il confronto sperimentale verifica se il DPO migliori la correttezza rispetto al modello iniziale, se il beneficio riguardi anche completezza e adattamento didattico e se si ripeta su modelli di famiglie e dimensioni diverse. Un ulteriore vincolo progettuale è la possibilità di addestrare e utilizzare il prototipo su hardware locale con memoria limitata.

La pipeline separa preparazione documentale, apprendimento e inferenza. L'indicizzazione rende interrogabile il corpus; il training produce gli adattatori; durante l'uso, il recupero seleziona i passaggi da fornire al generatore. La valutazione del retrieval e il confronto Base/DPO sono esperimenti distinti, descritti nelle sezioni dedicate.

2 Costruzione della pipeline RAG

Le fasi implementate in `src/` trasformano le fonti in un indice interrogabile e, successivamente, una domanda in una risposta contestualizzata. Il percorso comprende acquisizione, parsing, chunking, indicizzazione, retrieval e generazione. La mappa dei moduli è riportata nell'appendice di riproducibilità.

2.1 Acquisizione, parsing e composizione del corpus

La raccolta comprende PDF di astronomia e materiali divulgativi acquisiti da Vikidia ed EduINAF. Docling converte i PDF in testo strutturato, con OCR per le pagine rasterizzate e

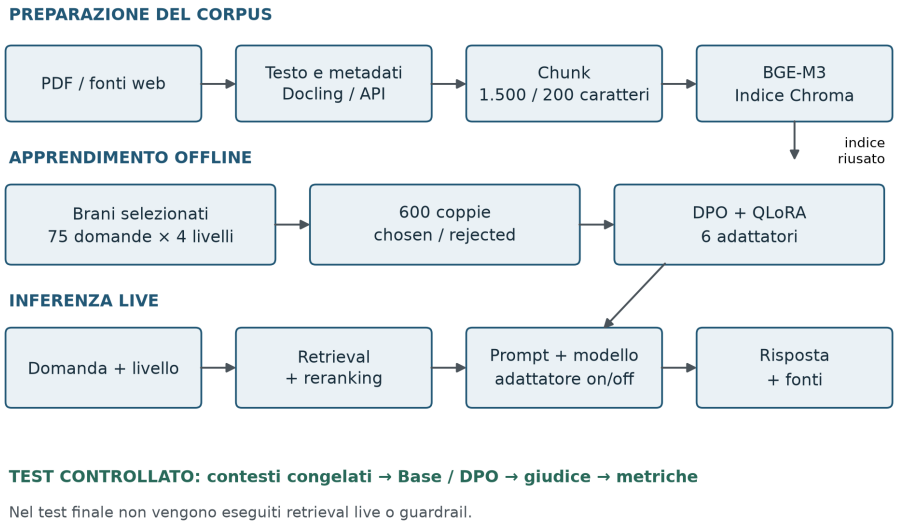


Figura 1: Architettura complessiva: preparazione documentale, apprendimento delle preferenze e inferenza live. Il test finale bypassa il retrieval e usa contesti congelati.

arricchimento delle formule; i contenuti web già testuali entrano direttamente nella preparazione del testo. I documenti conservano titolo, fonte, argomento e livello, necessari per risalire all'origine dei passaggi e condizionare la ricerca.

Il livello dei PDF deriva dal prefisso del nome, mentre l'argomento deriva dalla cartella. Quando un documento ha più livelli, il chunking conserva soltanto il primo: questa semplificazione incide sul successivo filtro di ricerca. La conversione non garantisce la correttezza di ogni formula o simbolo; gli errori di estrazione possono propagarsi al recupero e alla risposta.

Il corpus esaminato comprende 82 file di chunk, 17.976 righe e 16.874 testi distinti. La differenza di 1.102 righe rappresenta ripetizioni testuali, non altrettanti documenti duplicati. Il numero dei file di chunk non coincide con quello dei PDF, perché sono presenti anche fonti web.

Tabella 1: Distribuzione delle righe di chunk per livello documentale nel corpus

Livello documentale	**Righe di chunk**	**Quota del totale**
A, primaria	252	1,40%
B, medie	4.330	24,09%
C, superiori	2.847	15,84%
D, università	10.547	58,67%

La prevalenza del livello D e la ridotta disponibilità di materiale A motivano l'ammissione di livelli vicini durante il recupero. La quantità complessiva di testo non garantisce tuttavia una copertura uniforme degli argomenti e dei prerequisiti.

2.2 Pulizia, chunking e indicizzazione

Il testo estratto viene ripulito da markup e riferimenti alle immagini, normalizzato e suddiviso prima per titoli Markdown e poi ricorsivamente. La configurazione usa frammenti di 1.500 caratteri, sovrapposizione di 200 e scarto dei frammenti inferiori a 150 caratteri. Dimensione e sovrapposizione cercano un equilibrio fra conservazione del contesto e selettività del recupero; sono scelte pratiche, non valori ottimizzati sperimentalmente. I caratteri non corrispondono ai token dei modelli.

La rappresentazione è testuale: le immagini non vengono interrogate e la pulizia delle tabelle HTML può perdere la struttura di righe e colonne. Questi limiti sono rilevanti per testi scientifici contenenti formule, diagrammi e dati tabulari.

I chunk vengono trasformati in vettori con **BAAI/bge-m3** e salvati in **ChromaDB**, utilizzando la distanza coseno. L'identificativo derivato dal testo permette di deduplicare passaggi identici. Questo riduce la ridondanza, ma un solo record non conserva necessariamente tutte le provenienze di un testo ripetuto. L'encoder multilingue consente di trattare il corpus italiano e inglese; la sua scelta non deriva da una comparazione esaustiva fra encoder.

2.3 Recupero, reranking e gestione dei livelli

La ricerca densa seleziona i candidati semanticamente vicini alla domanda. Il cross-encoder **BAAI/bge-reranker-v2-m3** valuta poi le coppie domanda–passaggio e ne affina l'ordinamento. I duplicati vengono rimossi e un bonus di 0,5 favorisce i passaggi del livello esatto. I livelli di fallback sono ammessi contemporaneamente, senza una priorità sequenziale fra loro.

Tabella 2: Filtro sui livelli documentali ammessi per ciascun profilo studente

Livello richiesto	**Livelli documentali ammessi**	**Significato**
A · primaria	A, B	Evita l'uso diretto di testi universitari.
B · medie	B, A, C	Consente fonti vicine ai prerequisiti.
C · superiori	C, B, D	Ammette approfondimenti da semplificare.
D · università	D, C	Privilegia fonti avanzate, con fallback.

La pipeline originale può usare la domanda italiana e una variante tradotta per ampliare la ricerca. Il benchmark IR utilizza 20 candidati per variante; il generatore corrente e la demo ne richiedono 15, con tre risultati finali nella configurazione ordinaria. La demo usa soltanto la query italiana. Il ramo live è denso con reranking: BM25 è impiegato come baseline nella valutazione, non come componente di un recupero ibrido.

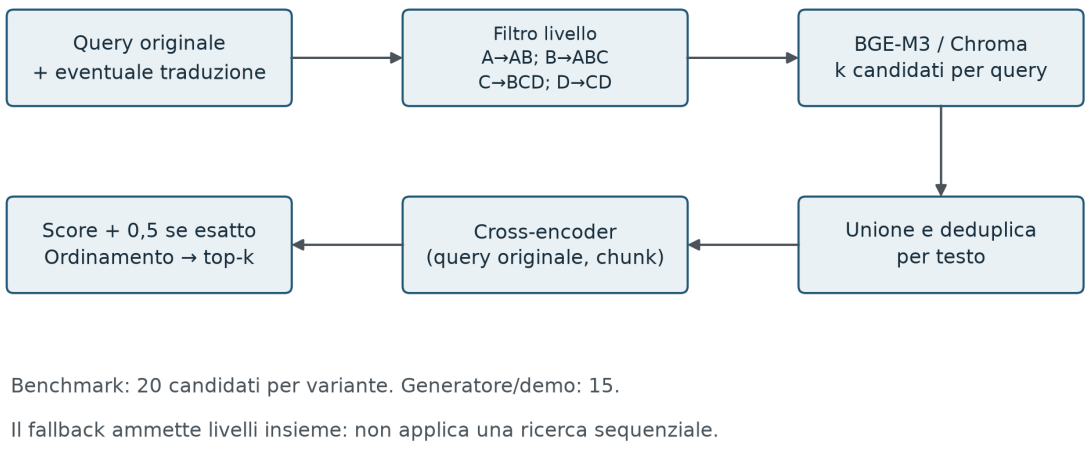


Figura 2: Struttura del recupero: filtro sul livello, ricerca densa, unione dei candidati, reranking sulla query originale e bonus per corrispondenza esatta.

2.4 Generazione della risposta

Il generatore compone il prompt con domanda, passaggi recuperati, titoli delle fonti e istruzioni per il livello richiesto. Nella pipeline originale utilizza Ollama con Qwen 2.5 3B. Le istruzioni chiedono di basarsi sul contesto e di rifiutare quando questo non contiene la risposta; la loro presenza non garantisce da sola l'assenza di allucinazioni.

I guardrail originali controllano leggibilità, gergo, formule e lunghezza e possono richiedere una rigenerazione. Sono controlli euristici sulla forma, non verificatori della correttezza scientifica. Il sistema registra risposta originale, risposta finale e interventi correttivi. La demo finale e il confronto Base/DPO non applicano questa rigenerazione, così l'effetto dell'adattatore non viene confuso con quello del correttore.

2.5 Valutazione del retrieval

Il riferimento comprende 172 query deduplicate per coppia domanda–livello: 40 A, 42 B, 35 C e 55 D. Deriva dagli esempi storici in cui è noto il file del chunk utilizzato per generare la domanda. Gli esempi topic-based, nei quali le fonti provengono dal retriever stesso, sono esclusi: usarli come verità di riferimento introdurrebbe una valutazione circolare.

Il risultato viene giudicato a granularità di documento. La lista dei chunk è collassata alla prima occorrenza di ogni documento, poi si individua il rango della fonte attesa. Con una sola fonte nota, Recall@k coincide con la frazione di query per cui quella fonte compare entro k; MRR media l'inverso del suo rango, con zero quando non compare entro la profondità considerata. nDCG@10 applica uno sconto logaritmico al rango entro dieci. Sono metriche appropriate al riferimento disponibile, ma non stimano esaustivamente tutte le fonti pertinenti.

La scelta documentale evita di penalizzare un chunk vicino a quello sorgente che risponde altrettanto bene. Introduce però un limite complementare: recuperare un passaggio poco utile del documento atteso può contare come successo. Inoltre, una fonte diversa ma valida non è necessariamente riconosciuta dal silver standard. La misura non va quindi descritta come percentuale di risposte corrette del tutor.

Tabella 3: Risultati del benchmark di retrieval sulle 172 query per configurazione

Configurazione	**R@1**	**R@3**	**R@5**	**R@20**	**MRR**	**nDCG @10**
BM25	0,1802	0,2209	0,2442	0,2616	0,2058	0,2144
BM25 + expansion	0,3081	0,4360	0,5291	0,7151	0,4055	0,4470
solo bi-encoder	0,5756	0,7326	0,8256	0,8837	0,6742	0,7249
+ re-ranker	0,5233	0,7616	0,8314	0,8837	0,6511	0,7084
+ query expansion	0,5233	0,7674	0,8372	0,8953	0,6560	0,7131
+ bonus livello	0,5930	0,7965	0,8663	0,8953	0,7046	0,7515

Il recupero denso aumenta Recall@3 da 0,2209 di BM25 a 0,7326; BM25 con espansione raggiunge 0,4360. Il reranker porta Recall@3 a 0,7616, ma riduce Recall@1 e MRR: il beneficio dipende quindi dalla profondità considerata. L'espansione e il bonus di livello portano infine Recall@3 a 0,7965, MRR a 0,7046 e nDCG@10 a 0,7515. Il bonus non è stato ottimizzato mediante una griglia di valori.

Le prime due righe della tabella costituiscono il ramo lessicale; le successive descrivono il ramo denso e l'aggiunta progressiva dei suoi componenti. Il confronto non è dunque un'unica sequenza cumulativa. Nella configurazione completa Recall@3 è 0,700 per A, 0,857 per B, 0,714 per C e 0,873 per D, evidenziando differenze fra profili.

Queste misure provengono dalla campagna IR del 26 luglio 2026 e non da una nuova esecuzione della demo corrente. Il riferimento sintetico e documentale limita l'estensione dei risultati alle

domande reali degli studenti; il recupero della fonte attesa non equivale alla correttezza della risposta finale.

3 Generazione del dataset e controlli di qualità

3.1 Dalla raccolta iniziale al dataset finale

La prima raccolta, implementata in `src/alignment.py`, utilizzava un modello oracolo per le risposte preferite e un modello più piccolo per alternative con registro scorretto, allucinazioni o contenuti fuori dominio. Le risposte prodotte da autori diversi potevano introdurre differenze stilistiche estranee all'obiettivo didattico; inoltre, la valutazione dell'intera pipeline combinava effetti del recupero, del prompt e dei guardrail.

La campagna finale adotta un dataset costruito offline con assistenza IA a partire dai PDF e un confronto controllato su input congelati. Questo dataset non è un semplice ampliamento delle precedenti raccolte. La generazione automatica inizialmente tentata aveva prodotto contesti e coppie non sempre adatti; la costruzione finale rende espliciti brani, domande e criterio di preferenza.

3.2 Costruzione delle domande e delle coppie

Da sei documenti di training sono stati selezionati 25 nuclei tematici, con tre domande per nucleo: **75 domande distinte**. Ogni domanda compare ai quattro livelli, ottenendo 300 prompt. Una risposta preferita viene confrontata con due alternative rifiutate: si ottengono così **600 coppie DPO**, 150 per livello.

Tabella 4: Struttura e funzione degli elementi che compongono ciascuna coppia di preferenza

Elemento	Contenuto e funzione
Prompt	Profilo, brano di riferimento e domanda; stesso input per chosen e rejected.
Chosen	Risposta pertinente, basata sul brano e formulata per il livello indicato.
Rejected fattuale	Contiene un errore intenzionale; 300 coppie.
Rejected fuori tema	Risposta tratta da un altro nucleo, allo stesso livello; 300 coppie.

Il primo negativo contiene un errore fattuale intenzionale; il secondo è una risposta di un altro nucleo tematico, allo stesso livello, ma estranea alla domanda. Il segnale riguarda quindi soprattutto correttezza e pertinenza: non isola una preferenza didattica fra due spiegazioni entrambe corrette.

La versione A della risposta usa il testo semplice; B aggiunge una spiegazione; C combina testo preciso e spiegazione; D usa il testo preciso. Il livello avanzato non è pertanto ottenuto rendendo sistematicamente la risposta più lunga. Questa costruzione controllata consente di riprodurre i dati, ma non garantisce una profondità adeguata a ogni livello per ciascuna domanda.

Domanda, livello A: «Perché non c'è un'eclissi di Luna a ogni Luna piena?»

Preferita: «Il percorso della Luna è inclinato: spesso la Luna piena passa sopra o sotto l'ombra della Terra.»

Rifiutata, errore intenzionale: «A ogni Luna piena si verifica necessariamente un'eclissi, perché l'orbita lunare non è inclinata rispetto a quella terrestre.»

La coppia mostra bene ciò che il modello può apprendere: favorire una spiegazione coerente con l'inclinazione dell'orbita rispetto a un'affermazione falsa. Non mostra, invece, una preferenza puramente didattica fra due spiegazioni corrette. Inoltre, negativi con errori evidenti o formule assolute possono rendere il compito relativamente facile e permettere scorciatoie stilistiche.

Le risposte preferite hanno in media 21,92 parole, quelle rifiutate 19,89. Le chosen non sono dunque sistematicamente più corte, ma rimangono brevi in termini assoluti. La presenza di negativi facilmente distinguibili può favorire scorciatoie stilistiche.

3.3 Controlli strutturali e provenienza

Per ogni coppia vengono conservati identificativo, fonte e collegamento al brano originale. I controlli verificano conteggi, unicità, differenza fra chosen e rejected e presenza degli estratti nei chunk salvati. Gli offset si riferiscono ai caratteri del chunk, non alle pagine del PDF; gli hash permettono di rilevare modifiche agli artefatti.

Alcuni contesti sono in inglese, mentre le risposte sono in italiano. I dati non contengono token specifici di un modello: ciascun trainer applica il proprio chat template. È disponibile anche un insieme SFT con le 300 risposte preferite deduplicate, che non costituisce un braccio del confronto finale.

Queste verifiche attestano la struttura e la tracciabilità dei dati, non la correttezza scientifica di ogni affermazione. Non è stata svolta una revisione umana indipendente del dataset; errori nella fonte o nell'estrazione possono rimanere anche in un brano correttamente tracciato.

3.4 Separazione fra training, sviluppo e test

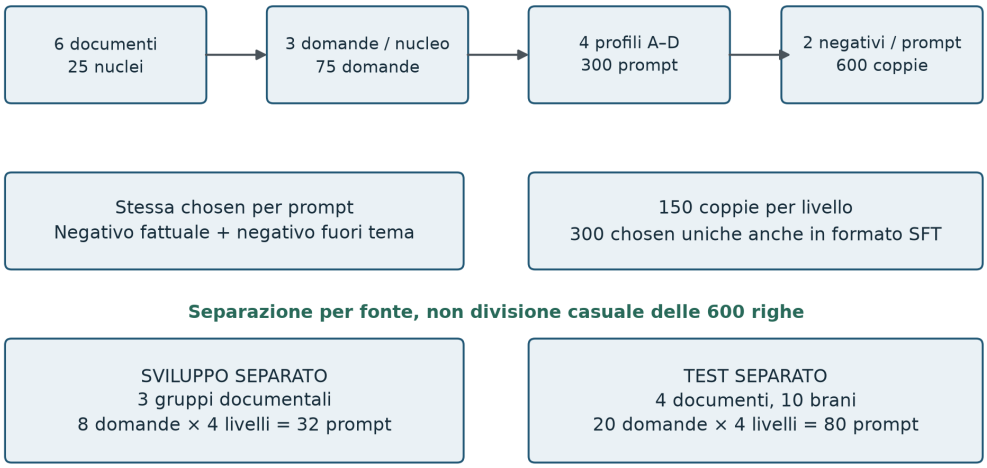


Figura 3: Costruzione del training e separazione dei dati: 25 nuclei, 75 domande, 300 prompt e 600 confronti. Il test deriva da quattro documenti distinti rispetto al training e allo sviluppo.

Le fonti sono separate per documento: sei per il training, tre gruppi documentali per lo sviluppo e quattro documenti per il test. Lo sviluppo comprende 32 prompt; il test 20 domande su dieci brani, ripetute ai quattro livelli per un totale di 80 prompt. I contesti di test sono riformulazioni italiane assistite dei documenti riservati, con conservazione degli estratti originali.

Una divisione casuale delle 600 righe sarebbe inadatta, perché la stessa domanda potrebbe comparire in insiemi diversi con un altro livello o un altro negativo. La separazione documentale riduce questo rischio, ma non esclude sovrapposizioni concettuali fra testi astronomici o la presenza delle fonti nel pretraining dei modelli.

Il training finale utilizza tutte le 600 coppie, senza validation durante l'ottimizzazione. I prompt di sviluppo sono separati e non costituiscono una curva di validation. Le 600 coppie non sono 600 domande indipendenti; analogamente, gli 80 prompt di test derivano da sole 20 domande.

4 Addestramento DPO dei diversi modelli

4.1 Obiettivo di apprendimento

Il DPO ottimizza la preferenza per una risposta rispetto a un'altra sullo stesso prompt, senza addestrare separatamente un reward model [2]. Il modello iniziale costituisce il riferimento rispetto al quale viene misurata la variazione della preferenza.

Nel training x indica il prompt, y+ la risposta preferita e y− quella rifiutata. La policy aggiornata viene confrontata con il modello di riferimento sulle medesime stringhe. La loss sigmoid usata dalla campagna si esprime come segue:

$$\mathcal{L}_{\mathrm{DPO}} = -\mathbb{E}_{(x,y^+,y^-)\sim D}\left[\log\sigma\left(\beta\left[\log\frac{\pi_\theta(y^+ \mid x)}{\pi_{\mathrm{ref}}(y^+ \mid x)} - \log\frac{\pi_\theta(y^- \mid x)}{\pi_{\mathrm{ref}}(y^- \mid x)}\right]\right)\right]. \tag{1}$$

L'argomento della sigmoide aumenta quando migliora la preferenza relativa per y+ rispetto a y−, misurata contro il riferimento. Non impone che la probabilità assoluta della chosen cresca a ogni step: il margine può aumentare anche riducendo maggiormente la probabilità della rejected. I reward salvati sono trasformazioni delle log-probabilità rispetto al riferimento; non sono punteggi assegnati dal giudice della valutazione.

4.2 Modelli e configurazione comune

Sono stati addestrati Qwen 2.5 1.5B e 3B, SmolLM3 3B, Gemma 3 1B, Llama 3.2 3B e Mistral 7B v0.3. Il confronto fra famiglie permette di osservare l'eterogeneità dell'effetto, ma non isola la sola dimensione del modello: cambiano anche pretraining e instruction tuning.

La memoria locale di circa 8 GB ha motivato l'uso di QLoRA [3]: i pesi base restano congelati e quantizzati, mentre si aggiornano adattatori a basso rango. La quantizzazione NF4 con doppia quantizzazione riduce la memoria dei pesi; il calcolo usa BF16. Il gradient checkpointing riduce la memoria delle attivazioni ricalcolandone una parte durante il backward.

Tabella 5: Impostazioni comuni di addestramento DPO condivise tra i sei modelli

Impostazione comune	**Valore**
Dati e durata	600 coppie; 2 epoche; 300 step di ottimizzazione
DPO	Loss sigmoid; beta 0,1; modello iniziale come riferimento
Ottimizzazione	Learning rate costante 5×10^{-6}; seed 42
Batch	1 esempio per dispositivo; accumulo di 4 step
LoRA	Rank 8; alpha 16; dropout 0,0; proiezioni q/k/v/o
Memoria	NF4 con doppia quantizzazione; BF16; gradient checkpointing

Gli adattatori intervengono sulle proiezioni query, key, value e output dell'attenzione. Il batch effettivo è quattro, ottenuto accumulando quattro microbatch da un esempio: con 600 coppie si eseguono 150 aggiornamenti per epoca e 300 in due epoche. Gli iperparametri comuni rendono il protocollo confrontabile, senza garantire la configurazione ottimale per ogni famiglia. La campagna finale confronta Base e DPO diretto; SFT e SFT+DPO restano fuori dal confronto.

4.3 Compatibilità, tempi e memoria

Le lunghezze sono state controllate con ciascun tokenizer e il rispettivo template. Gemma e Mistral uniscono l'istruzione di sistema al primo messaggio utente; SmolLM3 usa la configurazione senza thinking. I valori di max_length si riferiscono alle sequenze di training, non alla capacità massima dichiarata del modello.

Tabella 6: Lunghezze di contesto, durata del training e VRAM allocata per modello

Modello	Token min–max	max_length	Tempo, min	VRAM allocata, GiB
Qwen 1,5B	250–502	510	31,13	1,743
Qwen 3B	250–502	510	17,38	2,848
SmolLM3 3B	287–542	550	15,43	2,700
Gemma 1B	193–422	430	10,02	1,640
Llama 3B	270–525	533	15,15	3,237
Mistral 7B	267–548	556	46,05	4,949

Tutti i training sono stati completati su RTX 4070 Laptop da 8 GB. Le durate vanno da circa 10 a 46 minuti e i picchi allocati da 1,64 a 4,95 GiB. Questi dati descrivono i run effettuati, non un benchmark controllato di velocità; non includono preparazione dei dati, download e valutazione. La memoria allocata da PyTorch non coincide necessariamente con l'occupazione totale della GPU.

4.4 Andamento dell'ottimizzazione

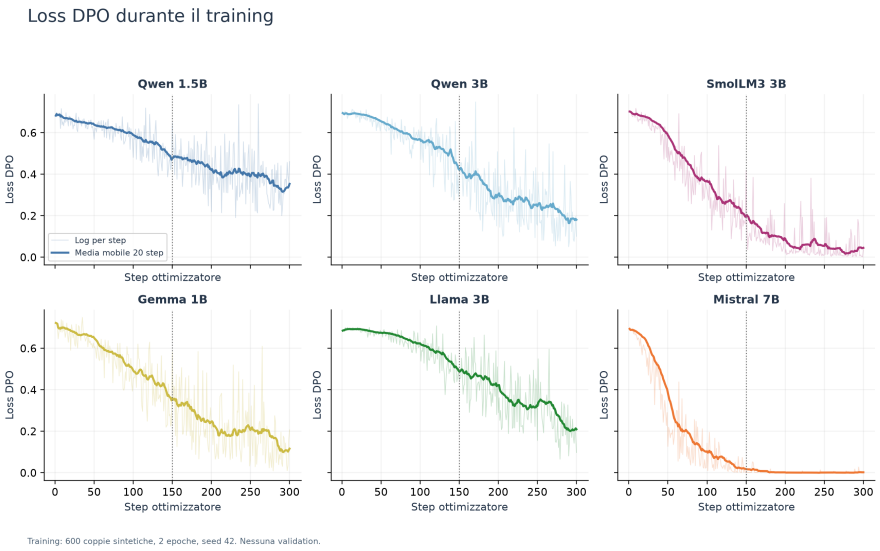


Figura 4: Loss registrata durante i sei training. Linee tenui: valori per step; linee piene: media mobile retrospettiva su 20 step. Il confine fra epoche è indicato verticalmente.

La loss diminuisce in tutti i run, indicando che l'obiettivo sulle coppie di training viene ottimizzato. Non dimostra, da sola, una maggiore correttezza su nuove domande o l'assenza di memorizzazione. Non essendoci curve di validation, il comportamento fuori dal training viene esaminato attraverso il test separato. Le metriche di preferenza e gli altri grafici diagnostici sono riportati in appendice.

5 Test comparativo e risultati

5.1 Disegno del confronto Base/DPO

Il test è stato congelato prima della generazione finale. Comprende 20 domande su dieci brani ai quattro livelli: 80 prompt per modello. Sei modelli e due condizioni producono **960 risposte**.

Le fonti del test sono distinte da quelle di training e sviluppo; i punti di riferimento usati per il giudizio non sono forniti al generatore.

Per ogni prompt si usa lo stesso modello quantizzato, con adattatore disattivato nella condizione Base e attivo nella condizione DPO. Contesto, domanda, livello e parametri di generazione restano invariati entro ciascun confronto. Si usa decoding greedy, senza campionamento, con repetition penalty 1 e massimo 384 nuovi token; non vengono applicati guardrail o riscritture successive.

Il confronto utilizza contesti predefiniti per isolare l'effetto del DPO sulla generazione delle risposte. Il retrieval è valutato separatamente. I risultati non costituiscono quindi una valutazione end-to-end del sistema RAG, ma descrivono l'effetto dell'adattatore a parità di informazioni disponibili. La normalizzazione dei contesti italiani riduce inoltre il rumore di estrazione che potrebbe essere presente durante l'uso live.

5.2 Rubrica e giudice automatico

Il giudice finale è **openai/gpt-oss-120b su Groq**, con temperatura zero. Riceve domanda, livello, contesto, punti di riferimento e risposta, senza conoscere il modello o la condizione Base/DPO. Ogni risposta viene valutata separatamente secondo la stessa rubrica.

Tabella 7: Dimensioni e criteri operativi della rubrica di valutazione automatica

Dimensione	**Criterio della rubrica**
Correttezza C/P/I	C: nucleo corretto senza errori sostanziali; P: parziale o ambiguo; I: nucleo errato o errore grave.
Completezza 0–2	Copertura degli elementi essenziali della domanda, senza pretendere ogni informazione del contesto.
Adeguatezza 0–2	Compatibilità di prerequisiti, termini spiegati e profondità con il livello.
Chiarezza 0–2	Comprensibilità, coerenza e assenza di contraddizioni.

La rubrica distingue correttezza, completezza, adeguatezza e chiarezza, senza premiare automaticamente lunghezza o tecnicismo. Le preferenze appaiate vengono derivate dai voti, nell'ordine correttezza, completezza, adeguatezza e chiarezza, mantenendo le parità: non sono una seconda valutazione indipendente.

Le 960 risposte corrispondono a 952 giudizi unici, perché otto duplicati sullo stesso prompt riutilizzano il giudizio. Le risposte al limite di output restano nel test. I punteggi rappresentano stime automatiche: il campione predisposto di 24 coppie per revisione umana non risulta ancora validato indipendentemente.

5.3 Correttezza delle risposte

Tabella 8: Risultati sulla correttezza stimata (voti C ed I) prima e dopo l'intervento DPO

Modello	**C base → DPO**	**Delta p.p.**	**I base → DPO**
Qwen 2.5 1.5B	40 → 42	+2.50	18 → 20
Qwen 2.5 3B	63 → 67	+5.00	8 → 0
SmolLM3 3B	69 → 66	-3.75	3 → 3
Gemma 3 1B	38 → 47	+11.25	20 → 14
Llama 3.2 3B	50 → 63	+16.25	12 → 6
Mistral 7B v0.3	73 → 79	+7.50	2 → 0

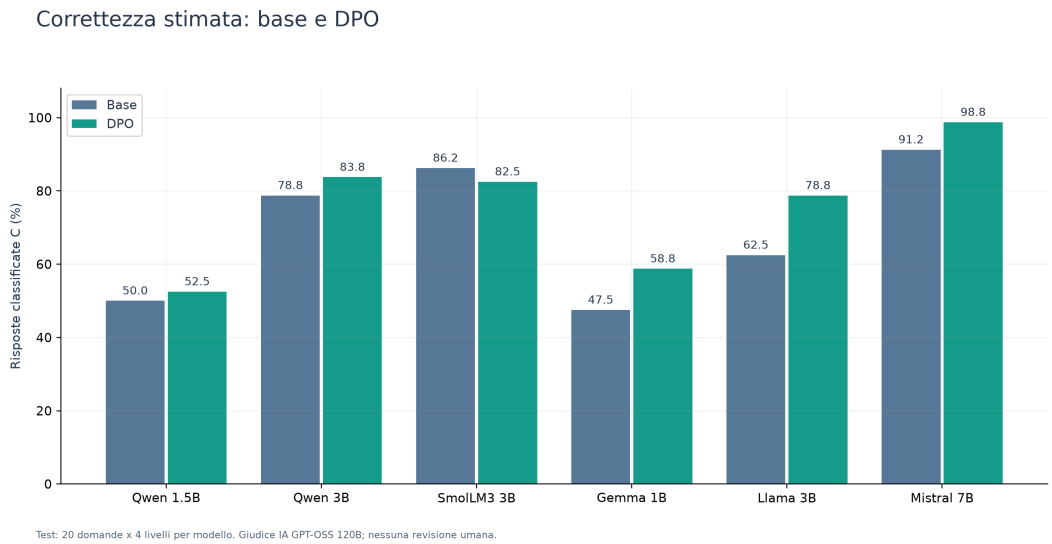


Figura 5: Risposte classificate C dal giudice automatico, su 80 per modello e condizione. La percentuale rappresenta il campione osservato, non una probabilità generale di correttezza.

Il conteggio delle risposte corrette aumenta in cinque modelli su sei. **Llama 3.2 3B** mostra il maggiore incremento assoluto: 13 risposte C in più, pari a 16,25 punti percentuali. **Gemma** guadagna nove risposte, mentre **Mistral**, già elevato nella condizione iniziale, passa da 73 a 79. SmolLM3 è l'eccezione: perde tre risposte C e passa da 86,25% a 82,50%.

Per **Qwen 3B** il beneficio è particolarmente visibile nella categoria I, che scende da otto a zero; non tutte le risposte diventano però pienamente corrette, perché aumentano anche le parziali. In **Qwen 1.5B** aumentano sia C sia I, a scapito di P. Guardare soltanto la prima colonna avrebbe nascosto questa regressione. Il dato va quindi letto come distribuzione della qualità, non come una sola classifica.

Aggregando descrittivamente i sei modelli, C passa da 333 a 364 su 480 risposte per condizione. Il totale non equivale a 480 domande indipendenti: gli stessi quesiti e brani vengono riutilizzati. Inoltre, un modello con punteggio iniziale alto dispone di un margine di crescita minore. Il confronto più informativo resta quello appaiato entro ciascun modello.

5.4 Adeguatezza, completezza e lunghezza

I guadagni fattuali non si trasferiscono automaticamente all'obiettivo educativo. L'adeguatezza media rimane invariata in SmolLM3, cresce di poco in Qwen 1.5B e Gemma, e diminuisce in Qwen 3B, Llama e Mistral. Il risultato non sostiene quindi un miglioramento uniforme dell'adattamento ai prerequisiti dello studente. Le medie su una scala di tre valori sono sintesi descrittive, non misure continue della qualità pedagogica.

Per esempio, in **Llama** il livello A passa da 1,70 a 2,00, mentre B scende da 1,85 a 1,55 e D da 1,80 a 1,65. In **Qwen 3B** A migliora da 1,85 a 1,95, ma B passa da 1,85 a 1,65. Non esiste dunque un unico effetto "sul livello": lo stesso training può favorire alcune condizioni e penalizzarne altre.

Il caso **Mistral** evidenzia il compromesso: C aumenta fino a 79/80, ma completezza e adeguatezza medie scendono rispettivamente da 1,95 a 1,80 e da 1,95 a circa 1,84. Secondo la regola di preferenza derivata, il DPO vince solo sette confronti contro 21 del base, con 52 parità. Correttezza aggregata e preferenza complessiva non sono quindi indicatori intercambiabili.

Nella tabella B→D indica Base→DPO, non il passaggio fra livelli scolastici. I voti sono medie descrittive sulla scala ordinale 0–2, arrotondate a tre decimali; ogni condizione comprende 80 risposte.

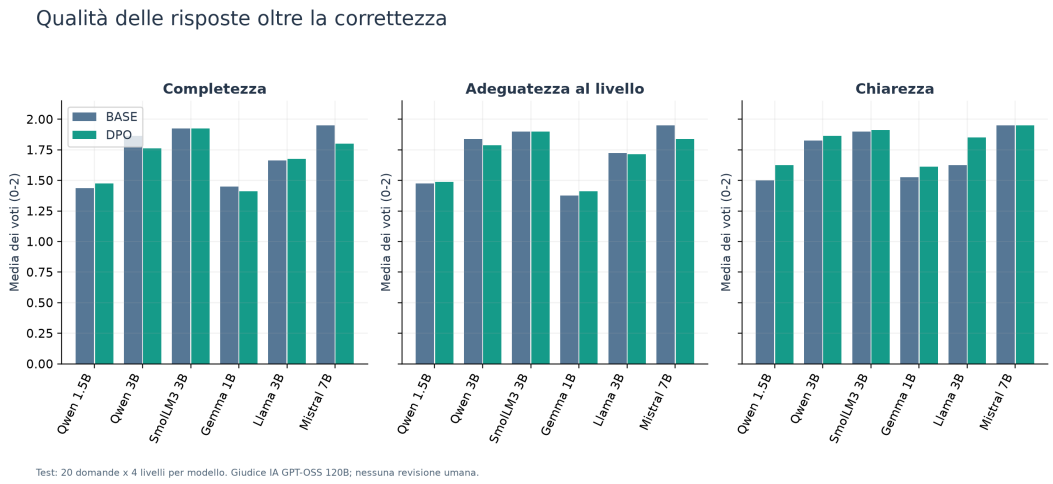


Figura 6: Medie descrittive dei voti ordinali 0–2. Le dimensioni vengono mantenute separate perché una risposta corretta può essere incompleta o inadatta al profilo.

Tabella 9: Punteggi medi per le dimensioni qualitative di completezza, adeguatezza e chiarezza

Modello	**Completezza B→D**	**Adeguatezza B→D**	**Chiarezza B→D**
Qwen 1.5B	1,438 → 1,475	1,475 → 1,488	1,500 → 1,625
Qwen 3B	1,863 → 1,762	1,837 → 1,788	1,825 → 1,863
SmolLM3	1,925 → 1,925	1,900 → 1,900	1,900 → 1,913
Gemma 1B	1,450 → 1,413	1,375 → 1,413	1,525 → 1,613
Llama 3B	1,663 → 1,675	1,725 → 1,712	1,625 → 1,850
Mistral 7B	1,950 → 1,800	1,950 → 1,837	1,950 → 1,950

Le parole medie scendono in tutte le famiglie: da 103,0 a 48,0 in Qwen 3B, da 146,3 a 63,3 in Llama e da 86,4 a 43,6 in Mistral. Una risposta più breve può evitare aggiunte errate, ma anche perdere spiegazioni necessarie. Non è stata eseguita un'ablazione che separi l'effetto della correttezza da quello della brevità implicita nelle preferenze. I conteggi completi e i grafici per livello sono riportati in appendice.

5.5 Analisi di due casi rappresentativi

Nel prompt **test03_D**, sul gas vicino ai buchi neri, Qwen 3B base aggiunge che la trasformazione avviene «solo quando il gas si avvicina troppo al buco nero, oltre l'orizzonte degli eventi». Il giudice assegna I. Dopo DPO la risposta diventa: «L'energia potenziale gravitazionale può essere convertita in calore e radiazione durante l'accrescimento del gas che si avvicina al buco nero.» Il giudizio passa a C, mentre la completezza scende da 2 a 1 e l'adeguatezza rimane 1.

Questo caso documenta la rimozione di un'affermazione problematica, non il raggiungimento di una spiegazione universitaria completa. È un esempio scelto per illustrare il compromesso, non una stima rappresentativa di tutti i casi.

In **test01_A**, Mistral base spiega che l'infrarosso attraversa le nubi con attenuazione minore rispetto al visibile. La risposta DPO conserva il riferimento all'emissione infrarossa della polvere, ma omette quel passaggio. Entrambe sono classificate C dal giudice, mentre la completezza passa da 2 a 1. La motivazione salvata permette di capire la perdita che la sola correttezza binaria non mostrerebbe.

Queste valutazioni sono riportate come giudizi automatici conservati, non come validazione esperta delle singole frasi. Anche la coerenza fra motivazione e punteggio merita revisione umana. Sono state mantenute nel test tutte le risposte, comprese quelle al limite: i casi segnalati passano complessivamente da 37 nel base a 3 nel DPO. Escluderli a posteriori avrebbe modificato il confronto.

5.6 Incertezza delle stime

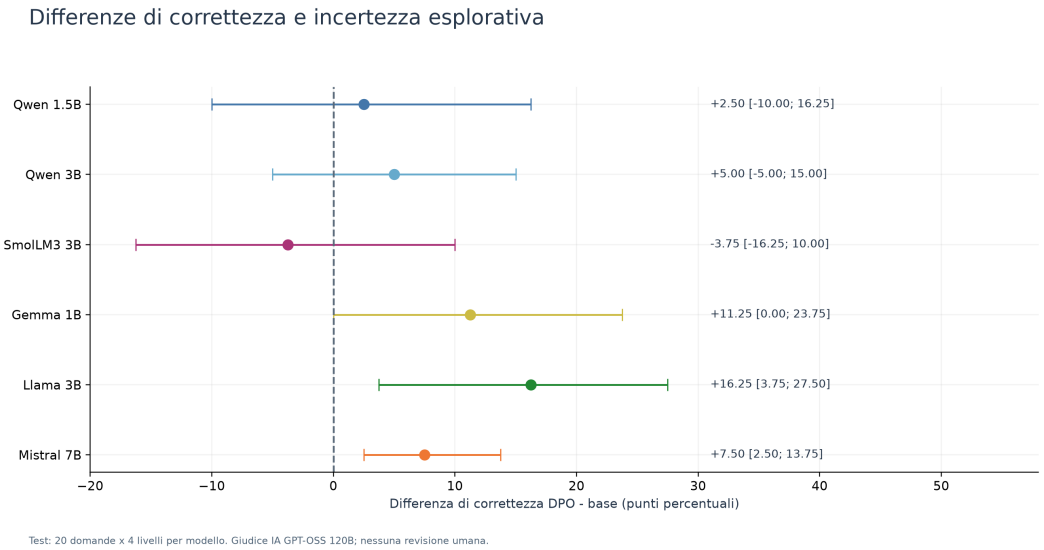


Figura 7: Differenza DPO meno Base nella quota di risposte C, con intervalli bootstrap esplorativi al 95%. Il ricampionamento raggruppa le osservazioni per dieci brani.

Le quattro versioni di una domanda condividono il contenuto e due domande possono condividere il brano. Trattare tutte le righe come indipendenti renderebbe l'incertezza troppo ottimistica. Il bootstrap usato raggruppa per contesto, ma dispone soltanto di dieci gruppi e non rappresenta tutte le dipendenze fra brani dello stesso PDF. Non incorpora inoltre errore del giudice, variabilità fra seed o scelta degli iperparametri.

Gli intervalli comprendono lo zero per Qwen 1.5B, Qwen 3B e SmolLM3; quello di Gemma lo tocca. Per Llama e Mistral restano positivi nel ricampionamento adottato. Non è stata applicata una correzione per confronti multipli: questi risultati non vengono trasformati in una dichiarazione generale di significatività. Un effetto osservato su un piccolo test rimane dipendente dal protocollo.

6 Discussione e conclusioni

6.1 Risultati rispetto agli obiettivi

AstroTutor ha raggiunto due risultati distinti: una pipeline utilizzabile per rispondere su documenti astronomici e un confronto tracciabile dell'effetto del DPO su sei modelli. Il secondo mostra miglioramenti della correttezza stimata in cinque casi, insieme a una riduzione generalizzata della lunghezza. Completezza e adeguatezza non seguono lo stesso andamento. La risposta alla domanda iniziale è quindi articolata: **il DPO può essere utile con questi dati e queste impostazioni, ma non realizza automaticamente un tutor didatticamente migliore**.

La distinzione è coerente con il segnale di training. Le coppie contrappongono soprattutto risposte corrette a errori o contenuti estranei; non isolano la preferenza per un registro adeguato.

Il mancato guadagno didattico non dimostra l'inefficacia generale del metodo. Allo stesso tempo, la discesa della loss e alcuni miglioramenti fattuali non autorizzano a dichiarare raggiunto l'obiettivo educativo originario.

Il confronto entro ciascun modello sostiene l'analisi dell'effetto del DPO nelle condizioni adottate. La valutazione separata del retrieval documenta invece la capacità di ritrovare le fonti attese nel benchmark disponibile. Queste evidenze rispondono a domande complementari e non vengono combinate in una misura unica della qualità del tutor.

6.2 Integrazione nella demo

La demo Streamlit integra il recupero live con i sei modelli e permette di confrontare Base e DPO sugli stessi brani, mostrando le fonti. Utilizza una query italiana, senza espansione e senza guardrail; embedding e reranking sono eseguiti su CPU per riservare la GPU al generatore. La cronologia visualizzata non viene usata come memoria conversazionale.

La demo rende utilizzabile il prototipo, ma le interazioni occasionali non sono nuove osservazioni del test. La fattibilità locale è documentata dai training completati e dall'integrazione; non è stato eseguito un benchmark finale controllato della latenza dell'intera pipeline.

6.3 Limiti e sviluppi futuri

I limiti principali sono dati sintetici non revisionati indipendentemente, test di 20 domande, un solo seed, un solo giudice automatico e assenza di un confronto SFT sistematico. La separazione per documento riduce alcune contaminazioni, ma non esclude somiglianze concettuali. Il test controllato esclude gli errori di retrieval; la demo li reintroduce. Nessuno studio ha misurato apprendimento, autonomia o comprensione degli studenti.

Un'estensione mirata dovrebbe introdurre coppie entrambe corrette e pertinenti ma diverse per qualità della spiegazione, raccogliere una revisione cieca indipendente e confrontare Base, SFT, DPO e SFT+DPO sugli stessi dati. Per attribuire l'effetto del DPO dopo SFT, il confronto necessario è SFT contro SFT+DPO. Repliche con più seed e un test più ampio renderebbero più solide le stime; uno studio con studenti risponderebbe a una domanda diversa, quella dell'efficacia educativa.

Una valutazione end-to-end con recupero live resta un possibile sviluppo per misurare la propagazione degli errori fra recupero e generazione. Non è necessaria per interpretare il confronto controllato svolto, purché le conclusioni rimangano circoscritte alla generazione con contesto e ai modelli, dati e impostazioni studiati.

A Diagnostica supplementare

Le figure seguenti approfondiscono la campagna già descritta e non costituiscono repliche indipendenti. La media mobile delle curve di training è retrospettiva su 20 step, con finestra ridotta all'inizio. Questi grafici non sostituiscono curve di validation, assenti nei sei run.

A.1 Metriche di addestramento

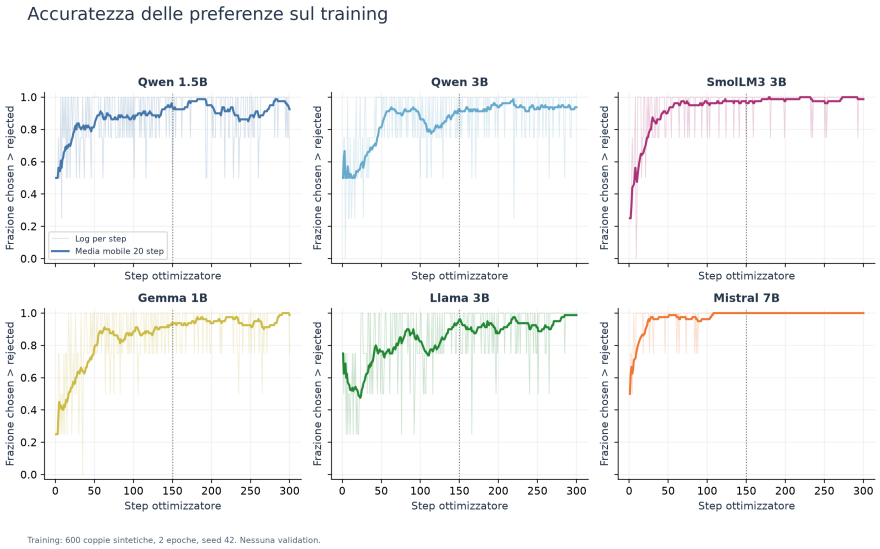


Figura 8: Accuratezza delle preferenze. Metriche del training finale; non sono giudizi esterni sulle risposte.

La quota di margini positivi descrive il successo sulle coppie di training. Un valore elevato può coesistere con un effetto modesto o negativo sulla correttezza del test, come ricorda il caso SmolLM3. Non misura il numero di risposte astronomiche corrette.

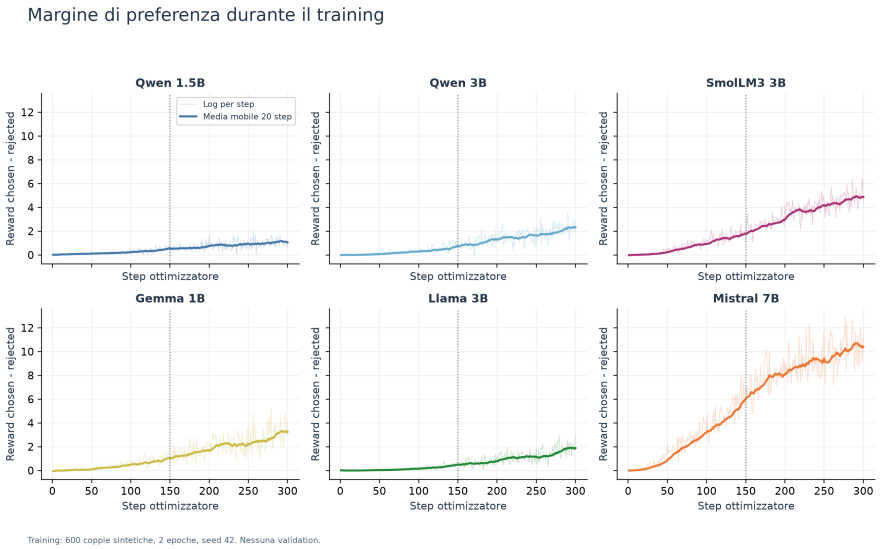


Figura 9: Margine rispetto al riferimento. Metriche del training finale; non sono giudizi esterni sulle risposte.

Il margine misura la separazione fra i reward impliciti di chosen e rejected. La sua crescita conferma la direzione dell'ottimizzazione, senza stabilire che tale separazione corrisponda al criterio didattico desiderato.

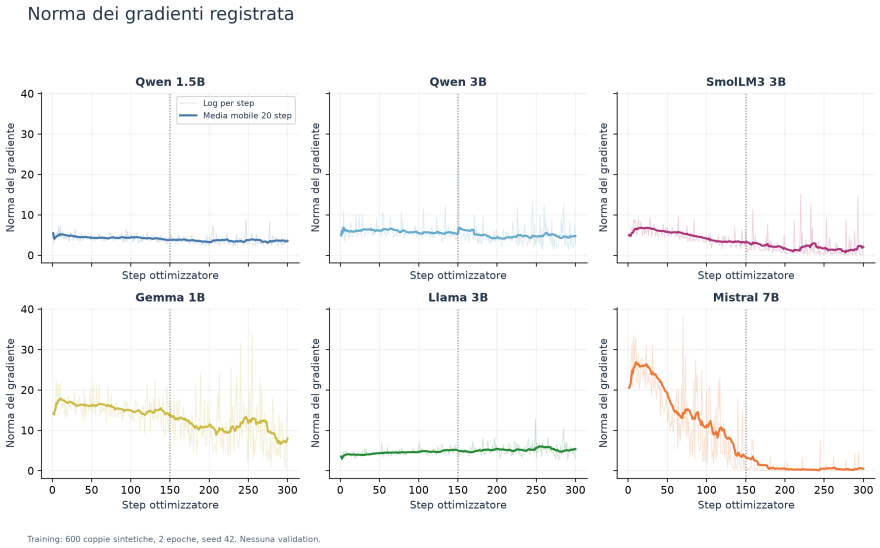


Figura 10: Norma dei gradienti. Metriche del training finale; non sono giudizi esterni sulle risposte.

La serie è diagnostica dell'ottimizzazione. Un valore registrato superiore a uno non dimostra che il clipping sia disattivato: il logging può precedere l'applicazione del clipping. Non si confrontano le scale come una classifica di qualità dei modelli.

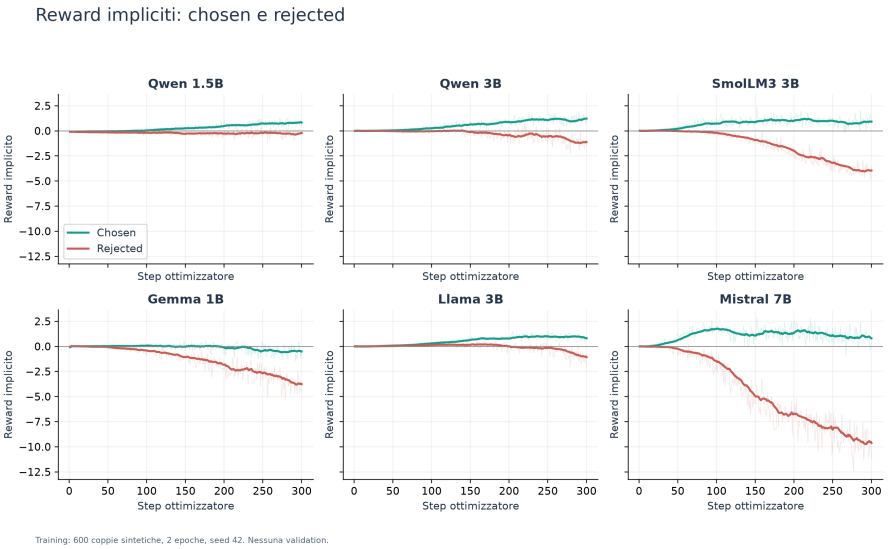


Figura 11: Reward impliciti dei due completamenti. Metriche del training finale; non sono giudizi esterni sulle risposte.

Chosen e rejected vanno lette insieme: il margine può aumentare soprattutto perché si riduce il reward della rejected. I reward sono differenze di log-probabilità rispetto al riferimento e non i voti del giudice Groq.

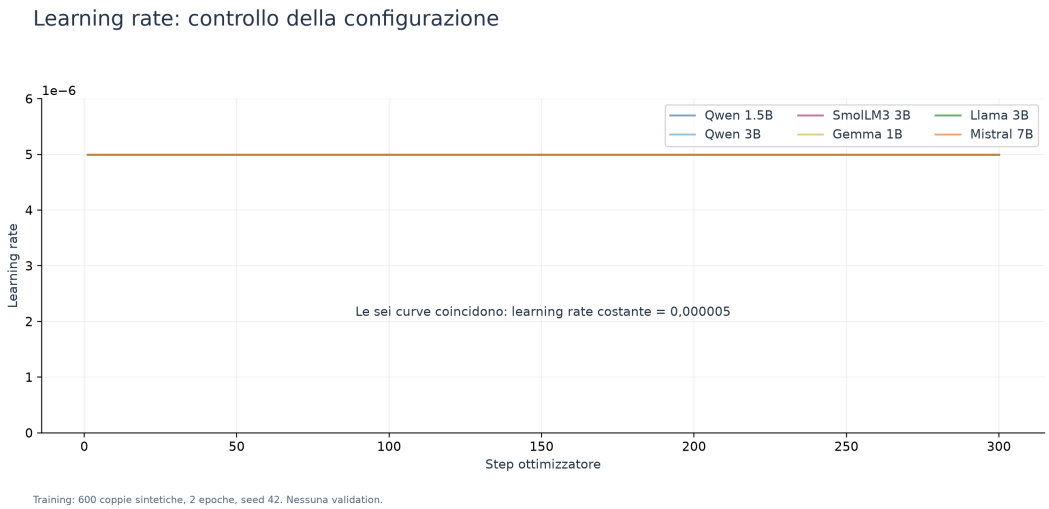


Figura 12: Learning rate effettivo. Metriche del training finale; non sono giudizi esterni sulle risposte.

La costanza della curva è coerente con scheduler constant e warmup nullo nei manifest finali. Non si attribuisce a questi run lo scheduler cosine delle configurazioni storiche. Nessuna ricerca separata del learning rate per famiglia è documentata.

A.2 Analisi supplementari delle risposte

D/B/= indica il numero di preferenze derivate per DPO, Base e parità. Gli intervalli riguardano la differenza della quota C, in punti percentuali, e provengono dal bootstrap per brano; non sono intervalli sulle medie di lunghezza. Il raggiungimento del limite è un flag di possibile troncamento.

Tabella 10: Brevità, raggiungimento del limite token, preferenze appaiate e intervalli di confidenza

Modello	Parole B→D	Limite token B→D	Preferenze D/B/=	IC 95%, punti %
Qwen 1.5B	76,3 → 52,0	2 → 0	25/18/37	-10,00; 16,25
Qwen 3B	103,0 → 48,0	2 → 0	18/18/44	-5,00; 15,00
SmolLM3	117,4 → 83,6	10 → 2	10/12/58	-16,25; 10,00
Gemma 1B	89,4 → 54,8	5 → 0	28/21/31	0,00; 23,75
Llama 3B	146,3 → 63,3	15 → 1	26/21/33	3,75; 27,50
Mistral 7B	86,4 → 43,6	3 → 0	7/21/52	2,50; 13,75

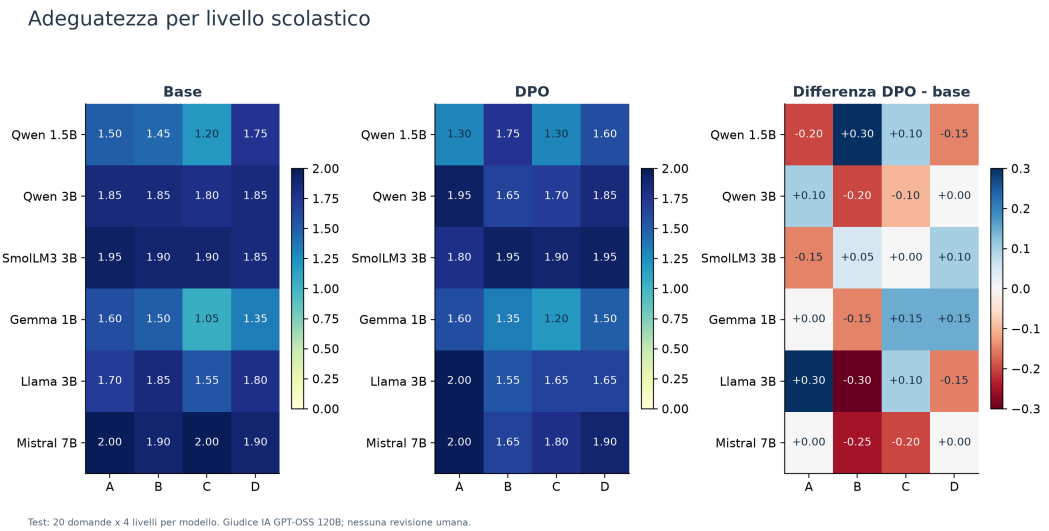


Figura 13: Adeguatezza distinta per livello e variazione dopo DPO. Ogni cella contiene soltanto 20 risposte; la mappa serve a localizzare differenze che la media generale nasconde.

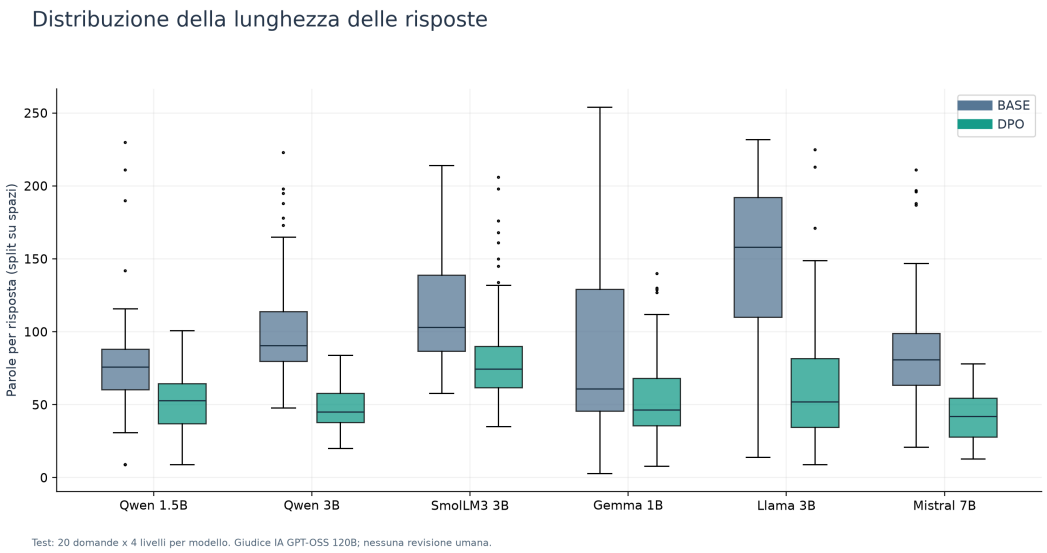


Figura 14: Distribuzione della lunghezza in parole. La riduzione compare in tutte le famiglie. Il numero di parole è una descrizione del comportamento, non un voto didattico.

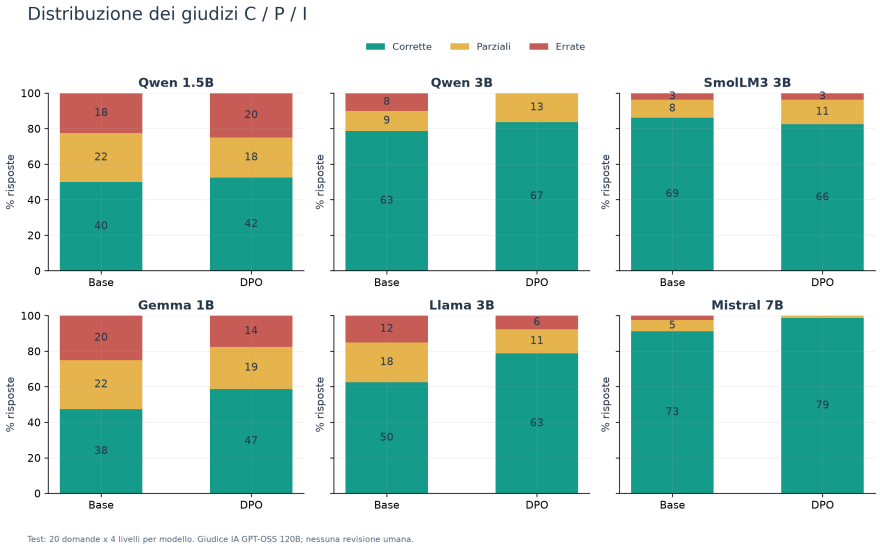


Figura 15: Distribuzione completa C/P/I. Dati della campagna finale; giudizi automatici e campione dipendente.

I conteggi per classe mostrano ciò che la sola quota C nasconde. Qwen 1.5B passa da 18 a 20 risposte I pur aumentando da 40 a 42 le C; Qwen 3B passa invece da otto I a zero, ma mantiene 13 risposte P.

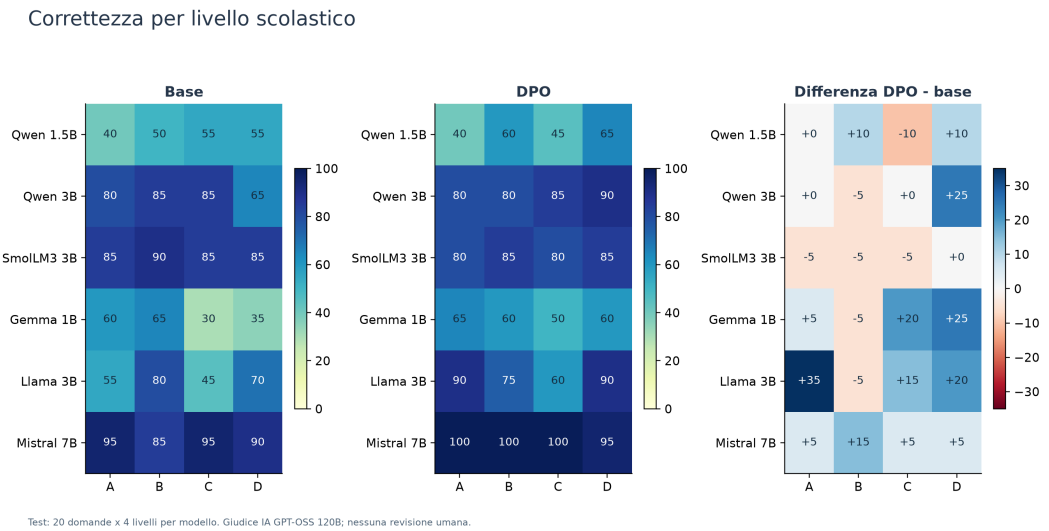


Figura 16: Correttezza distinta per profilo. Dati della campagna finale; giudizi automatici e campione dipendente.

Ogni cella contiene 20 risposte: una risposta vale cinque punti percentuali. Il confronto per livello localizza l'eterogeneità, ma non crea nuovi campioni indipendenti e non dimostra competenza generale per un intero grado scolastico.

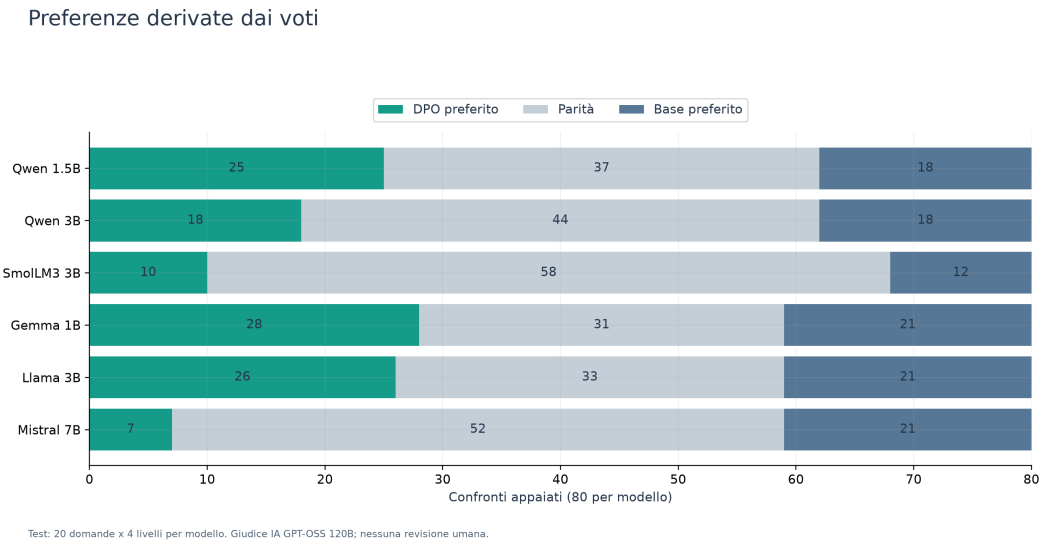


Figura 17: Preferenze derivate dai voti. Dati della campagna finale; giudizi automatici e campione dipendente.

La regola confronta nell'ordine correttezza, completezza, adeguatezza e chiarezza, mantenendo le parità. Il giudice non svolge una seconda valutazione globale della coppia. Per Mistral, sette preferenze DPO e 21 Base coesistono con una quota C migliore dopo DPO.

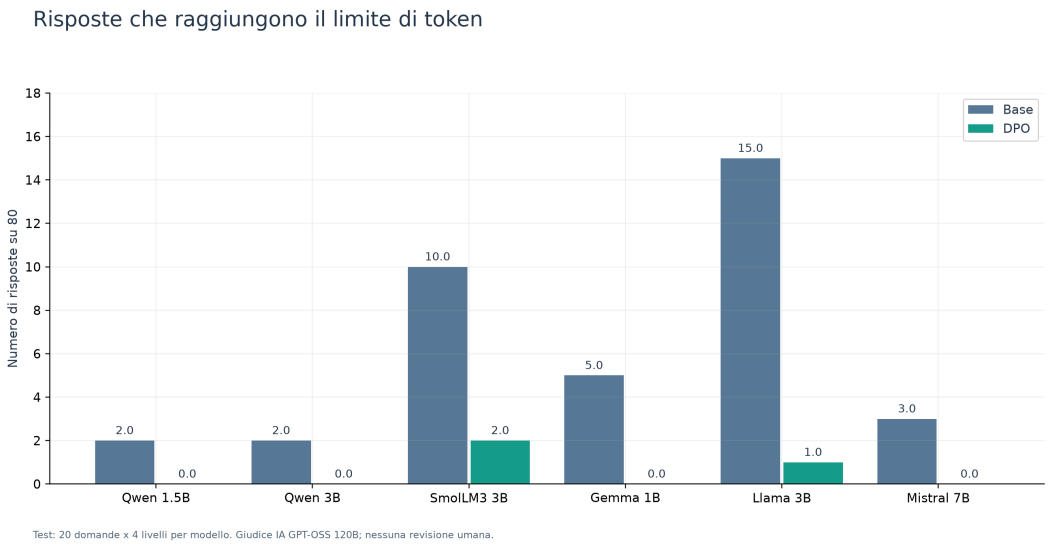


Figura 18: Raggiungimento del limite di output. Dati della campagna finale; giudizi automatici e campione dipendente.

Il flag indica 384 nuovi token senza token finale EOS. È un possibile troncamento, non una certezza di errore. I casi rimangono nel test; la riduzione complessiva da 37 a tre contribuisce a descrivere il cambiamento di comportamento, ma non dimostra da sola un miglioramento della spiegazione.

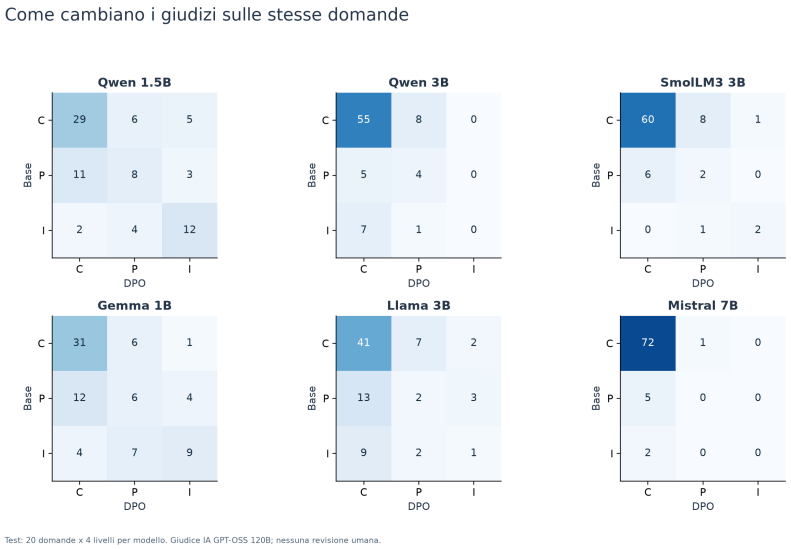


Figura 19: Transizioni appaiate fra giudizi. Dati della campagna finale; giudizi automatici e campione dipendente.

Righe e colonne rappresentano rispettivamente Base e DPO sullo stesso prompt. Le celle fuori diagonale separano miglioramenti e regressioni individuali: il saldo aggregato può nascondere entrambi. L'appaiamento è informativo, ma le varianti condividono domande e brani.

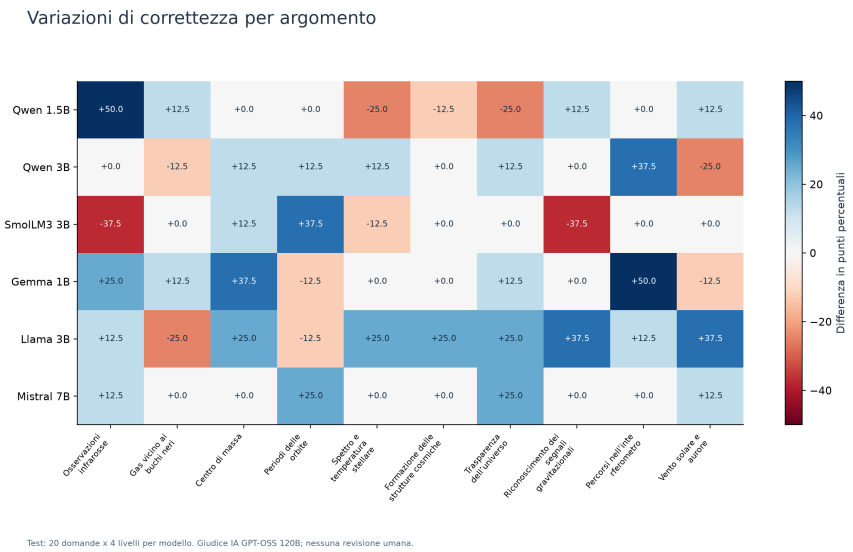


Figura 20: Variazioni per argomento. Dati della campagna finale; giudizi automatici e campione dipendente.

Ogni argomento comprende soltanto otto risposte per condizione, due domande ai quattro livelli. Una risposta vale 12,5 punti percentuali. Le differenze servono a identificare casi da rivedere; non sono una graduatoria affidabile delle competenze astronomiche generali.

B Riproducibilità e provenienza

B.1 Ambiente e artefatti

La campagna conserva revisioni dei checkpoint, configurazioni degli adattatori, tokenizer, hash dei dati, risposte grezze, giudizi e riepiloghi. I sei manifest registrano Python 3.14.3, PyTorch 2.11.0+cu128, Transformers 4.57.6, Datasets 5.0.1, Accelerate 1.15.0, TRL 0.24.0, PEFT 0.17.1 e bitsandbytes 0.48.1. Le versioni descrivono i run salvati; la riproduzione richiede anche pesi, adattatori, tokenizer e indice. Il file delle dipendenze non è un lockfile transitivo completo e le revisioni di encoder e reranker non sono fissate al commit nel caricamento ordinario.

Tabella 11: Mappa degli artefatti verificabili conservati nel repository

Evidenza	Artefatto relativo al repository	Utilità
Architettura e runtime	src/parsing.py, chuncking.py, indexing.py, retrieval.py, generation.py	Verifica del flusso e dei parametri effettivi.
Corpus	data/processed/chunks/	Conteggi delle righe e dei testi distinti.
Benchmark IR	data/retrieval_eval.json e retrieval_eval_meta.json	Metriche, popolazione e configurazione storica.
Dataset finale	experiments/dpo_pdf_600/data/dataset_consegna/	Coppie, snapshot, provenienza e controlli strutturali.
Sviluppo e test	experiments/dpo_pdf_600/data/	Prompt congelati e manifest di separazione.
Training	experiments/dpo_pdf_600/runs/	Manifest, metriche e cronologie dei sei run.
Risposte e giudizi	experiments/dpo_pdf_600/results/evaluation/	Record per condizione e riepilogo final_groq_v1.
Grafici della campagna	experiments/dpo_pdf_600/results/figures/	Diciotto figure, didascalie e hash degli input.
Demo	experiments/dpo_pdf_600/demo/	Interfaccia, gestione dei modelli e recupero live.

B.2 Fonti documentali e perimetro delle verifiche

Le fonti di training comprendono Astrofisica per ansiosi, Astronomy 2e di OpenStax, Black Holes, Wormholes & Time Machines, il materiale identificato come George's Secret Key, I buchi neri di Alessandro Marconi e Stelle, pianeti e galassie. Lo sviluppo usa Exploring Black Holes, le note di relatività generale di Sean Carroll e Prospettive cosmiche. Il test usa Cosmology di David Tong, Dal Big Bang ai buchi neri, Death by Black Hole e le lezioni sulle onde gravitazionali di Alessandra Buonanno.

La relazione descrive il periodo documentale dal 1 ottobre 2025 allo snapshot esaminato l'11 novembre 2026; questa ultima data non viene attribuita all'esecuzione dei training. Il testo si basa su codice, documentazione e risultati salvati. I conteggi del corpus e i riepiloghi sono quelli ricostruiti nella relazione di partenza; la presente revisione ne riorganizza l'esposizione senza introdurre nuove misure. Non sono stati rieseguiti training, scraping, generazioni o giudizi automatici.

La costruzione dei dati e la redazione sono assistite da IA. I controlli strutturali e la verifica del documento non equivalgono a una validazione scientifica indipendente. Le configurazioni adottate non vengono dichiarate ottimali in assenza di ablazioni dedicate.

Riferimenti bibliografici

[1] Lewis et al. (2020), *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.* https://arxiv.org/abs/2005.11401

[2] Rafailov et al. (2023), *Direct Preference Optimization: Your Language Model is Secretly a Reward Model.* https://arxiv.org/abs/2305.18290

[3] Dettmers et al. (2023), *QLoRA: Efficient Finetuning of Quantized LLMs.* https://arxiv.org/abs/2305.14314