Indice

1 Obiettivi e perimetro **3**
1.1 Metodo di ricostruzione . . . 3

2 Principi e scelte progettuali **3**
2.1 Separare conoscenza, istruzioni e apprendimento . . . 3
2.2 Perché studiare il DPO . . . 4
2.3 Perché usare adattatori quantizzati . . . 4

3 Il sistema RAG originale **4**
3.1 Dai documenti a un indice interrogabile . . . 4
3.2 Recupero in due stadi . . . 5
3.3 Architettura complessiva e confini dell'esperimento . . . 5
3.4 Corpus, copertura e granularità dei metadati . . . 6
3.5 Parsing: formule, OCR e limiti delle conversioni . . . 7
3.6 Pulizia e chunking: cosa viene conservato e cosa può andare perso . . . 7
3.7 Indicizzazione, deduplicazione e aggiornamento . . . 7

4 Valutazione del retrieval e motivazioni quantitative **8**
4.1 Dalla query ai passaggi da inserire nel prompt . . . 8
4.2 Riferimento silver e significato delle metriche . . . 9
4.3 Ablazioni e risultati . . . 9
4.4 Eterogeneità e limiti del benchmark IR . . . 10

5 Generazione e primo allineamento **11**
5.1 Il ruolo di RAGGenerator e dei guardrail . . . 11
5.2 Le versioni DPO già presenti . . . 11
5.3 Composizione del prompt e tracciabilità della risposta . . . 11
5.4 Guardrail, leggibilità e adattamento . . . 12

6 Evoluzione sperimentale e scelte riviste **12**
6.1 Dalla raccolta RLAIF alla diagnosi dei confondimenti . . . 12
6.2 Perché la prima valutazione non sostiene la conclusione finale . . . 12
6.3 Errori di memoria e motivazioni del nuovo protocollo . . . 13

7 Costruzione delle 600 coppie **13**
7.1 Provenienza, numerosità e criterio di preferenza . . . 13
7.2 Esempio tratto dal dataset . . . 14
7.3 Controlli e limiti dei dati . . . 14
7.4 Struttura delle coppie e dipendenze fra esempi . . . 14
7.5 Esempi indipendenti e rischio di contaminazione . . . 15

8 Training e diagnostica dell'ottimizzazione **15**
8.1 Obiettivo di preferenza e significato dei reward . . . 16
8.2 Dove si collocano gli adattatori . . . 17
8.3 Lunghezze e compatibilità fra famiglie . . . 17

9 Protocollo del test e ruolo del giudice **18**
9.1 Un test distinto dallo sviluppo . . . 18
9.2 Confronto appaiato Base/DPO . . . 18
9.3 Valutazione automatica e ripresa dei lavori . . . 19
9.4 Rubrica, anonimizzazione e conservazione dei giudizi . . . 19

9.5 Che cosa controlla il confronto e che cosa lascia aperto 19

10 Risultati sulla correttezza **19**

11 Adeguatezza didattica e completezza **20**
11.1 Valori numerici delle dimensioni qualitative 21

12 Brevità ed esempi delle risposte **21**
12.1 Un errore eliminato, ma meno spiegazione 22
12.2 Un'omissione che il voto C non riassume 22

13 Incertezza e costo computazionale **22**
13.1 Confronti appaiati, lunghezza e intervalli 23

14 Interfaccia e organizzazione del codice **24**
14.1 Una demo utilizzabile del tutor 24
14.2 Perché demo e test restano distinti 24

15 Motivazioni delle scelte e alternative non dimostrate **24**
15.1 Riproducibilità e perimetro della verifica 25

16 Discussione e conclusioni **26**
16.1 Che cosa dimostra il lavoro 26
16.2 Limiti e sviluppi motivati dai risultati 26
16.3 Bilancio rispetto agli obiettivi iniziali 26

17 Appendice: diagnostica completa e lettura dei grafici **27**
17.1 Accuratezza delle preferenze 27
17.2 Margine rispetto al riferimento 27
17.3 Norma dei gradienti 27
17.4 Reward impliciti dei due completamenti 27
17.5 Learning rate effettivo 29
17.6 Distribuzione completa C/P/I 29
17.7 Correttezza distinta per profilo 31
17.8 Preferenze derivate dai voti 31
17.9 Raggiungimento del limite di output 31
17.10 Transizioni appaiate fra giudizi 31
17.11 Variazioni per argomento 31

18 Riferimenti e provenienza dei dati **34**
18.1 Fonti teoriche 34
18.2 Mappa degli artefatti verificabili 35

AstroTutor — Relazione tecnica completa

Periodo documentale: 01/10/2025–11/11/2026

Sintesi

AstroTutor è un prototipo di assistente didattico che risponde a domande di astronomia utilizzando una raccolta documentale e un livello scolastico indicato dall'utente. Il problema affrontato non è soltanto produrre una risposta plausibile, ma conciliare correttezza, pertinenza e comprensibilità rispetto ai prerequisiti dello studente. Una spiegazione formalmente corretta può infatti risultare troppo tecnica per un bambino o troppo generica per uno studente universitario.

Il progetto combina **Retrieval-Augmented Generation (RAG)**, per fornire al modello brani pertinenti, e **Direct Preference Optimization (DPO)**, per modificarne il comportamento attraverso confronti fra risposte preferite e rifiutate. La prima implementazione comprendeva già indicizzazione, ricerca, generazione, guardrail e allineamento di Qwen 3B. La fase successiva ha approfondito soprattutto la tracciabilità e la valutazione, fino a un confronto controllato su sei modelli.

La campagna finale utilizza 600 coppie sintetiche derivate dai PDF e un test separato di 20 domande, ripetute a quattro livelli. Le 960 risposte Base/DPO sono state valutate automaticamente con una rubrica comune. Il DPO aumenta il numero di risposte corrette in cinque modelli su sei, ma non migliora uniformemente l'adeguatezza didattica e tende a ridurre la lunghezza. Il risultato principale è quindi un **beneficio condizionato alla dimensione di qualità osservata**, non una conferma generale dell'utilità o inutilità della tecnica.

1 Obiettivi e perimetro

R1. Il DPO migliora la correttezza delle risposte rispetto allo stesso modello iniziale, a parità di contesto e condizioni di generazione?

R2. Il miglioramento, quando presente, riguarda anche completezza e adattamento al livello?

R3. L'effetto si ripete su famiglie e dimensioni differenti, oppure dipende dal modello?

R4. È possibile realizzare e mostrare l'intero prototipo su hardware locale con memoria limitata?

1.1 Metodo di ricostruzione

Le pagine seguenti descrivono i concetti, la pipeline originale, le modifiche, i dati, il protocollo e i risultati. L'analisi distingue tre oggetti: il sistema RAG completo, il test controllato della generazione e la demo Streamlit. I risultati del secondo non equivalgono a una validazione complessiva del primo, né a una misura dell'apprendimento degli studenti.

La relazione è basata sul codice e sui file salvati, non su nuove esecuzioni dei training. La provenienza sintetica dei dati e l'assenza di revisione umana indipendente vengono dichiarate come limiti del lavoro.

2 Principi e scelte progettuali

2.1 Separare conoscenza, istruzioni e apprendimento

Un modello linguistico può rispondere usando quanto appreso nel pretraining, ma questa conoscenza non coincide necessariamente con i documenti selezionati per il corso. AstroTutor introduce un contesto esterno: la domanda viene confrontata con il corpus e i brani recuperati sono inseriti nel prompt. Il RAG rende così esplicito il materiale su cui costruire la risposta e

consente di mostrarlo allo studente. Il paradigma collega una componente di recupero a una di generazione [1].

Il prompt definisce invece il compito: rispondere in italiano, usare il contesto e rispettare il livello. Cambiare il prompt non modifica i pesi del modello. Questa semplicità lo rende una baseline necessaria: un eventuale training deve dimostrare un beneficio aggiuntivo rispetto a un modello già istruito in modo adeguato. Un buon risultato della baseline non rende il progetto banale; rende più esigente la domanda sperimentale.

Tabella 1: Confronto tra le diverse tecniche di condizionamento e loro ruolo in AstroTutor

Tecnica	**Informazione utilizzata**	**Ruolo in AstroTutor**
RAG	Brani pertinenti recuperati dai documenti	Fornisce evidenza e limita il campo della risposta.
Prompting	Istruzioni, domanda e profilo dello studente	Specifica il comportamento desiderato in inferenza.
SFT	Esempi di risposte desiderate	È stato esplorato nei pilot, non nel confronto finale a sei modelli.
DPO	Preferenza fra chosen e rejected sullo stesso prompt	È l'intervento studiato nella campagna finale.

2.2 Perché studiare il DPO

Il DPO ottimizza direttamente le preferenze rispetto a un modello di riferimento, senza addestrare separatamente un reward model [2]. In una coppia il prompt è identico: cambia la risposta. Il segnale di training indica quale delle due debba essere favorita. Il vantaggio pratico per questo progetto è poter descrivere un comportamento desiderato anche attraverso esempi negativi, anziché fornire soltanto risposte da imitare.

La tecnica, però, apprende il criterio effettivamente rappresentato nei dati. Se una risposta è preferita perché corretta e l'altra è falsa, il segnale riguarda soprattutto la correttezza. Per isolare l'adattamento didattico servirebbero anche coppie entrambe corrette e pertinenti, ma diverse per prerequisiti, spiegazione dei termini e profondità. Questa distinzione è decisiva nell'interpretazione del dataset finale.

2.3 Perché usare adattatori quantizzati

La memoria della GPU locale è limitata a circa 8 GB. Con QLoRA il modello di base è mantenuto quantizzato e congelato, mentre si aggiornano piccoli adattatori LoRA [3]. Nella campagna sono stati utilizzati NF4, doppia quantizzazione e calcolo BF16. La scelta rende praticabile il training locale; non elimina la necessità di controllare memoria, lunghezze e compatibilità dei tokenizer.

3 Il sistema RAG originale

3.1 Dai documenti a un indice interrogabile

La raccolta combina PDF di astronomia e contenuti divulgativi. Il livello del materiale è importante perché una fonte per la scuola primaria e un testo universitario possono trattare lo stesso tema con prerequisiti molto diversi. I metadati conservano titolo, provenienza, argomento e difficoltà, così da poter usare queste informazioni durante il recupero e mostrare la fonte della risposta.

Il parsing dei PDF è affidato a Docling; i moduli di acquisizione gestiscono anche fonti divulgative come Vikidia ed EduINAF. Il testo estratto viene pulito e suddiviso in porzioni, dette *chunk*. Il file **chuncking.py** combina separazione per titoli Markdown e suddivisione ricorsiva: la configurazione letta prevede 1.500 caratteri, sovrapposizione di 200 e scarto dei frammenti inferiori a 150 caratteri. Sono caratteri, non token del modello.

La suddivisione cerca un equilibrio: un frammento troppo breve perde il contesto; uno troppo lungo può mescolare informazioni e occupare spazio nel prompt. La sovrapposizione riduce il rischio di spezzare completamente un concetto al confine. Queste scelte non assicurano automaticamente qualità scientifica: refusi, semplificazioni e ambiguità del documento possono rimanere nei brani.

3.2 Recupero in due stadi

I chunk sono trasformati in vettori con **BAAI/bge-m3** e salvati in **ChromaDB**. La ricerca iniziale seleziona candidati semanticamente vicini alla domanda. Un secondo modello, **BAAI/bge-reranker-v2-m3**, valuta direttamente coppie domanda–brano e riordina i candidati. Il primo stadio restringe il campo; il secondo affina l'ordinamento prima della generazione.

La classe **AdvancedRetriever** accetta più varianti della domanda: nella pipeline originale possono essere usate la formulazione italiana e quella tradotta. I documenti duplicati vengono rimossi. Il filtro ammette il livello richiesto e livelli vicini; un bonus di 0,5 favorisce, a parità di pertinenza, la corrispondenza esatta. Il fallback evita che l'assenza di materiale di un livello renda impossibile rispondere, ma richiede al generatore di adattare il testo.

Tabella 2: Filtro sui livelli documentali ammessi per ciascun profilo studente

Livello richiesto	**Livelli documentali ammessi**	**Significato**
A · primaria	A, B	Evita l'uso diretto di testi universitari.
B · medie	B, A, C	Consente fonti vicine ai prerequisiti.
C · superiori	C, B, D	Ammette approfondimenti da semplificare.
D · università	D, C	Privilegia fonti avanzate, con fallback.

La documentazione della ricostruzione registra un indice di 16.874 testi unici. Il conteggio sui file correnti è approfondito di seguito; il controllo di completezza resta distinto dalla qualità del recupero.

3.3 Architettura complessiva e confini dell'esperimento

Il sistema separa una fase offline, che rende interrogabili i documenti, una fase di apprendimento, che produce gli adattatori, e una fase online, che risponde a una domanda. Questa separazione è fondamentale: ricostruire l'indice non addestra il generatore; addestrare un adattatore non aggiorna automaticamente il corpus; interrogare la demo non aggiunge osservazioni alla valutazione scientifica. Gli schemi di questa relazione sono ricostruzioni del flusso implementato, non misure sperimentali aggiuntive.

L'unità documentale viene prima convertita in testo con metadati, poi frammentata e infine rappresentata nello spazio vettoriale. A runtime, la domanda e il livello selezionato guidano la ricerca; il generatore riceve soltanto i passaggi selezionati e le istruzioni. Il ramo DPO utilizza invece esempi statici con due possibili completamenti dello stesso prompt. Gli adattatori risultanti possono essere attivati o disattivati sul medesimo checkpoint iniziale, rendendo possibile un confronto appaiato.

Il progetto non implementa un sistema che stimi continuamente la competenza dello studente. I quattro livelli sono profili dichiarati, non stati cognitivi inferiti dal dialogo. Anche la cronologia

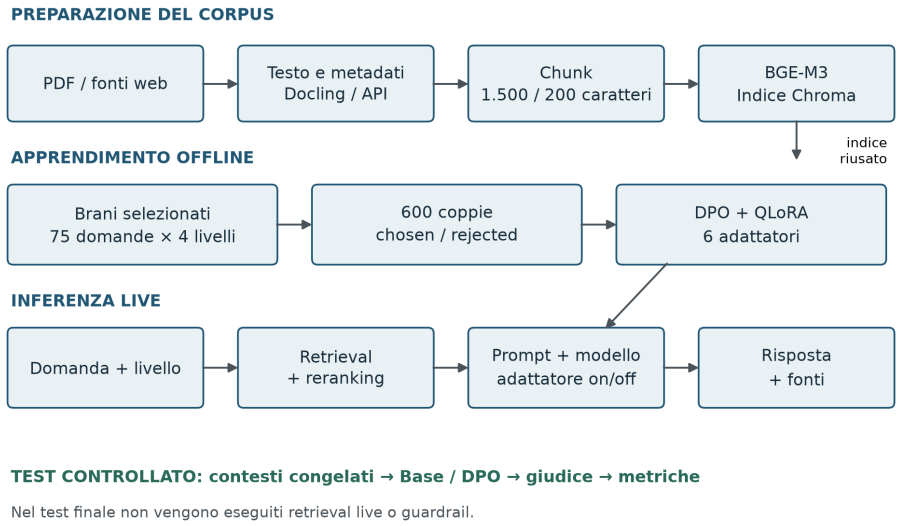


Figura 1: Architettura complessiva: preparazione documentale, apprendimento delle preferenze e inferenza live. Il test finale bypassa il retrieval e usa contesti congelati.

della demo serve a consultare le interazioni precedenti: non viene usata come memoria conversazionale nella domanda successiva. L'aggettivo adattivo riguarda quindi il condizionamento esplicito della spiegazione rispetto al profilo.

3.4 Corpus, copertura e granularità dei metadati

La ricognizione dei file presenti al momento della relazione conta 82 file di chunk, 17.976 righe e 16.874 testi distinti. La differenza di 1.102 righe rappresenta ripetizioni testuali rispetto al conteggio unico, non necessariamente 1.102 documenti duplicati. Il numero dei file di chunk non va confuso con quello dei PDF: il corpus incorpora anche materiali acquisiti direttamente dal web. Il conteggio è stato ricalcolato sui JSONL disponibili, senza rigenerare gli embedding.

Tabella 3: Distribuzione delle righe di chunk per livello documentale nel corpus

Livello documentale	Righe di chunk	Quota del totale
A, primaria	252	1,40%
B, medie	4.330	24,09%
C, superiori	2.847	15,84%
D, università	10.547	58,67%

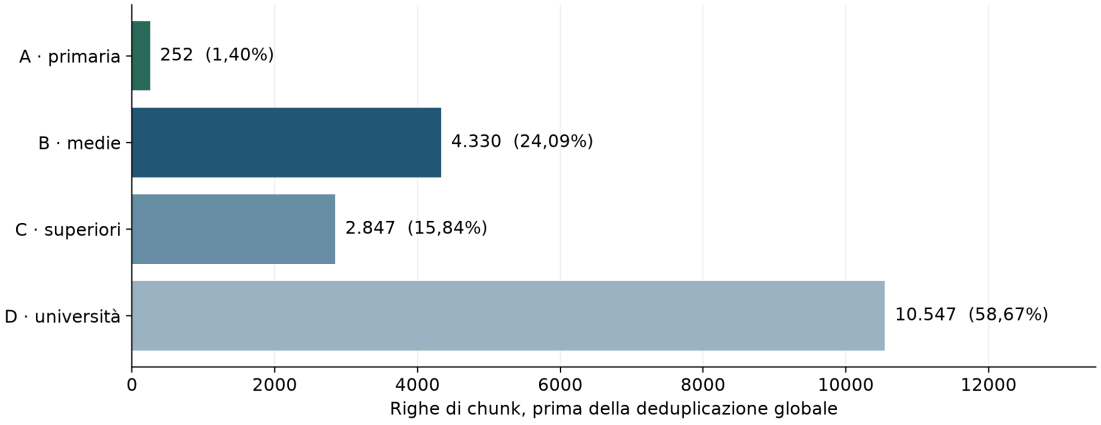


Figura 2: Distribuzione delle 17.976 righe del corpus per livello, prima della deduplicazione testuale globale. Conteggi ricalcolati dai file di chunk presenti.

La forte prevalenza del livello D spiega perché un filtro esatto fosse troppo restrittivo per

3.5 Parsing: formule, OCR e limiti delle conversioni

Docling viene configurato con OCR e arricchimento delle formule. L'OCR permette di recuperare testo da pagine rasterizzate; l'arricchimento cerca di rendere le formule utilizzabili nella rappresentazione testuale. Le opzioni non costituiscono una certificazione della correttezza di ogni simbolo. Un errore OCR può propagarsi al chunk, al retrieval, alla risposta e infine al giudizio automatico se la fonte viene trattata come infallibile.

La versione locale elabora blocchi di dieci pagine, usa due thread e un batch OCR di due elementi. Il motivo documentato è contenere i picchi di memoria osservati sui PDF lunghi. Sono presenti anche percorsi di elaborazione cloud e prove con MinerU; la sostituzione non è stata indiscriminata. Per Gravitation fu conservata l'estrazione Docling, ritenuta già adeguata nell'ispezione storica, evitando un nuovo parsing costoso senza un beneficio dimostrato. Il numero storico di formule estratte non viene assunto come una misura automatica di accuratezza.

Per Vikidia ed EduINAF, l'acquisizione si collega direttamente allo stadio del testo strutturato. Saltare l'OCR per contenuti già testuali evita calcolo superfluo e uniforma il successivo chunking. Le prove storiche comprendevano ulteriori siti e download automatici di PDF, ma la presenza di un tentativo nella progettazione non equivale a una fonte effettivamente utilizzata nella campagna finale.

3.6 Pulizia e chunking: cosa viene conservato e cosa può andare perso

La pulizia decodifica le entità HTML, elimina commenti e riferimenti alle immagini, estrae il testo con BeautifulSoup, ricongiunge alcune righe spezzate dal PDF e normalizza gli spazi. Segue lo split per titoli Markdown di primo, secondo e terzo livello; i blocchi ancora lunghi vengono suddivisi ricorsivamente con priorità a paragrafi, righe, punti e spazi. La soglia di 150 caratteri elimina frammenti spesso poco informativi, ma può escludere anche brevi definizioni utili: non è stato misurato un optimum di questa soglia.

La configurazione 1.500/200 è una scelta pratica di dimensione e sovrapposizione, non il risultato di una ricerca sistematica degli iperparametri. Il primo valore è un limite espresso in caratteri, non una garanzia di lunghezza tokenizzata uniforme. L'overlap attenua i confini artificiali all'interno dello splitting ricorsivo, ma non garantisce che una formula e la sua definizione rimangano sempre nello stesso chunk, soprattutto attraverso sezioni separate.

Un punto richiede precisione rispetto alle intenzioni iniziali: il codice corrente usa get_text sul contenuto HTML e non realizza una conversione strutturata delle tabelle HTML in tabelle Markdown. La geometria riga–colonna può quindi andare persa. Analogamente, la rimozione dei riferimenti alle immagini fa sì che diagrammi e figure dei PDF non siano interrogati come contenuto visivo. AstroTutor è, in questa implementazione, un sistema di recupero testuale; l'uso di un parser documentale non lo rende automaticamente multimodale.

3.7 Indicizzazione, deduplicazione e aggiornamento

Ogni testo è trasformato in embedding con BGE-M3 e inserito nella collezione persistente ChromaDB configurata per distanza coseno. L'identificativo è l'MD5 del testo; gli inserimenti avvengono tramite upsert. Testi identici possono quindi condividere un solo vettore anche se compaiono in più cartelle. La finalità è ridurre ridondanza e lavoro ripetuto, non fornire una firma crittografica della provenienza scientifica.

L'unicità testuale comporta un compromesso: un singolo record di metadati non rappresenta automaticamente tutte le provenienze di un passaggio ripetuto. Il controllo di riavvio verifica inoltre soltanto l'ID del primo chunk del file e, se lo trova, salta l'intero file. Questa euristica accelera le riprese ordinarie, ma non prova che ogni chunk successivo sia presente o aggiornato. Un'interruzione parziale o una modifica dopo il primo frammento richiedono un controllo di integrità esplicito. È quindi più preciso parlare di riuso dei risultati già presenti che di idempotenza completa garantita per ogni possibile stato.

Il sistema non implementa una fusione BM25+denso nella ricerca live. BM25 è una baseline della valutazione, mentre la produzione usa il ramo denso con reranking. La selezione di BGE-M3 è motivata dal corpus italiano/inglese e dall'esigenza di recuperare formulazioni semanticamente affini; non deriva, in questo progetto, da un confronto esaustivo fra tutti gli encoder disponibili.

4 Valutazione del retrieval e motivazioni quantitative

4.1 Dalla query ai passaggi da inserire nel prompt

La ricerca accetta una lista di varianti della domanda. Per ciascuna interroga ChromaDB sul pool ammesso dal livello, unisce i candidati, elimina i duplicati di testo e valuta ciascuna coppia domanda originale–passaggio con il cross-encoder. Il punteggio finale aggiunge 0,5 ai passaggi il cui livello corrisponde esattamente alla richiesta. La presenza del topic nei metadati non comporta un filtro per argomento: il recupero può attraversare categorie documentali.

L'ordine scritto nelle liste di fallback non viene applicato come una ricerca sequenziale. Il filtro $in ammette simultaneamente tutti i livelli della lista; il ranking successivo distingue soltanto corrispondenza esatta e fallback. Per B, per esempio, A e C sono entrambi ammessi e nessuna priorità supplementare impone di preferire A a C. Il bonus è un'euristica additiva, non una probabilità di correttezza né una soglia di sicurezza.

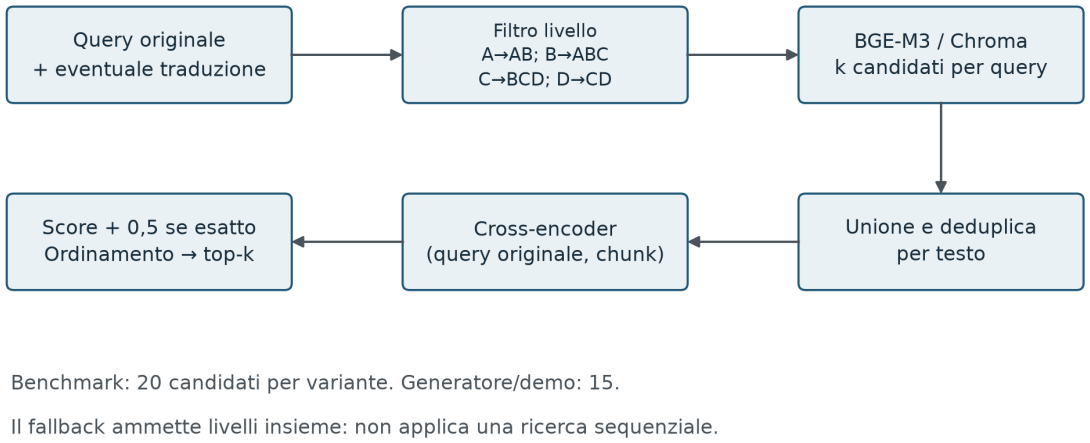


Figura 3: Struttura del recupero: filtro sul livello, ricerca densa, unione dei candidati, reranking sulla query originale e bonus per corrispondenza esatta.

Il retriever ha default di 20 candidati per variante e tre risultati finali; il generatore corrente e la demo lo invocano invece con 15 candidati. Il benchmark IR salvato utilizza 20. Con due varianti, prima della deduplicazione, il pool può arrivare rispettivamente a 40 o 30 elementi. La demo usa una sola query italiana e seleziona da una a tre fonti. Descrivere tutti questi percorsi come una sola configurazione nasconderebbe differenze effettive.

Nella pipeline originale la traduzione IT↔EN consente di ampliare le corrispondenze, soprattutto con terminologia scientifica. Nella valutazione del retrieval le traduzioni sono state generate una sola volta con Qwen 2.5 3B e conservate in cache, così ciascuna configurazione riceve lo stesso testo. La demo rinuncia invece alla traduzione: è una scelta di esecuzione del prototipo e non una replica della configurazione IR completa misurata.

4.2 Riferimento silver e significato delle metriche

Il riferimento comprende 172 query deduplicate per coppia domanda–livello: 40 A, 42 B, 35 C e 55 D. Deriva dagli esempi storici in cui è noto il file del chunk utilizzato per generare la domanda. Gli esempi topic-based, nei quali le fonti provengono dal retriever stesso, sono esclusi: usarli come verità di riferimento introdurrebbe una valutazione circolare.

Il risultato viene giudicato a granularità di documento. La lista dei chunk è collassata alla prima occorrenza di ogni documento, poi si individua il rango della fonte attesa. Con una sola fonte nota, Recall@k coincide con la frazione di query per cui quella fonte compare entro k; MRR media l'inverso del suo rango, con zero quando non compare entro la profondità considerata. nDCG@10 applica uno sconto logaritmico al rango entro dieci. Sono metriche appropriate al riferimento disponibile, ma non stimano esaustivamente tutte le fonti pertinenti.

La scelta documentale evita di penalizzare un chunk vicino a quello sorgente che risponde altrettanto bene. Introduce però un limite complementare: recuperare un passaggio poco utile del documento atteso può contare come successo. Inoltre, una fonte diversa ma valida non è necessariamente riconosciuta dal silver standard. La misura non va quindi descritta come percentuale di risposte corrette del tutor.

4.3 Ablazioni e risultati

Tabella 4: Risultati del benchmark di retrieval sulle 172 query per configurazione

Configurazione	R@1	R@3	R@5	R@20	MRR	nDCG@10
BM25	0,1802	0,2209	0,2442	0,2616	0,2058	0,2144
BM25 + expansion	0,3081	0,4360	0,5291	0,7151	0,4055	0,4470
solo bi-encoder	0,5756	0,7326	0,8256	0,8837	0,6742	0,7249
+ re-ranker	0,5233	0,7616	0,8314	0,8837	0,6511	0,7084
+ query expansion	0,5233	0,7674	0,8372	0,8953	0,6560	0,7131
+ bonus livello	0,5930	0,7965	0,8663	0,8953	0,7046	0,7515

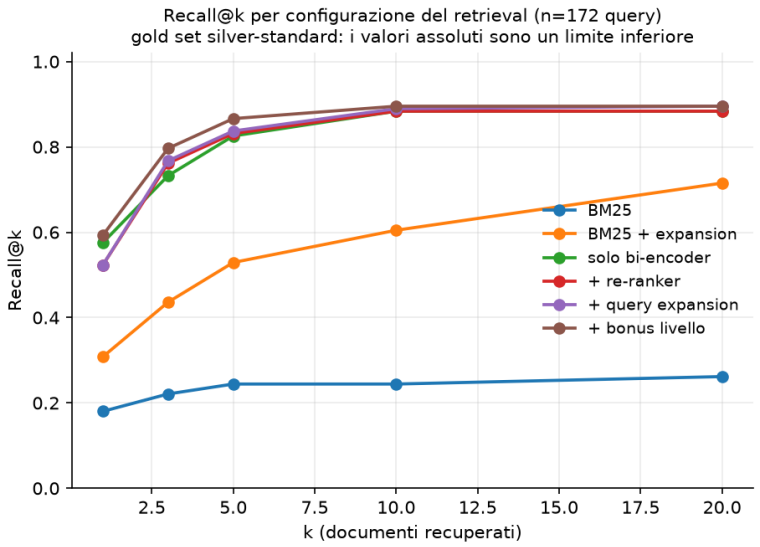


Figura 4: Recall a diverse profondità nelle sei configurazioni salvate. Il riferimento è documentale e comprende 172 query, non annotazioni esaustive di rilevanza.

Il passaggio da BM25 al solo bi-encoder porta Recall@3 da 0,2209 a 0,7326, una differenza descrittiva di circa 51,16 punti percentuali. BM25 con espansione raggiunge 0,4360: una parte del divario lessicale si riduce traducendo la query, ma il recupero denso rimane migliore in questo test. BM25 utilizza un indice invertito implementato nel progetto, con k1=1,5 e b=0,75; il filtro di livello è condiviso con gli altri bracci, mentre l'IDF è calcolata sul corpus complessivo.

Il reranker fa salire Recall@3 da 0,7326 a 0,7616, ma riduce Recall@1 da 0,5756 a 0,5233 e MRR da 0,6742 a 0,6511. Non è dunque corretto affermare che migliora tutte le metriche. Se il generatore usa tre passaggi, l'aumento a k=3 può essere pertinente alla scelta; se si desidera una sola fonte in testa, il peggioramento a k=1 merita attenzione. Nessuna misura di qualità della risposta, tuttavia, dimostra qui quale sia il compromesso migliore end-to-end.

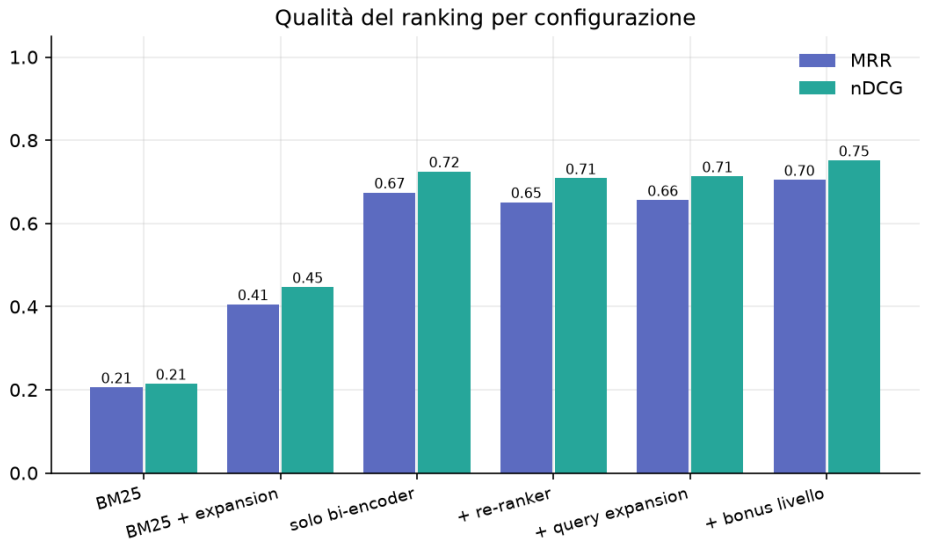


Figura 5: MRR e nDCG@10 del retrieval. L'effetto del reranking non è monotono: le due misure scendono nel passaggio dal solo bi-encoder al reranker.

L'espansione successiva al reranking aggiunge circa 0,58 punti a Recall@3. Il bonus di livello porta il valore da 0,7674 a 0,7965, circa 2,91 punti ulteriori, e restituisce MRR 0,7046 e nDCG@10 0,7515. Questi dati motivano il mantenimento del profilo documentale come informazione utile. Non dimostrano però che 0,5 sia il bonus ottimale: non sono salvate repliche con una griglia di pesi e un test indipendente di selezione.

Le sei righe non formano un'unica catena cumulativa in ogni passaggio: BM25 e BM25+\allowbreak{}espansio costituiscono il ramo lessicale; il passaggio al bi-encoder cambia il metodo di recupero. La sequenza cumulativa vera del ramo denso aggiunge reranking, espansione e bonus. Questa distinzione evita di leggere ogni differenza come l'effetto isolato dell'aggiunta di un solo componente a un sistema altrimenti identico.

4.4 Eterogeneità e limiti del benchmark IR

Nella configurazione completa Recall@3 è 0,700 per A, 0,857 per B, 0,714 per C e 0,873 per D. A e C rimangono i profili più deboli nella misura salvata. La distribuzione sbilanciata delle query e la loro provenienza sintetica limitano l'estensione delle conclusioni a domande reali degli studenti. La ricerca documentale e la capacità del generatore di adattare un passaggio recuperato sono due problemi diversi: il fallback risolve l'accesso a una fonte candidata, non prova che la fonte sia didatticamente appropriata.

Non sono stati rigenerati embedding o classifiche per questa relazione. I grafici IR rappresentano la campagna del 26 luglio 2026. Il conteggio attuale dei chunk è compatibile con il totale storico, ma da solo non dimostra identità completa dei testi e dei pesi dell'encoder: servirebbe la

verifica dei relativi snapshot e revisioni. Le metriche IR storiche non vengono quindi presentate come una nuova misura della demo corrente.

5 Generazione e primo allineamento

5.1 Il ruolo di RAGGenerator e dei guardrail

La classe **RAGGenerator** costruisce il prompt unendo domanda, contesto recuperato e istruzioni di livello. Nella versione originale la generazione avviene tramite Ollama e il modello predefinito è Qwen 2.5 3B. Il prompt impone di usare le fonti e prevede un rifiuto quando il contesto non contiene la risposta. Il livello non viene stimato dal sistema: è selezionato esplicitamente dall'utente.

ResponseGuardrails controlla aspetti come leggibilità, gergo, formule e lunghezza. Se rileva problemi può richiedere una nuova risposta. È quindi un controllo successivo alla generazione, non un meccanismo di apprendimento. Soprattutto, non è un verificatore scientifico: una risposta semplice e scorrevole può contenere un errore fisico e superare comunque questi controlli.

Questa distinzione spiega perché osservare soltanto la risposta finale può essere fuorviante. Un miglioramento potrebbe derivare dal modello, dal prompt, dai documenti recuperati o da una rigenerazione. Per attribuirlo al DPO occorre mantenere fissi gli altri componenti o almeno registrarne il comportamento.

5.2 Le versioni DPO già presenti

Il progetto originale non si limitava al prompting. La classe **TripletFactory** costruiva esempi di preferenza usando un modello "oracolo", configurato tramite Groq, e risposte rifiutate con problemi di registro, contenuto o pertinenza. Il lavoro storico comprende due versioni DPO di Qwen 3B, indicate nel confronto finale di luglio come 378 e 623 triplette. I modelli venivano addestrati con QLoRA/TRL, esportati in GGUF e usati tramite Ollama.

La valutazione originale considerava l'indice di leggibilità Gulpease, la fedeltà al contesto tramite RAGAS e il comportamento su domande fuori dominio. Il report del 26 luglio documenta differenze fra giudice locale e rivalutazione su Colab, oltre a un difetto nella metrica dei rifiuti. Questi elementi non consentivano una conclusione stabile sull'effetto dell'allineamento.

5.3 Composizione del prompt e tracciabilità della risposta

Nel prompt originale il system message contiene regole, stile e contesto; la domanda occupa il messaggio utente. I passaggi sono numerati e accompagnati dal titolo della fonte. Le regole chiedono di usare soltanto il contesto e di rifiutare quando è insufficiente. La richiesta non equivale a una garanzia di assenza di allucinazioni. È anche presente una tensione: il profilo A invita a usare analogie semplici, mentre la regola generale vieta analogie non presenti nel testo. Il generatore deve quindi soddisfare vincoli che possono restringere la libertà esplicativa proprio sul livello elementare.

Il percorso corrente produce un record con prompt, fonti, parametri, risposta originale, risposta finale e interventi correttivi. È possibile passare gli stessi documenti a modelli diversi senza ripetere il retrieval. L'assenza di documenti viene distinta dall'assenza di ricerca: un contesto fornito vuoto conduce al rifiuto imposto dalla pipeline, mentre la modalità senza RAG chiede di rispondere dalla conoscenza generale. Registrare se il modello sia stato effettivamente chiamato evita di attribuire al DPO un rifiuto deciso dal codice.

Il vecchio controllo basato su score inferiore a -5 era stato diagnosticato come inefficace nella scala osservata dei punteggi. Nel codice corrente letto per questa relazione quel controllo non compare nel percorso di generazione: il caso esplicito di rifiuto automatico è l'assenza di

documenti. Questo non introduce una soglia calibrata di answerability; un insieme non vuoto di passaggi può comunque non contenere la risposta.

5.4 Guardrail, leggibilità e adattamento

I guardrail originali controllano leggibilità Gulpease, lunghezza, formule e alcune espressioni di gergo, soprattutto per A e B. Le soglie storiche minime sono 55 per A e 45 per B. Il Gulpease combina lunghezza delle parole e delle frasi; non misura direttamente correttezza scientifica, qualità dell'analogia o comprensione da parte dello studente. Un valore universitario più basso non è un obiettivo pedagogico da massimizzare meccanicamente: una spiegazione rigorosa può e dovrebbe essere chiara.

La correzione corrente prevede al massimo una rigenerazione. La candidata sostituisce l'originale soltanto se il numero di problemi rilevati diminuisce; l'eventuale errore della rigenerazione viene registrato. Non è una dimostrazione che il contenuto sia migliorato: il criterio conta violazioni euristiche. La demo finale e il test congelato disabilitano questo passaggio, così i risultati Base/DPO non incorporano una seconda risposta scelta dal correttore.

Il metadato level_match distingue fonti esatte e di fallback nell'output del retriever, ma build_prompt non include una descrizione esplicita di tale distinzione. L'adattamento è affidato all'istruzione sul livello richiesto. Rendere visibile al generatore lo scarto tra livello della fonte e destinatario è un miglioramento possibile, da sottoporre a confronto anziché assumerne l'efficacia.

6 Evoluzione sperimentale e scelte riviste

6.1 Dalla raccolta RLAIF alla diagnosi dei confondimenti

La prima raccolta adottava un modello oracolo per costruire risposte preferite e un modello piccolo per produrre alternative rifiutate. Le strategie miravano a registro scorretto, allucinazione e domande fuori dominio. Questo schema riduceva il costo di annotazione manuale e cercava di esporre al training errori vicini a quelli del sistema effettivo. La scelta dell'oracolo API rispondeva anche alla lentezza delle generazioni con un modello più grande sull'hardware locale iniziale.

I due lati della preferenza avevano però autori diversi. Di conseguenza, il modello poteva distinguere lo stile dell'oracolo da quello del piccolo generatore senza imparare esclusivamente l'adattamento al livello. È un possibile confondimento, non una causa sperimentalmente isolata di tutti i risultati. Anche lunghezza, regolarità dei negativi e formulazione dei prompt potevano offrire scorciatoie. La presenza di un buon contrasto Gulpease nelle coppie non eliminava questi fattori.

Le versioni storiche da 378 e 623 coppie furono addestrate e convertite per Ollama tramite merge e GGUF. Questa distribuzione differisce dalla campagna finale, che mantiene checkpoint e adattatori separati in Transformers/PEFT. Le configurazioni LoRA storiche, più ampie, non descrivono gli adattatori finali: non devono essere mescolate in una sola tabella di iperparametri.

6.2 Perché la prima valutazione non sostiene la conclusione finale

La valutazione locale di luglio suggeriva medie di faithfulness crescenti, 0,679, 0,697 e 0,728 per Base, DPO 378 e DPO 623. Nella successiva valutazione Colab, con giudice Qwen 14B e generazione controllata, le medie diventavano rispettivamente 0,596, 0,556 e 0,566. All'interno della seconda campagna i contesti risultavano identici fra i bracci; nella prima non erano conservati in modo sufficiente a verificare il confronto.

Fra le due campagne cambiarono più fattori, inclusi giudice e generazioni. Non è possibile attribuire l'inversione alla sola severità del giudice o al solo retrieval. La conclusione sostenibile è che il primo ordinamento non costituiva evidenza stabile. I sei grafici storici relativi a quella

prima valutazione non sono usati qui come risultati conclusivi; sono conservati nelle fonti come documentazione della revisione metodologica.

Il conteggio OOD presentava inoltre un problema di definizione: cercava una frase canonica letterale. Un rifiuto semanticamente corretto ma parafrasato poteva essere classificato come fallimento. Nella verifica storica Colab, i conteggi letterali 9/20, 8/20 e 11/20 diventavano 18/20, 19/20 e 19/20 con la lettura semantica documentata. Si trattava in larga parte di conformità a un formato, non di una misura completa della qualità dei rifiuti. Il test finale a sei modelli non è una nuova valutazione OOD dedicata.

6.3 Errori di memoria e motivazioni del nuovo protocollo

Le prove iniziali incontrarono esaurimenti di memoria sia in training sia in evaluation, con particolare attenzione alla materializzazione dei logits e alla dimensione del batch. Il batch di evaluation non seguiva automaticamente quello di training. Furono introdotti checkpoint più frequenti per evitare che un errore durante la valutazione facesse perdere un'intera epoca. La lezione rilevante è distinguere memoria dei pesi, attivazioni, logits e stati dell'ottimizzatore: quantizzare i pesi non annulla tutti gli altri costi.

Successivamente furono esplorati pilot, inclusi percorsi SFT e SFT+DPO, prima di fissare la campagna finale. La documentazione consolidata ne registra l'esistenza, ma gli artefatti dei pilot non costituiscono qui un benchmark completo ricostruito. Non si riportano loro medie come risultati finali. Il confronto conclusivo resta Base contro DPO diretto, con dati e prompt congelati, sei modelli e giudizi salvati.

La motivazione metodologica del passaggio è ridurre il numero di cause che possono spiegare una differenza: stessi prompt, stessi contesti, stesso decoder entro ciascun confronto, adattatore disattivato o attivo. Si guadagna validità interna, al prezzo di escludere dal test errori di parsing, recupero e interazione. Per questo il nuovo esperimento integra la valutazione del sistema, senza sostituirsi a una prova end-to-end con studenti.

7 Costruzione delle 600 coppie

7.1 Provenienza, numerosità e criterio di preferenza

I primi tentativi di produzione automatica con generatori e giudici avevano una resa bassa: contesti inadatti, evidenze non trovate, risposte artificiali o coppie senza una preferenza chiara. I limiti API aumentavano il costo operativo. Il dataset finale è stato quindi costruito offline con assistenza IA a partire da concetti contenuti nei PDF. Non coincide con i candidati scartati né con un semplice ampliamento delle 623 triplette originali.

Sono stati selezionati 25 nuclei tematici da sei documenti di training, con tre domande per nucleo: **75 domande distinte**. Ogni domanda è proposta ai livelli A–D, ottenendo 300 prompt. Per ogni prompt sono presenti una risposta preferita e due risposte rifiutate, che producono **600 coppie DPO**, 150 per livello. Le 600 righe non rappresentano quindi 600 contenuti indipendenti.

Tabella 5: Struttura e funzione degli elementi che compongono ciascuna coppia di preferenza

Elemento	Contenuto e funzione
Prompt	Profilo, brano di riferimento e domanda; stesso input per chosen e rejected.
Chosen	Risposta pertinente, basata sul brano e formulata per il livello indicato.
Rejected fattuale	Contiene un errore intenzionale; 300 coppie.
Rejected fuori tema	Risposta tratta da un altro nucleo, allo stesso livello; 300 coppie.

7.2 Esempio tratto dal dataset

Domanda, livello A: «Perché non c'è un'eclissi di Luna a ogni Luna piena?»
Preferita: «Il percorso della Luna è inclinato: spesso la Luna piena passa sopra o sotto l'ombra della Terra.»
Rifiutata, errore intenzionale: «A ogni Luna piena si verifica necessariamente un'eclissi, perché l'orbita lunare non è inclinata rispetto a quella terrestre.»

La coppia mostra bene ciò che il modello può apprendere: favorire una spiegazione coerente con l'inclinazione dell'orbita rispetto a un'affermazione falsa. Non mostra, invece, una preferenza puramente didattica fra due spiegazioni corrette. Inoltre, negativi con errori evidenti o formule assolute possono rendere il compito relativamente facile e permettere scorciatoie stilistiche.

7.3 Controlli e limiti dei dati

Il pacchetto conserva chunk sorgente, percorsi, identificativi e offset dei brani, insieme ad hash e controlli di conteggio, unicità e separazione delle fonti. Gli offset si riferiscono ai chunk: non vengono inventati numeri di pagina. Alcuni contesti di training sono in inglese, mentre le risposte sono in italiano. I dati sono neutrali rispetto al tokenizer, così da applicare a ogni modello il proprio chat template.

Verificare che un brano sia presente nel corpus non significa validarne scientificamente ogni affermazione. La scrittura assistita e i controlli strutturali non sostituiscono una revisione indipendente. È disponibile anche un file SFT con le 300 risposte preferite deduplicate, ma non è stato usato come braccio della campagna finale.

7.4 Struttura delle coppie e dipendenze fra esempi

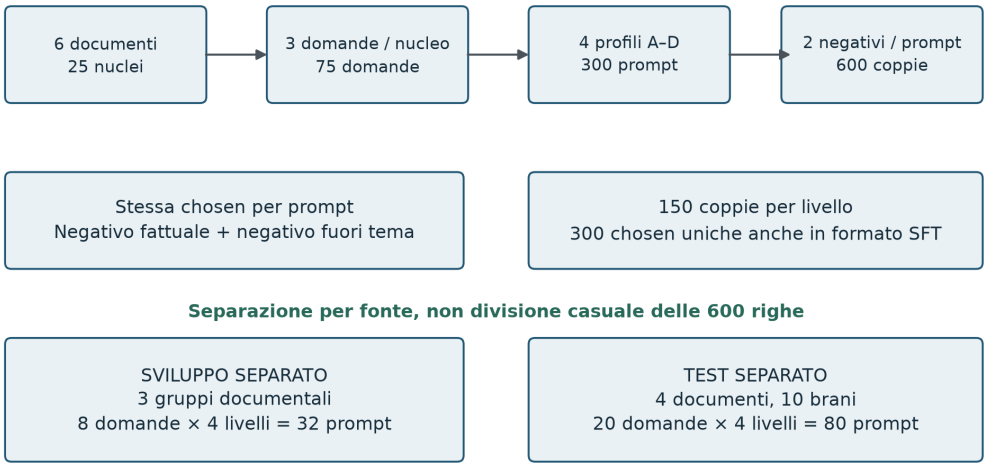


Figura 6: Costruzione del training e separazione dei dati: 25 nuclei, 75 domande, 300 prompt e 600 confronti. Il test deriva da quattro documenti distinti rispetto al training e allo sviluppo.

La versione A usa il testo semplice; B concatena testo semplice e spiegazione; C concatena testo preciso e spiegazione; D usa il solo testo preciso. La struttura deriva direttamente dal costruttore dei dati. Il livello D non è quindi ottenuto rendendo sempre la risposta più lunga: l'obiettivo dichiarato è maggiore precisione, e l'adeguatezza dipende anche dalla complessità della domanda. Questo meccanismo è trasparente e riproducibile, ma rende il registro meno ricco di quello di una raccolta aperta di spiegazioni scritte da docenti.

Le sei fonti di training comprendono Astrofisica per ansiosi, Astronomy 2e di OpenStax, Black Holes, Wormholes & Time Machines, il materiale identificato come George's Secret Key, I buchi neri di Alessandro Marconi e Stelle, pianeti e galassie. La presenza di materiale narrativo richiede selezione dei passaggi: un'affermazione di un personaggio non diventa una verità scientifica soltanto perché compare nel PDF. La campagna mantiene i riferimenti ai brani, senza dichiarare una revisione semantica indipendente che non è stata svolta.

I tre gruppi documentali dello sviluppo sono Exploring Black Holes, le note di relatività generale di Sean Carroll e Prospettive cosmiche. Il test usa invece Cosmology di David Tong, Dal Big Bang ai buchi neri, Death by Black Hole e le lezioni sulle onde gravitazionali di Alessandra Buonanno. La separazione è verificata sui gruppi di fonte: non garantisce assenza di sovrapposizione concettuale fra testi astronomici né assenza di tali testi nel pretraining dei modelli.

Il pacchetto di training contiene un file di provenienza allineato riga per riga alle coppie, uno snapshot dei chunk e intervalli di caratteri degli estratti. Il controllo di sottostringa certifica il collegamento al testo salvato; non certifica che l'OCR sia esatto o che ogni affermazione della fonte sia corretta. Gli hash permettono di rilevare modifiche agli artefatti, non di trasformare dati sintetici in annotazioni umane.

Le lunghezze medie registrate sono 21,92 parole per chosen e 19,89 per rejected. Questo contrasta con l'idea di trasferire automaticamente al dataset finale il vecchio schema "risposta preferita sempre più corta". Le risposte preferite finali restano comunque brevi in termini assoluti. L'ipotesi che il training favorisca risposte concise è compatibile con i risultati, ma l'attribuzione causale richiede coppie bilanciate e ablazioni controllate.

7.5 Esempi indipendenti e rischio di contaminazione

Una divisione casuale delle 600 righe sarebbe inadatta: la stessa domanda comparirebbe facilmente nel training e nella validation con un altro livello o un diverso negativo. La separazione per fonte e il congelamento del test sono scelte volte a ridurre questa contaminazione. Il training finale usa tutte le 600 coppie senza validation; i 32 prompt di sviluppo restano un insieme separato e non una curva di generalizzazione tracciata durante i run.

Per ogni modello, il test comprende 80 prompt, ma soltanto 20 domande su dieci brani. I quattro livelli della stessa domanda condividono gran parte dell'informazione; due domande possono riferirsi allo stesso brano e più brani allo stesso PDF. La numerosità viene perciò sempre dichiarata su più livelli: risposte, prompt, domande, brani e documenti. È questa struttura, non il numero più grande disponibile, a guidare l'interpretazione dell'incertezza.

8 Training e diagnostica dell'ottimizzazione

Sono stati addestrati Qwen 2.5 1.5B e 3B, SmolLM3 3B, Gemma 3 1B, Llama 3.2 3B e Mistral 7B v0.3. Includere più modelli permette di osservare se l'effetto persiste oltre il primo Qwen, ma non rende il confronto una misura isolata dell'architettura: cambiano dimensione, dati di pretraining e instruction tuning.

Tabella 6: Impostazioni comuni di addestramento DPO condivise tra i sei modelli

Impostazione comune	**Valore**
Dati e durata	600 coppie; 2 epoche; 300 step di ottimizzazione
DPO	Loss sigmoid; beta 0,1; modello iniziale come riferimento
Ottimizzazione	Learning rate costante 5×10^{-6}; seed 42
Batch	1 esempio per dispositivo; accumulo di 4 step
LoRA	Rank 8; alpha 16; dropout 0,0; proiezioni q/k/v/o

Impostazione comune	Valore
Memoria	NF4 con doppia quantizzazione; BF16; gradient checkpointing

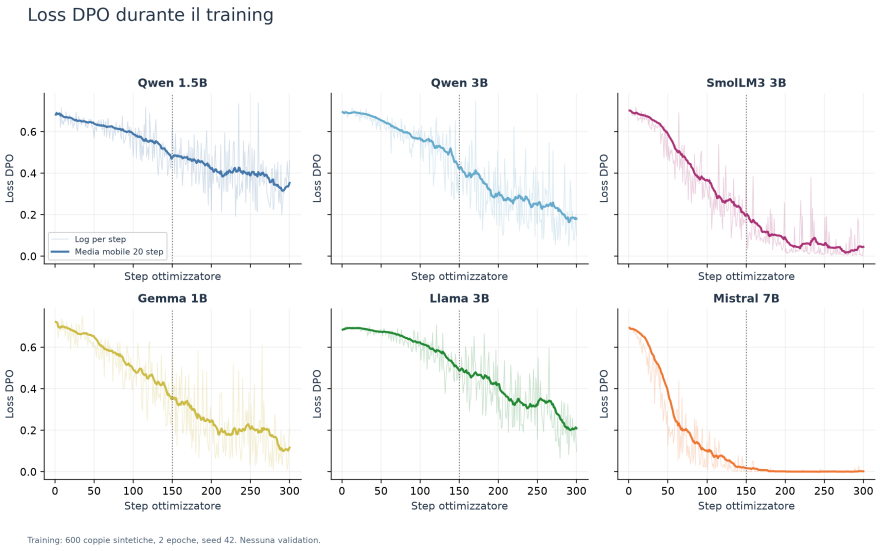


Figura 7: Loss registrata durante i sei training. Linee tenui: valori per step; linee piene: media mobile retrospettiva su 20 step. Il confine fra epoche è indicato verticalmente.

La loss diminuisce in tutti i run, indicando che l'obiettivo sulle coppie di training viene ottimizzato. Una loss molto bassa non dimostra però una spiegazione migliore su domande nuove. Può riflettere anche negativi facilmente distinguibili e ripetizione dei medesimi prompt. Non sono disponibili curve di validation per questa campagna: non si conclude quindi, dalla sola discesa, che il modello generalizzi o che non stia memorizzando.

Tokenizzazione e lunghezze sono state controllate per ciascuna famiglia. Gemma e Mistral richiedono l'unione dell'istruzione di sistema al primo messaggio utente; SmolLM3 usa la configurazione senza thinking. Le revisioni e le impostazioni effettive sono registrate nei manifest. Usare gli stessi iperparametri controlla una parte del confronto, ma non equivale a ottimizzarli per ogni modello.

8.1 Obiettivo di preferenza e significato dei reward

Nel training x indica il prompt, y+ la risposta preferita e y− quella rifiutata. La policy aggiornata viene confrontata con il modello di riferimento sulle medesime stringhe. La loss sigmoid usata dalla campagna si esprime come segue:

$$\mathcal{L}_{\text{DPO}} = -\mathbb{E}_{(x,y^+,y^-)\sim D}\left[\log \sigma\left(\beta\left[\log \frac{\pi_\theta(y^+ \mid x)}{\pi_{\text{ref}}(y^+ \mid x)} - \log \frac{\pi_\theta(y^- \mid x)}{\pi_{\text{ref}}(y^- \mid x)}\right]\right)\right]. \tag{1}$$

L'argomento della sigmoide aumenta quando migliora la preferenza relativa per y+ rispetto a y−, misurata contro il riferimento. Non impone che la probabilità assoluta della chosen cresca a ogni step: il margine può aumentare anche riducendo maggiormente la probabilità della rejected. I reward salvati sono trasformazioni delle log-probabilità rispetto al riferimento; non sono punteggi assegnati dal giudice della valutazione.

La reward accuracy misura quante coppie hanno margine positivo. Non è correttezza astronomica, né una stima di apprendimento degli studenti. Anche la normalizzazione rispetto al riferimento non dimostra l'assenza di bias di lunghezza o di scorciatoie: rimangono dipendenze

fra esempi, contenuto dei negativi e distribuzione delle risposte. La loss deve essere interpretata insieme alle generazioni su dati separati.

8.2 Dove si collocano gli adattatori

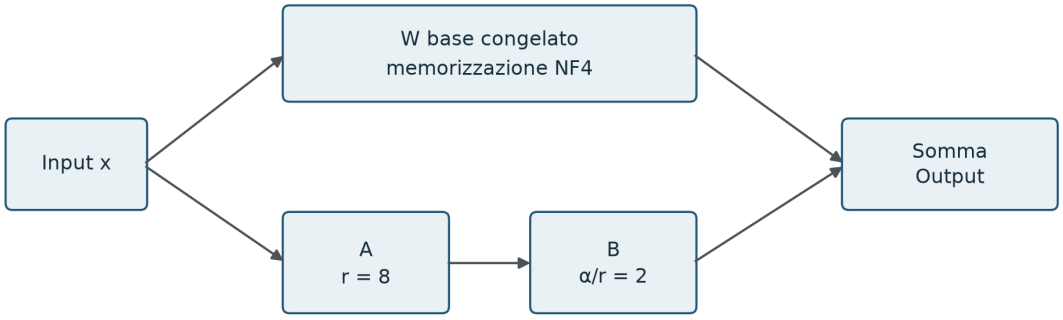


Figura 8: Schema funzionale di un adattatore LoRA su una proiezione: il percorso dei pesi congelati si somma alla correzione a basso rango. Nella campagna la correzione riguarda q, k, v e o dell'attenzione.

LoRA aggiunge una correzione a basso rango alle proiezioni selezionate. Qui rank 8 e alpha 16 determinano un fattore di scala alpha/r pari a 2, mentre dropout 0 evita quel tipo di rumore durante l'ottimizzazione. I target q/k/v/o corrispondono alle proiezioni query, key, value e output dell'attenzione. Non vengono aggiunti adattatori a tutte le proiezioni MLP come in alcune prove storiche. Il disegno è comune ai sei run, ma non è stato dimostrato che questa scelta sia ottimale per ogni architettura.

La quantizzazione NF4 conserva i pesi base a quattro bit; la doppia quantizzazione riduce il costo delle costanti di quantizzazione, mentre BF16 è usato per il calcolo. Gradient checkpointing riduce la memoria delle attivazioni ricalcolandone una parte durante il backward. Il precalcolo delle log-probabilità del riferimento evita di ripetere quel lavoro durante tutti gli step. Queste tecniche rispondono a costi diversi e sono complementari.

Il batch effettivo è quattro: un esempio per microbatch e quattro accumuli del gradiente. Con 600 coppie, si hanno 150 aggiornamenti per epoca e 300 in due epoche. Gli stessi prompt ricompaiono con due negativi; un aggiornamento non rappresenta quindi quattro domande necessariamente indipendenti. Sono registrati learning rate costante, nessun warmup, weight decay nullo e clipping del gradiente a 1. L'ottimizzatore finale è AdamW di PyTorch, non il paged optimizer usato in una configurazione storica.

8.3 Lunghezze e compatibilità fra famiglie

Tabella 7: Lunghezze di contesto, durata del training e VRAM allocata per modello

Modello	**Token min–max**	**max_length**	**Tempo, min**	**VRAM allocata, GiB**
Qwen 1,5B	250–502	510	31,13	1,743
Qwen 3B	250–502	510	17,38	2,848
SmolLM3 3B	287–542	550	15,43	2,700

Modello	Token min–max	max_length	Tempo, min	VRAM allocata, GiB
Gemma 1B	193–422	430	10,02	1,640
Llama 3B	270–525	533	15,15	3,237
Mistral 7B	267–548	556	46,05	4,949

Il margine fra massima lunghezza tokenizzata osservata e max_length è otto token in tutti questi manifest. I valori non devono essere copiati a un nuovo tokenizer senza controllo. I conteggi si riferiscono agli esempi di training con i template applicati, non al massimo contesto dichiarato dal modello o ai 384 token di output del test.

Gemma e Mistral uniscono il contenuto del system message al primo messaggio utente; Qwen e Llama usano i ruoli previsti dal proprio percorso e SmolLM3 disabilita il thinking. Questa normalizzazione evita di imporre un formato di chat non supportato. Rimane un fattore che differenzia le famiglie: uniformità del contenuto non significa identità dei token. Il confronto causale più pulito resta entro il singolo modello, dove il template è mantenuto fisso fra Base e DPO.

9 Protocollo del test e ruolo del giudice

9.1 Un test distinto dallo sviluppo

Il test comune è stato congelato prima della generazione finale. Comprende 20 domande, due per ciascuno di dieci nuclei, a quattro livelli: **80 prompt per modello**. Le quattro fonti documentali non appartengono al training o allo sviluppo. Gli argomenti possono sovrapporsi a quelli già trattati: si valuta il trasferimento a nuove domande e nuovi brani, non necessariamente a un dominio astronomico mai incontrato.

I contesti del test sono riformulazioni italiane dell'assistente, con conservazione degli estratti originali. La scelta uniforma la lingua e riduce refusi e passaggi estranei, ma introduce una mediazione sintetica che deve essere dichiarata. I punti di riferimento per il giudizio non vengono forniti al generatore. Il campione è piccolo e contiene anche quesiti di definizione o correzione di equivoci.

9.2 Confronto appaiato Base/DPO

Per ciascun prompt vengono prodotte due risposte sullo stesso modello quantizzato: una con adapter disattivato e una con adapter attivo. Restano uguali contesto, domanda, profilo e decoding greedy, con massimo 384 nuovi token e repetition penalty 1. Retrieval variabile e guardrail sono esclusi. Questo disegno riduce i fattori che potrebbero essere scambiati per un effetto del DPO, ma misura la generazione con contesto, non la pipeline RAG end-to-end.

Tabella 8: Dimensioni e criteri operativi della rubrica di valutazione automatica

Dimensione	Criterio della rubrica
Correttezza C/P/I	C: nucleo corretto senza errori sostanziali; P: parziale o ambiguo; I: nucleo errato o errore grave.
Completezza 0–2	Copertura degli elementi essenziali della domanda, senza pretendere ogni informazione del contesto.
Adeguatezza 0–2	Compatibilità di prerequisiti, termini spiegati e profondità con il livello.
Chiarezza 0–2	Comprensibilità, coerenza e assenza di contraddizioni.

9.3 Valutazione automatica e ripresa dei lavori

Le 960 risposte sono state valutate con **GPT-OSS 120B su Groq**, senza nomi del modello o della condizione. Otto duplicati identici associati allo stesso prompt riutilizzano il giudizio: le valutazioni uniche sono 952. Il salvataggio progressivo permette di riprendere dopo limiti API senza rigenerare le risposte già prodotte. Una prima prova locale con Qwen 7B è stata esclusa dopo giudizi problematici.

Il giudice fornisce voti e motivazioni, ma resta un modello e può sbagliare. I controlli elementari effettuati non ne certificano l'affidabilità sull'intero campione. Le preferenze complessive sono derivate dai voti, dando priorità a correttezza, poi completezza, adeguatezza e chiarezza: non costituiscono una seconda valutazione indipendente. È predisposto un campione cieco di 24 coppie, non ancora revisionato da una persona.

9.4 Rubrica, anonimizzazione e conservazione dei giudizi

Il giudice riceve domanda, livello, contesto, punti di riferimento e risposta, senza l'identità del modello o la condizione Base/DPO. Valuta ogni risposta separatamente. La correttezza distingue C, nucleo corretto senza errori sostanziali; P, parziale o ambiguo con imprecisioni rilevanti; I, nucleo errato o errore grave. Completezza, adeguatezza e chiarezza usano una scala ordinale 0–2. Non si richiede di copiare il riferimento né di includere ogni dettaglio del contesto.

La rubrica chiede inoltre di non premiare automaticamente lunghezza o tecnicismo, di segnalare aggiunte non sostenute e di dichiarare incertezza quando necessario. Un'aggiunta non presente nel contesto non è automaticamente falsa: per questo unsupported_addition è separato dalla correttezza. Le 960 risposte hanno 952 giudizi unici perché le risposte identiche sul medesimo prompt riutilizzano il giudizio. Non sono otto risposte perse.

Il primo tentativo con giudice locale Qwen 7B fu interrotto per giudizi considerati inaffidabili; i sei voti di quella prova non confluiscono nel riepilogo Groq. Il giudice finale conservato è openai/gpt-oss-120b, con temperatura zero. Le prove elementari di calibrazione e la conformità allo schema JSON non misurano da sole l'accordo con esperti su tutto il test. Il fatto che il riepilogo riporti zero giudizi uncertain non prova che tutti i giudizi siano corretti.

È stato predisposto un campione di 24 coppie per revisione umana, ma non risulta completata una validazione indipendente. Il termine "correttezza" nelle tabelle va pertanto letto come correttezza stimata dal giudice automatico conservato. Le risposte troncate o sospette non vengono escluse a posteriori, evitando di selezionare soltanto i casi favorevoli al modello.

9.5 Che cosa controlla il confronto e che cosa lascia aperto

La generazione usa greedy decoding, un solo beam, nessun campionamento, repetition penalty 1 e al massimo 384 nuovi token. Entrambe le condizioni mantengono NF4; Base è ottenuta disattivando l'adattatore sul medesimo modello caricato. Non vengono aggiunti guardrail o riscritture dopo la risposta. Questo isola l'intervento dell'adattatore nel contesto del protocollo, ma non misura la perdita dovuta alla quantizzazione rispetto a un modello non quantizzato.

I contesti italiani del test sono riformulazioni assistite dei documenti riservati, con gli originali conservati. Questo rende l'input uniforme e leggibile, ma riduce il rumore di estrazione che il sistema incontrerebbe con alcuni PDF reali. Il test è quindi una valutazione della generazione condizionata, non una prova completa del RAG né un confronto tra capacità di retrieval dei sei modelli.

10 Risultati sulla correttezza

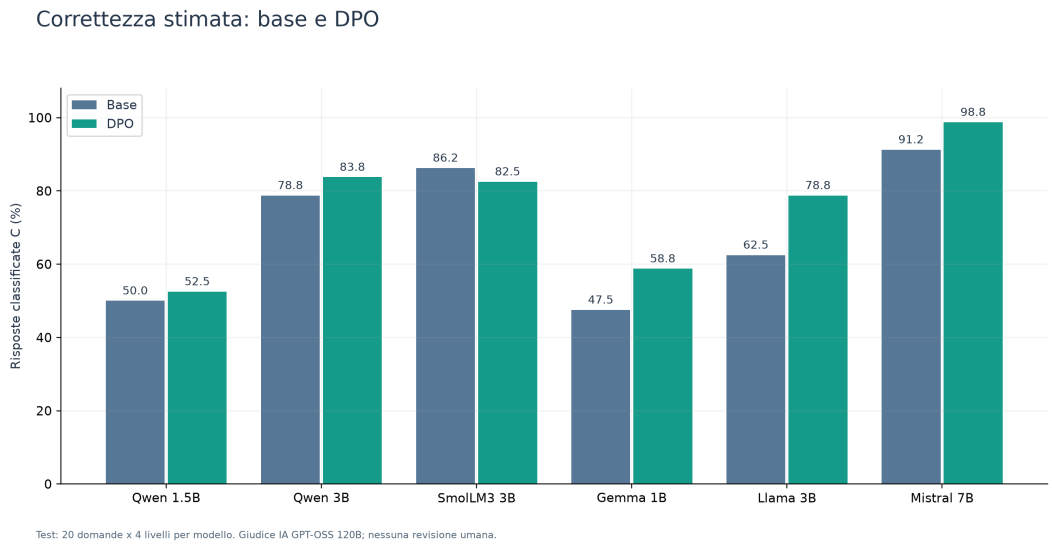


Figura 9: Risposte classificate C dal giudice automatico, su 80 per modello e condizione. La percentuale rappresenta il campione osservato, non una probabilità generale di correttezza.

Tabella 9: Risultati sulla correttezza stimata (voti C ed I) prima e dopo l'intervento DPO

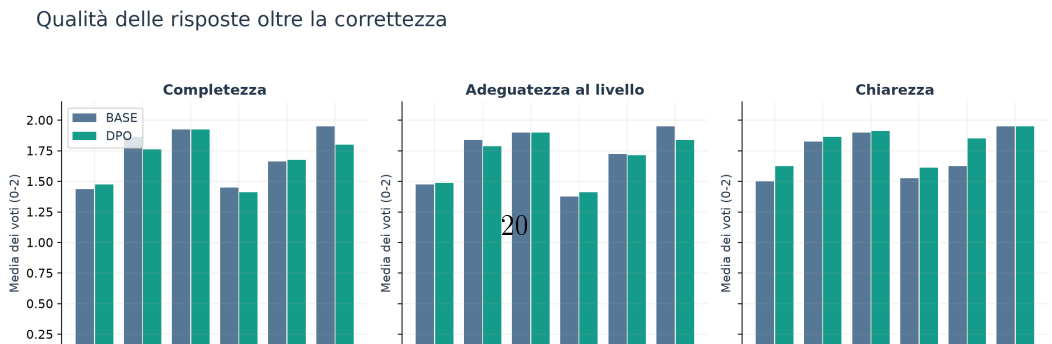
Modello	**C base → DPO**	**Delta p.p.**	**I base → DPO**
Qwen 2.5 1.5B	40 → 42	+2.50	18 → 20
Qwen 2.5 3B	63 → 67	+5.00	8 → 0
SmolLM3 3B	69 → 66	-3.75	3 → 3
Gemma 3 1B	38 → 47	+11.25	20 → 14
Llama 3.2 3B	50 → 63	+16.25	12 → 6
Mistral 7B v0.3	73 → 79	+7.50	2 → 0

Il conteggio delle risposte corrette aumenta in cinque modelli su sei. **Llama 3.2 3B** mostra il maggiore incremento assoluto: 13 risposte C in più, pari a 16,25 punti percentuali. **Gemma** guadagna nove risposte, mentre **Mistral**, già elevato nella condizione iniziale, passa da 73 a 79. SmolLM3 è l'eccezione: perde tre risposte C e passa da 86,25% a 82,50%.

Per **Qwen 3B** il beneficio è particolarmente visibile nella categoria I, che scende da otto a zero; non tutte le risposte diventano però pienamente corrette, perché aumentano anche le parziali. In **Qwen 1.5B** aumentano sia C sia I, a scapito di P. Guardare soltanto la prima colonna avrebbe nascosto questa regressione. Il dato va quindi letto come distribuzione della qualità, non come una sola classifica.

Aggregando descrittivamente i sei modelli, C passa da 333 a 364 su 480 risposte per condizione. Il totale non equivale a 480 domande indipendenti: gli stessi quesiti e brani vengono riutilizzati. Inoltre, un modello con punteggio iniziale alto dispone di un margine di crescita minore. Il confronto più informativo resta quello appaiato entro ciascun modello.

11 Adeguatezza didattica e completezza



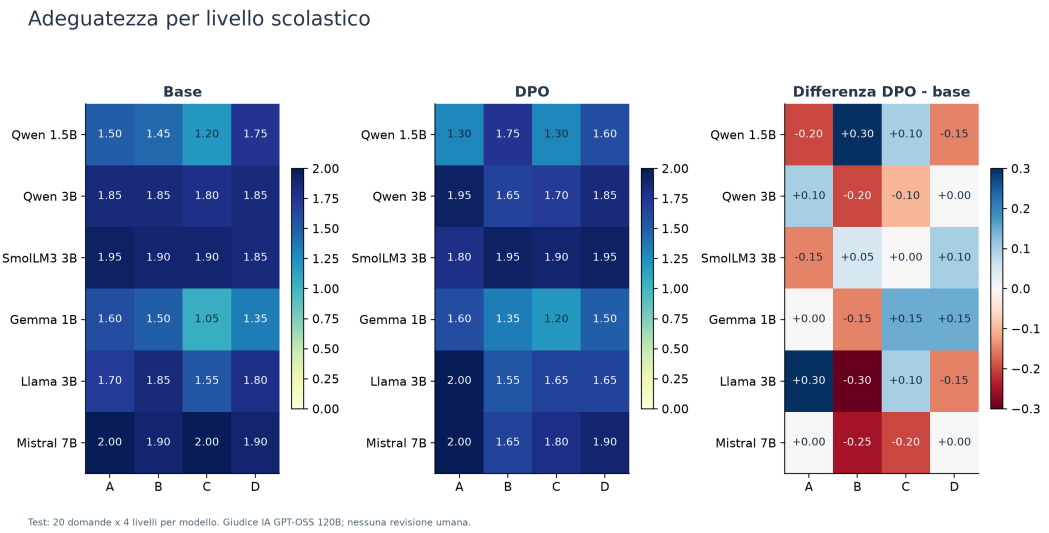


Figura 11: Adeguatezza distinta per livello e variazione dopo DPO. Ogni cella contiene soltanto 20 risposte; la mappa serve a localizzare differenze che la media generale nasconde.

Per esempio, in **Llama** il livello A passa da 1,70 a 2,00, mentre B scende da 1,85 a 1,55 e D da 1,80 a 1,65. In **Qwen 3B** A migliora da 1,85 a 1,95, ma B passa da 1,85 a 1,65. Non esiste dunque un unico effetto "sul livello": lo stesso training può favorire alcune condizioni e penalizzarne altre.

Il caso **Mistral** evidenzia il compromesso: C aumenta fino a 79/80, ma completezza e adeguatezza medie scendono rispettivamente da 1,95 a 1,80 e da 1,95 a circa 1,84. Secondo la regola di preferenza derivata, il DPO vince solo sette confronti contro 21 del base, con 52 parità. Correttezza aggregata e preferenza complessiva non sono quindi indicatori intercambiabili.

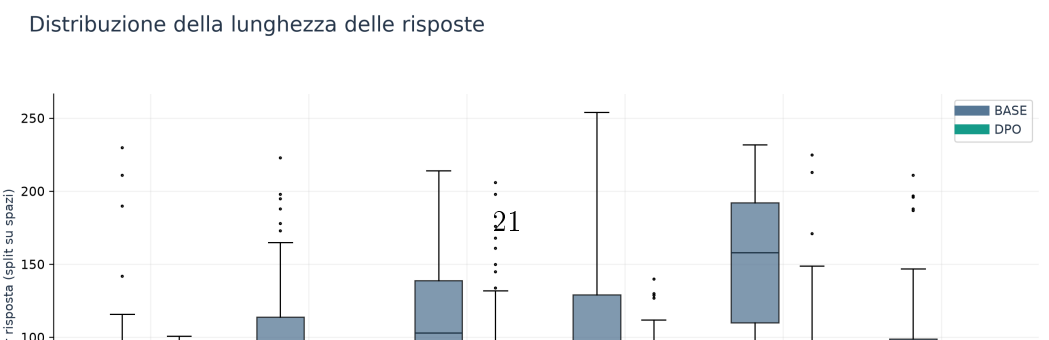
11.1 Valori numerici delle dimensioni qualitative

Nella tabella B→D indica Base→DPO, non il passaggio fra livelli scolastici. I voti sono medie descrittive sulla scala ordinale 0–2, arrotondate a tre decimali; ogni condizione comprende 80 risposte.

Tabella 10: Punteggi medi per le dimensioni qualitative di completezza, adeguatezza e chiarezza

Modello	Completezza B→D	Adeguatezza B→D	Chiarezza B→D
Qwen 1.5B	1,438 → 1,475	1,475 → 1,488	1,500 → 1,625
Qwen 3B	1,863 → 1,762	1,837 → 1,788	1,825 → 1,863
SmolLM3	1,925 → 1,925	1,900 → 1,900	1,900 → 1,913
Gemma 1B	1,450 → 1,413	1,375 → 1,413	1,525 → 1,613
Llama 3B	1,663 → 1,675	1,725 → 1,712	1,625 → 1,850
Mistral 7B	1,950 → 1,800	1,950 → 1,837	1,950 → 1,950

12 Brevità ed esempi delle risposte



anche perdere passaggi necessari. Il comportamento osservato è compatibile con questa interpretazione, senza dimostrarne la causa: non è stata eseguita un'ablazione che separi preferenza per correttezza e preferenza implicita per brevità.

12.1 Un errore eliminato, ma meno spiegazione

Nel prompt **test03_D**, sul gas vicino ai buchi neri, Qwen 3B base aggiunge che la trasformazione avviene «solo quando il gas si avvicina troppo al buco nero, oltre l'orizzonte degli eventi». Il giudice assegna I. Dopo DPO la risposta diventa: «L'energia potenziale gravitazionale può essere convertita in calore e radiazione durante l'accrescimento del gas che si avvicina al buco nero.» Il giudizio passa a C, mentre la completezza scende da 2 a 1 e l'adeguatezza rimane 1.

Questo caso documenta la rimozione di un'affermazione problematica, non il raggiungimento di una spiegazione universitaria completa. È un esempio scelto per illustrare il compromesso, non una stima rappresentativa di tutti i casi.

12.2 Un'omissione che il voto C non riassume

In **test01_A**, Mistral base spiega che l'infrarosso attraversa le nubi con attenuazione minore rispetto al visibile. La risposta DPO conserva il riferimento all'emissione infrarossa della polvere, ma omette quel passaggio. Entrambe sono classificate C dal giudice, mentre la completezza passa da 2 a 1. La motivazione salvata permette di capire la perdita che la sola correttezza binaria non mostrerebbe.

Queste valutazioni sono riportate come giudizi automatici conservati, non come validazione esperta delle singole frasi. Anche la coerenza fra motivazione e punteggio merita revisione umana. Sono state mantenute nel test tutte le risposte, comprese quelle al limite: i casi segnalati passano complessivamente da 37 nel base a 3 nel DPO. Escluderli a posteriori avrebbe modificato il confronto.

13 Incertezza e costo computazionale

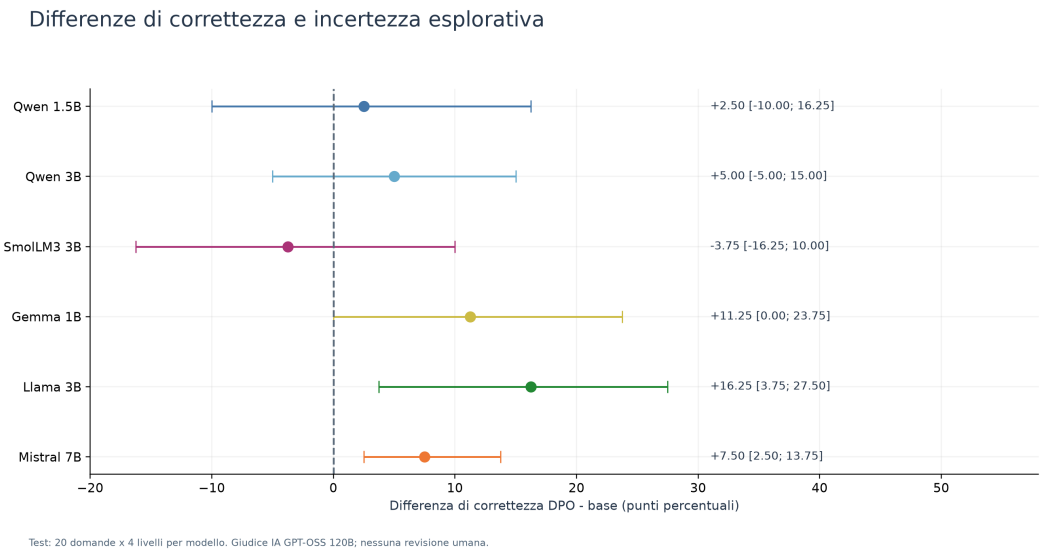


Figura 13: Differenza DPO meno Base nella quota di risposte C, con intervalli bootstrap esplorativi al 95%. Il ricampionamento raggruppa le osservazioni per dieci brani.

Le quattro versioni di una domanda condividono il contenuto e due domande possono condividere il brano. Trattare tutte le righe come indipendenti renderebbe l'incertezza troppo otti-

mistica. Il bootstrap usato raggruppa per contesto, ma dispone soltanto di dieci gruppi e non rappresenta tutte le dipendenze fra brani dello stesso PDF. Non incorpora inoltre errore del giudice, variabilità fra seed o scelta degli iperparametri.

Gli intervalli comprendono lo zero per Qwen 1.5B, Qwen 3B e SmolLM3; quello di Gemma lo tocca. Per Llama e Mistral restano positivi nel ricampionamento adottato. Non è stata applicata una correzione per confronti multipli: questi risultati non vengono trasformati in una dichiarazione generale di significatività. Un effetto osservato su un piccolo test rimane dipendente dal protocollo.

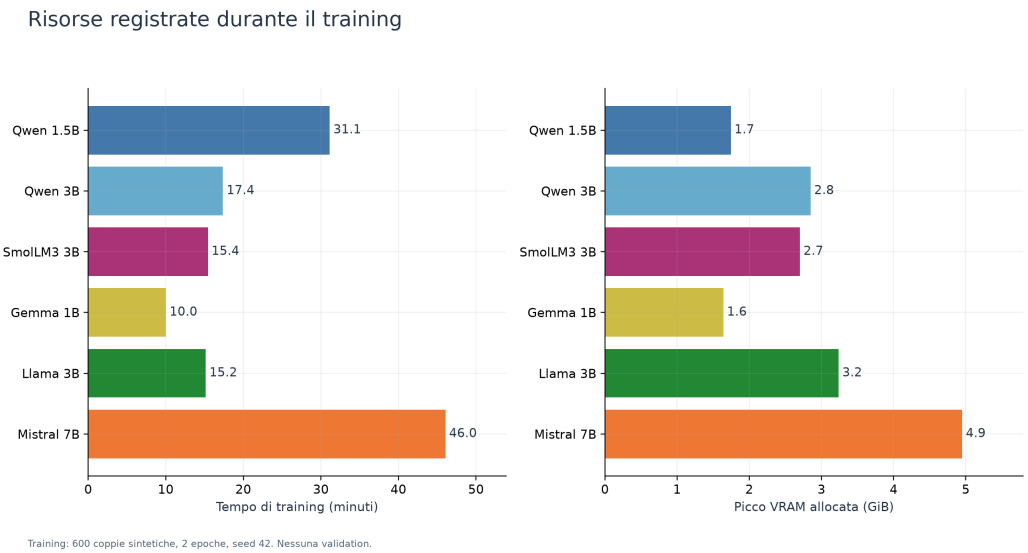


Figura 14: Durata del training e picco di memoria allocata registrato. Sono dati operativi dei run, non un benchmark controllato di velocità fra architetture.

Tutti i training sono stati completati sulla RTX 4070 Laptop da 8 GB. Le durate registrate vanno da circa 10 minuti per Gemma a 46 per Mistral; i picchi allocati sono compresi tra circa 1,64 e 4,95 GiB. Sono esclusi dal significato di "tempo di training" download, preparazione, esperimenti falliti e valutazione. La memoria allocata da PyTorch non coincide necessariamente con l'intera occupazione mostrata dal sistema.

PyTorch/CUDA, Transformers, Datasets, Accelerate, TRL, PEFT e bitsandbytes costituiscono lo stack della campagna. L'uso di adapter rende il lavoro fattibile su hardware personale; il costo più rilevante del percorso complessivo comprende anche costruzione dei dati, controlli e giudizi API, non soltanto gli step di ottimizzazione.

13.1 Confronti appaiati, lunghezza e intervalli

D/B/= indica il numero di preferenze derivate per DPO, Base e parità. Gli intervalli riguardano la differenza della quota C, in punti percentuali, e provengono dal bootstrap per brano; non sono intervalli sulle medie di lunghezza. Il raggiungimento del limite è un flag di possibile troncamento.

Tabella 11: Brevità, raggiungimento del limite token, preferenze appaiate e intervalli di confidenza

Modello	**Parole B→D**	**Limite token B→D**	**Preferenze D/ B/=**	**IC 95%, punti %**
Qwen 1.5B	76,3 → 52,0	2 → 0	25/18/37	-10,00; 16,25
Qwen 3B	103,0 → 48,0	2 → 0	18/18/44	-5,00; 15,00

Modello	Parole B→D	Limite token B→D	Preferenze D/ B/=	IC 95%, punti %
SmolLM3	117,4 → 83,6	10 → 2	10/12/58	-16,25; 10,00
Gemma 1B	89,4 → 54,8	5 → 0	28/21/31	0,00; 23,75
Llama 3B	146,3 → 63,3	15 → 1	26/21/33	3,75; 27,50
Mistral 7B	86,4 → 43,6	3 → 0	7/21/52	2,50; 13,75

14 Interfaccia e organizzazione del codice

14.1 Una demo utilizzabile del tutor

L'interfaccia Streamlit consente di selezionare livello A–D, modello e modalità Base, DPO o confronto affiancato. La risposta è accompagnata dai brani recuperati, consultabili in un pannello espandibile. È possibile esportare domande, risposte e fonti in JSON. La cronologia serve alla consultazione: ogni domanda viene elaborata separatamente e non viene simulata una memoria conversazionale non implementata.

Tabella 12: Componenti dell'interfaccia Streamlit e funzioni effettive nella dimostrazione

Elemento	Funzione effettiva
app.py	Gestisce impostazioni, input, risposte, fonti e visualizzazione dei risultati finali.
TutorService in backend.py	Riusa AdvancedRetriever.search e RAGGenerator.build_prompt; carica modello e adapter locali con Transformers/PEFT.
Confronto affiancato	Recupera i documenti una sola volta e genera con adapter spento/acceso sullo stesso modello.
Gestione delle risorse	Mantiene un solo modello; serializza l'accesso alla GPU; usa CPU per embedding e re-ranker.
run_app.ps1	Avvia Streamlit su localhost; non avvia training e non richiede chiavi Groq.

La demo legge i pesi già scaricati, gli adapter finali e l'indice esistente. La documentazione preesistente registra verifiche di avvio, controlli dell'interfaccia e un confronto reale Qwen 3B con due fonti; non sono stati rieseguiti per questa relazione. Questa verifica conferma il collegamento dei componenti, non la qualità educativa su tutte le domande o il funzionamento end-to-end di ogni famiglia in ogni condizione di memoria.

14.2 Perché demo e test restano distinti

Il test usa contesti congelati; la demo esegue una ricerca live con query italiana e il prompt RAG originale, senza traduzione e guardrail. Una risposta diversa nella demo non invalida né replica automaticamente il risultato del test. Il pulsante dei risultati mostra le misure già salvate e non le aggiorna usando conversazioni occasionali. Questa separazione evita che una dimostrazione favorevole venga presentata come un nuovo esperimento.

15 Motivazioni delle scelte e alternative non dimostrate

Tabella 13: Sintesi delle scelte progettuali, motivazioni funzionali ed evidenze sperimentali

Scelta	Motivazione documentata o funzionale	Evidenza e limite
Corpus multilingue e BGE-M3	Collegare domande italiane e fonti anche inglesi	Il denso supera BM25 nel silver test; nessuna gara esaustiva fra encoder.
Due stadi di recupero	Limitare il costo del cross-encoder ai candidati	Migliora R@3, ma il reranker isolato peggiora MRR e nDCG.
Fallback fra livelli vicini	Evitare pool troppo poveri per alcuni profili	Aumento della disponibilità; non prova di comprensibilità.
Bonus esatto di 0,5	Favorire fonti vicine ai prerequisiti richiesti	Guadagno osservato nel benchmark; peso non ottimizzato con una griglia.
DPO con negativi espliciti	Apprendere preferenze oltre l'imitazione della chosen	Il dataset privilegia correttezza e pertinenza; non isola il registro.
Sei famiglie/taglie	Osservare eterogeneità oltre il primo Qwen	Differiscono anche pretraining e template; nessuna causalità attribuibile alla sola taglia.
QLoRA e batch ridotto	Rispettare circa 8 GiB di VRAM	Sei run completati; non è un confronto con fine-tuning completo.
Iperparametri comuni	Rendere il protocollo comparabile	Non garantiscono il massimo potenziale di ciascun modello.
Contesti congelati	Ridurre la variabilità di retrieval	Valutazione della generazione, non dell'intera catena.
Giudice unico e cache	Rubrica uniforme e costo gestibile	Nessuna validazione umana indipendente; errori del giudice possibili.
Demo con encoder su CPU	Riservare la GPU al generatore	Compromesso funzionale, senza benchmark controllato di latenza.

Le motivazioni funzionali spiegano perché una scelta è plausibile nel progetto; non sostituiscono un'ablazione. Non sono stati confrontati sistematicamente parser, dimensioni dei chunk, valori del bonus, rank LoRA, beta, numero di epoche o diversi giudici. Dove mancano questi confronti, la formulazione corretta è "scelta adottata per questo vincolo", non "configurazione migliore".

15.1 Riproducibilità e perimetro della verifica

La campagna conserva revisioni dei checkpoint, configurazioni degli adattatori, tokenizer, hash dei dati, risposte grezze, giudizi e riepiloghi. Lo stack registrato nei sei manifest comprende Python 3.14.3, PyTorch 2.11.0+cu128, Transformers 4.57.6, Datasets 5.0.1, Accelerate 1.15.0, TRL 0.24.0, PEFT 0.17.1 e bitsandbytes 0.48.1. Sono versioni dei run salvati; non si sostiene che l'ambiente locale attuale sia identico o che l'intero setup sia stato reinstallato durante questa relazione.

I percorsi storici nei manifest descrivono il luogo originale di esecuzione e non vengono riscritti per adattarli al repository spostato. La riproduzione richiede pesi dei modelli, adattatori, tokenizer e indice, oltre al codice. Il file delle dipendenze è una lista consolidata, non un lockfile transitivo completo. Le revisioni di encoder e reranker non risultano fissate al commit nel percorso ordinario di caricamento: preservare gli snapshot resta necessario.

Per redigere questa relazione sono stati letti documentazione, codice e risultati salvati; sono stati ricalcolati i conteggi del corpus e verificate le corrispondenze dei riepiloghi con i record della campagna. Non sono stati rilanciati addestramenti, generazioni, scraping o richieste al giudice. I

nuovi diagrammi rappresentano l'architettura; non introducono nuove prestazioni. La distinzione consente di aggiornare la descrizione senza alterare l'esperimento originale.

16 Discussione e conclusioni

16.1 Che cosa dimostra il lavoro

AstroTutor ha raggiunto due risultati distinti: una pipeline utilizzabile per rispondere su documenti astronomici e un confronto tracciabile dell'effetto del DPO su sei modelli. Il secondo mostra miglioramenti della correttezza stimata in cinque casi, insieme a una riduzione generalizzata della lunghezza. Completezza e adeguatezza non seguono lo stesso andamento. La risposta alla domanda iniziale è quindi articolata: **il DPO può essere utile con questi dati e queste impostazioni, ma non realizza automaticamente un tutor didatticamente migliore**.

La distinzione è coerente con il segnale di training. Le coppie contrappongono soprattutto risposte corrette a errori o contenuti estranei; non isolano la preferenza per un registro adeguato. Il mancato guadagno didattico non dimostra l'inefficacia generale del metodo. Allo stesso tempo, la discesa della loss e alcuni miglioramenti fattuali non autorizzano a dichiarare raggiunto l'obiettivo educativo originario.

16.2 Limiti e sviluppi motivati dai risultati

I limiti principali sono dati sintetici non revisionati indipendentemente, test di 20 domande, un solo seed, un solo giudice automatico e assenza di un confronto SFT sistematico. La separazione per documento riduce alcune contaminazioni, ma non esclude somiglianze concettuali. Il test controllato esclude gli errori di retrieval; la demo li reintroduce. Nessuno studio ha misurato apprendimento, autonomia o comprensione degli studenti.

Un'estensione mirata dovrebbe introdurre coppie entrambe corrette e pertinenti ma diverse per qualità della spiegazione, raccogliere una revisione cieca indipendente e confrontare Base, SFT, DPO e SFT+DPO sugli stessi dati. Per attribuire l'effetto del DPO dopo SFT, il confronto necessario è SFT contro SFT+DPO. Repliche con più seed e un test più ampio renderebbero più solide le stime; uno studio con studenti risponderebbe a una domanda diversa, quella dell'efficacia educativa.

16.3 Bilancio rispetto agli obiettivi iniziali

È stata realizzata una catena documentale e di inferenza utilizzabile, ed è stato misurato un effetto del DPO sulla correttezza stimata che varia con il modello. Non è stato dimostrato un miglioramento uniforme della personalizzazione didattica, né dell'apprendimento degli studenti. È altrettanto scorretto trasformare questa assenza di prova in una dimostrazione dell'inutilità generale del DPO: il risultato dipende dal segnale di preferenza, dalla taglia del test, dal giudice e dal protocollo adottato.

Le priorità sperimentali conseguono ai limiti osservati: costruire preferenze che isolino il registro mantenendo correttezza e pertinenza comparabili; includere SFT come controllo; ripetere il training con più seed; ampliare domande e fonti; rivedere in cieco un campione consistente di giudizi. Per la pipeline live, servono invece verifiche dedicate di recupero, qualità delle tabelle e formule, provenienza dei duplicati e rifiuti su contesti insufficienti. La latenza per stadio non viene quantificata in questa relazione perché manca un benchmark finale controllato.

17 Appendice: diagnostica completa e lettura dei grafici

Le figure aggiuntive completano quelle nel corpo della relazione. I dati sono gli stessi della campagna salvata; non costituiscono repliche indipendenti. La media mobile delle curve di training è retrospettiva su 20 step, con finestra ridotta all'inizio. Le linee grezze restano visibili e il confine fra epoche è indicato. Nessun grafico di training sostituisce una curva di validation, assente nei sei run.

17.1 Accuratezza delle preferenze

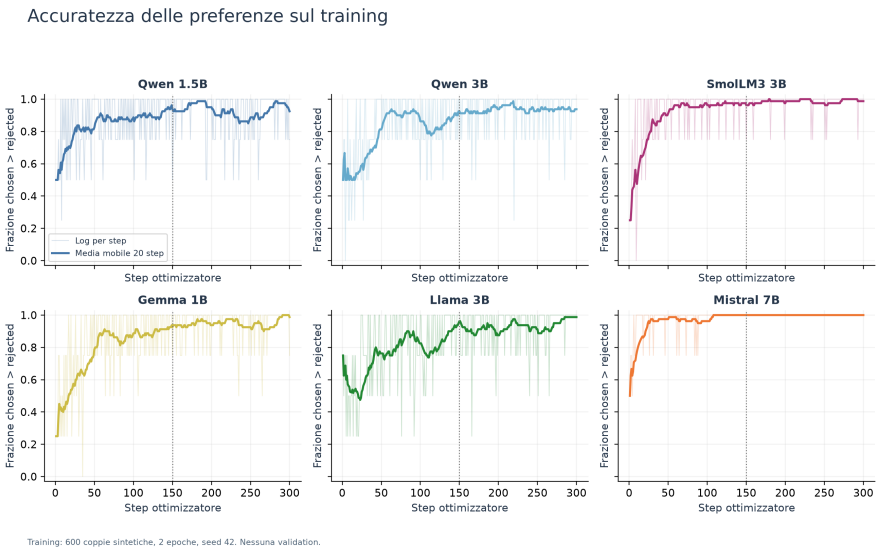


Figura 15: Accuratezza delle preferenze. Metriche del training finale; non sono giudizi esterni sulle risposte.

La quota di margini positivi descrive il successo sulle coppie di training. Un valore elevato può coesistere con un effetto modesto o negativo sulla correttezza del test, come ricorda il caso SmolLM3. Non misura il numero di risposte astronomiche corrette.

17.2 Margine rispetto al riferimento

Il margine misura la separazione fra i reward impliciti di chosen e rejected. La sua crescita conferma la direzione dell'ottimizzazione, senza stabilire che tale separazione corrisponda al criterio didattico desiderato.

17.3 Norma dei gradienti

La serie è diagnostica dell'ottimizzazione. Un valore registrato superiore a uno non dimostra che il clipping sia disattivato: il logging può precedere l'applicazione del clipping. Non si confrontano le scale come una classifica di qualità dei modelli.

17.4 Reward impliciti dei due completamenti

Chosen e rejected vanno lette insieme: il margine può aumentare soprattutto perché si riduce il reward della rejected. I reward sono differenze di log-probabilità rispetto al riferimento e non i voti del giudice Groq.

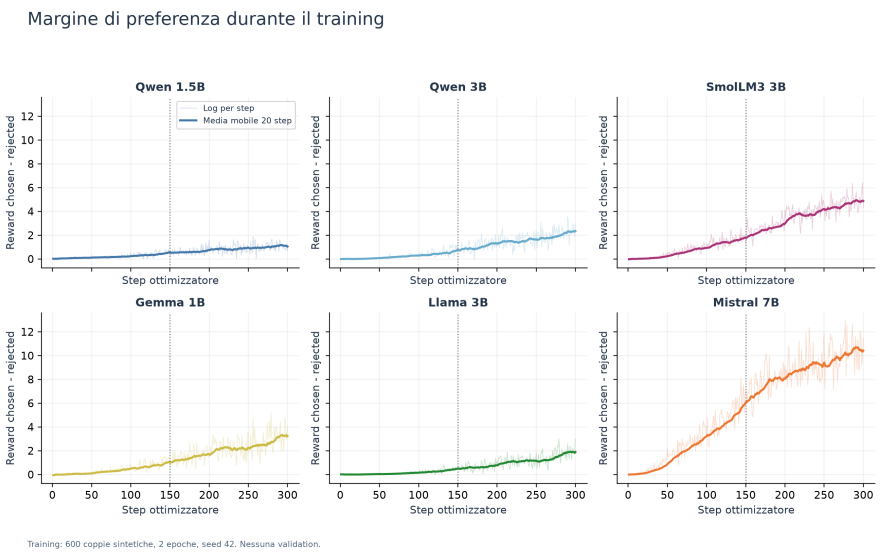


Figura 16: Margine rispetto al riferimento. Metriche del training finale; non sono giudizi esterni sulle risposte.

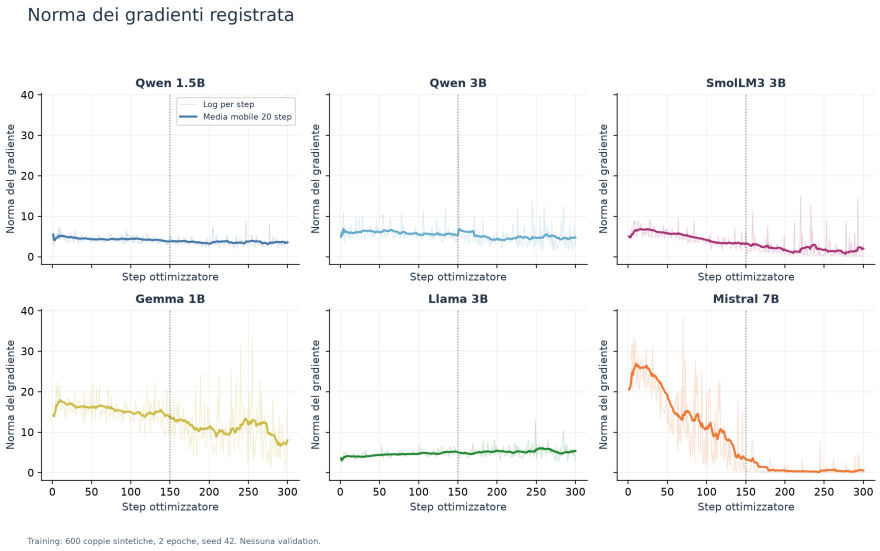


Figura 17: Norma dei gradienti. Metriche del training finale; non sono giudizi esterni sulle risposte.

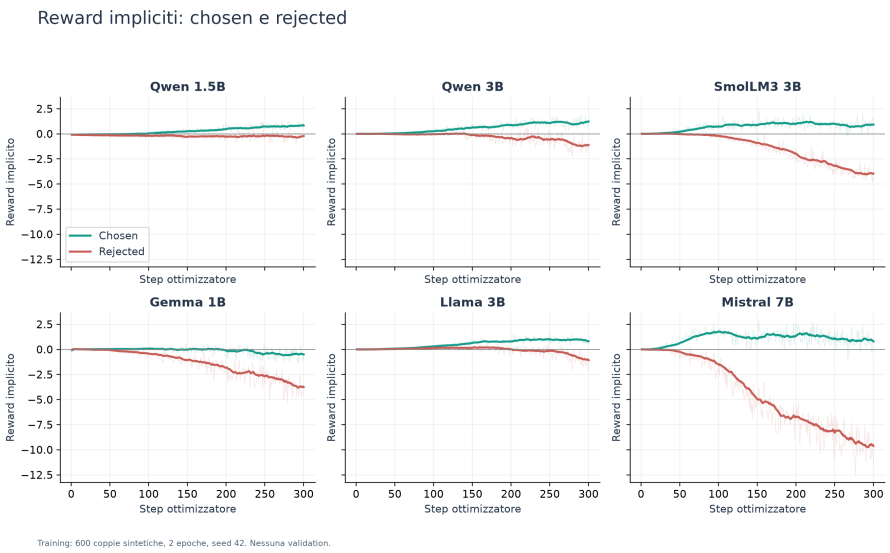


Figura 18: Reward impliciti dei due completamenti. Metriche del training finale; non sono giudizi esterni sulle risposte.

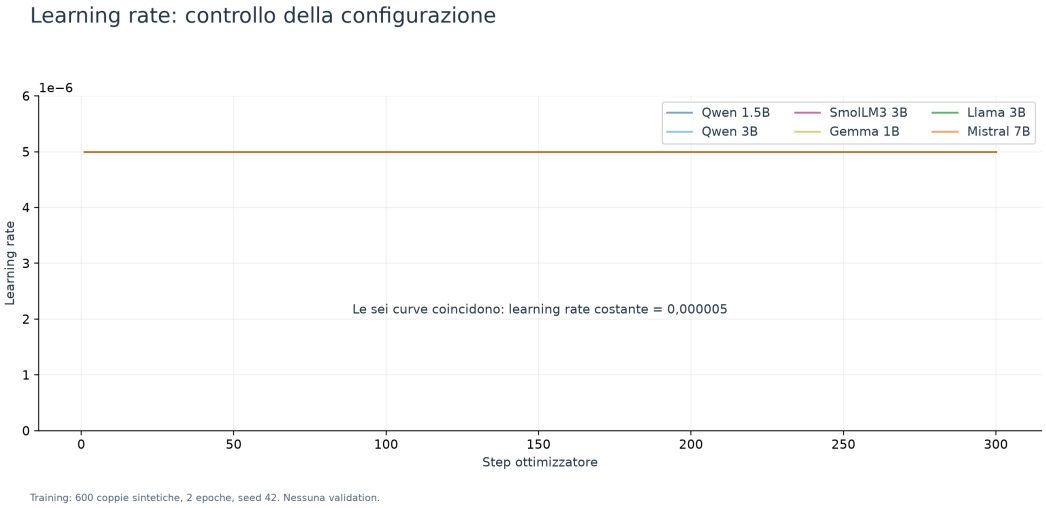


Figura 19: Learning rate effettivo. Metriche del training finale; non sono giudizi esterni sulle risposte.

17.5 Learning rate effettivo

La costanza della curva è coerente con scheduler constant e warmup nullo nei manifest finali. Non si attribuisce a questi run lo scheduler cosine delle configurazioni storiche. Nessuna ricerca separata del learning rate per famiglia è documentata.

17.6 Distribuzione completa C/P/I

I conteggi per classe mostrano ciò che la sola quota C nasconde. Qwen 1.5B passa da 18 a 20 risposte I pur aumentando da 40 a 42 le C; Qwen 3B passa invece da otto I a zero, ma mantiene 13 risposte P.

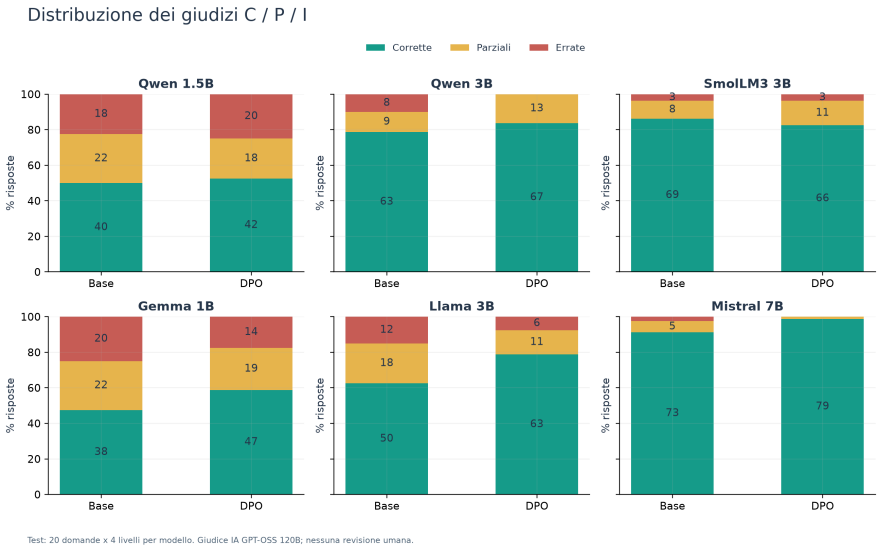


Figura 20: Distribuzione completa C/P/I. Dati della campagna finale; giudizi automatici e campione dipendente.

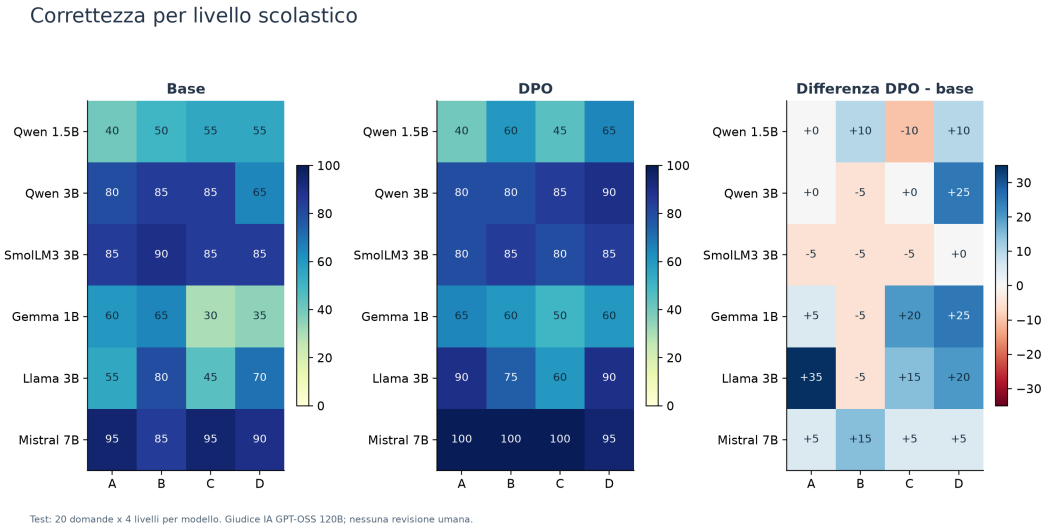


Figura 21: Correttezza distinta per profilo. Dati della campagna finale; giudizi automatici e campione dipendente.

17.7 Correttezza distinta per profilo

Ogni cella contiene 20 risposte: una risposta vale cinque punti percentuali. Il confronto per livello localizza l'eterogeneità, ma non crea nuovi campioni indipendenti e non dimostra competenza generale per un intero grado scolastico.

17.8 Preferenze derivate dai voti

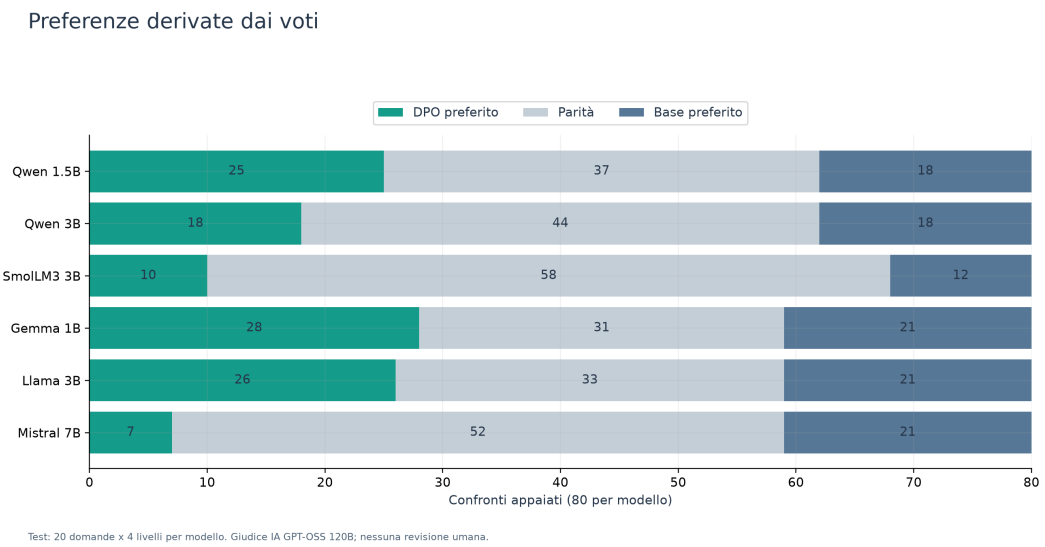


Figura 22: Preferenze derivate dai voti. Dati della campagna finale; giudizi automatici e campione dipendente.

La regola confronta nell'ordine correttezza, completezza, adeguatezza e chiarezza, mantenendo le parità. Il giudice non svolge una seconda valutazione globale della coppia. Per Mistral, sette preferenze DPO e 21 Base coesistono con una quota C migliore dopo DPO.

17.9 Raggiungimento del limite di output

Il flag indica 384 nuovi token senza token finale EOS. È un possibile troncamento, non una certezza di errore. I casi rimangono nel test; la riduzione complessiva da 37 a tre contribuisce a descrivere il cambiamento di comportamento, ma non dimostra da sola un miglioramento della spiegazione.

17.10 Transizioni appaiate fra giudizi

Righe e colonne rappresentano rispettivamente Base e DPO sullo stesso prompt. Le celle fuori diagonale separano miglioramenti e regressioni individuali: il saldo aggregato può nascondere entrambi. L'appaiamento è informativo, ma le varianti condividono domande e brani.

17.11 Variazioni per argomento

Ogni argomento comprende soltanto otto risposte per condizione, due domande ai quattro livelli. Una risposta vale 12,5 punti percentuali. Le differenze servono a identificare casi da rivedere; non sono una graduatoria affidabile delle competenze astronomiche generali.

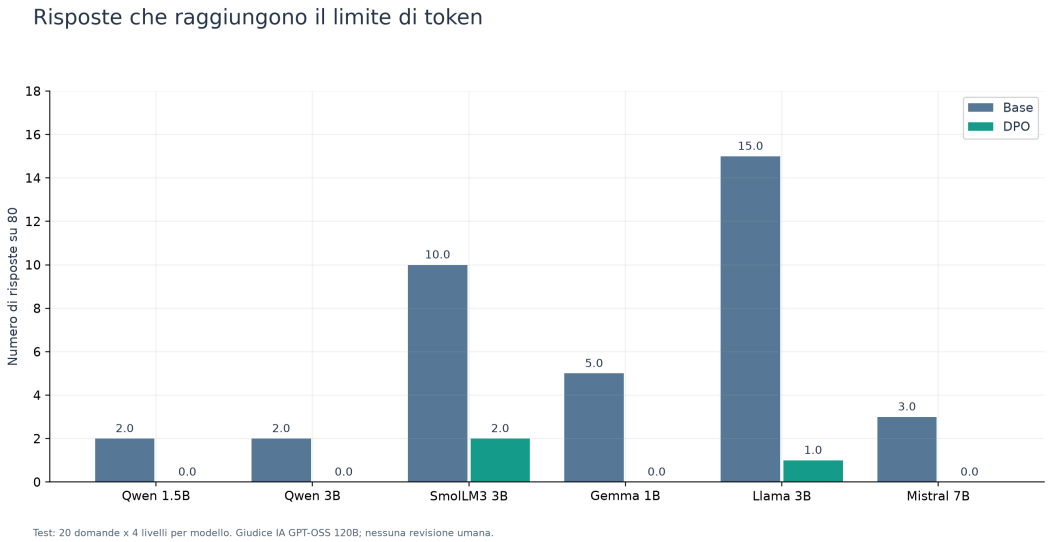


Figura 23: Raggiungimento del limite di output. Dati della campagna finale; giudizi automatici e campione dipendente.

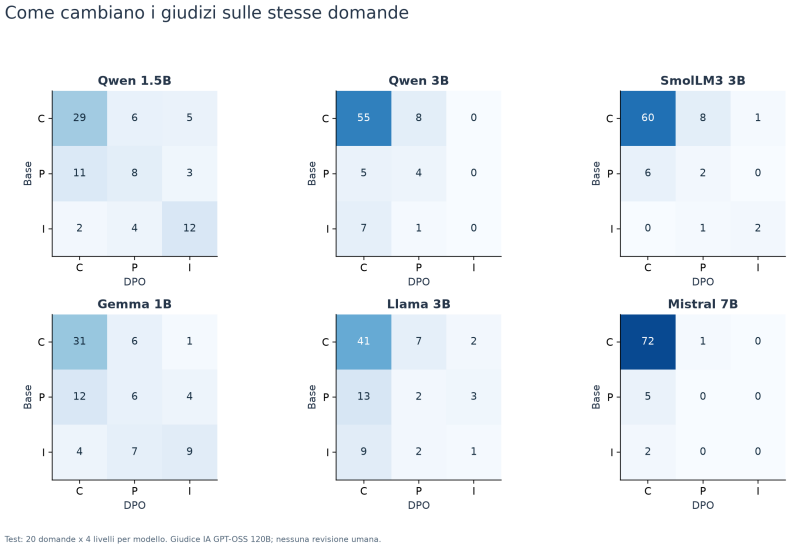


Figura 24: Transizioni appaiate fra giudizi. Dati della campagna finale; giudizi automatici e campione dipendente.

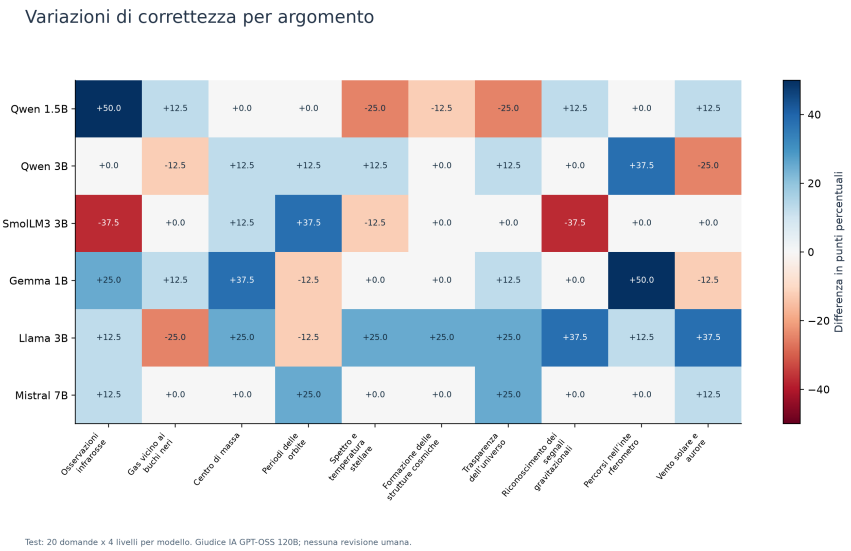


Figura 25: Variazioni per argomento. Dati della campagna finale; giudizi automatici e campione dipendente.

18 Riferimenti e provenienza dei dati

La ricostruzione copre l'ideazione del 1 ottobre 2025, lo sviluppo documentato fino al 26 luglio 2026 e la campagna successiva conservata nello snapshot esaminato l'11 novembre 2026. Non si attribuisce a questa ultima data l'esecuzione dei training. Sono presenti tutti i tredici resoconti storici richiamati dall'indice delle attività fino a luglio; la fase successiva è ricostruita da dataset, manifest, record, grafici e documentazione consolidata, senza un diario giornaliero equivalente disponibile.

18.1 Fonti teoriche

[1] Lewis et al. (2020), *Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks.* https://arxiv.org/abs/2005.11401

[2] Rafailov et al. (2023), *Direct Preference Optimization: Your Language Model is Secretly a Reward Model.* https://arxiv.org/abs/2305.18290

[3] Dettmers et al. (2023), *QLoRA: Efficient Finetuning of Quantized LLMs.* https://arxiv.org/abs/2305.14314

Questi riferimenti descrivono i metodi generali. Non sono prove dei risultati di AstroTutor, che derivano esclusivamente dagli artefatti sperimentali interni. In particolare, il progetto usa una composizione modulare di retrieval e generazione: non replica integralmente l'addestramento congiunto del lavoro originario sul RAG.

18.2 Mappa degli artefatti verificabili

Tabella 14: Mappa degli artefatti verificabili conservati nel repository

Evidenza	Artefatto relativo al repository	Utilità
Architettura e runtime	src/parsing.py, chuncking.py, indexing.py, retrieval.py, generation.py	Verifica del flusso e dei parametri effettivi.
Corpus	data/processed/chunks/	Conteggi delle righe e dei testi distinti.
Benchmark IR	data/retrieval_eval.json e retrieval_eval_meta.json	Metriche, popolazione e configurazione storica.
Dataset finale	experiments/dpo_pdf_600/data/dataset_consegna/	Coppie, snapshot, provenienza e controlli strutturali.
Sviluppo e test	experiments/dpo_pdf_600/data/	Prompt congelati e manifest di separazione.
Training	experiments/dpo_pdf_600/runs/	Manifest, metriche e cronologie dei sei run.
Risposte e giudizi	experiments/dpo_pdf_600/results/evaluation/	Record per condizione e riepilogo final_groq_v1.
Grafici della campagna	experiments/dpo_pdf_600/results/figures/	Diciotto figure, didascalie e hash degli input.
Demo	experiments/dpo_pdf_600/demo/	Interfaccia, gestione dei modelli e recupero live.

I percorsi sono riportati soltanto in questa mappa di riproducibilità. I nomi di file e cartelle descrivono lo snapshot corrente; gli hash e i percorsi storici incorporati nei manifest originali sono preservati. La relazione non sostituisce i record delle risposte né i giudizi individuali.

La costruzione dei dati finali e la redazione sono assistite da IA. I controlli strutturali, la revisione della relazione e il rendering del PDF non equivalgono a una validazione scientifica indipendente delle risposte. Le motivazioni non dimostrate da ablazioni sono dichiarate come scelte funzionali o ipotesi.